Bitcoin Overnight Signals für den QQQ-Eröffnungsgap

Kurzfassung

Wir untersuchen, ob die Bitcoin-Aktivität zwischen dem Ende der vorherigen regulären Nasdaq-Sitzung und 09:00 Uhr New Yorker Zeit zusätzliche Information für die Richtung des QQQ-Eröffnungsgaps um 09:30 Uhr enthält. Dafür vergleichen wir eine historische Mehrheitsklasse, logistische Regression, XGBoost und Chronos-2 jeweils in einem strikt chronologischen Walk-forward-Design.

Auf Basis der Expanding-window-Validierung 2021 bis 2025 wählen wir **XGBoost + Bitcoin** vor der Öffnung des Holdouts als Hauptmodell. Im partiellen Holdout vom 2. Januar bis 31. August 2026 erreicht es auf 166 Handelstagen **73,5 % Accuracy** und **74,0 % Balanced Accuracy**. Die XGBoost-Kontrollvariante ohne Bitcoin erreicht **51,2 % Accuracy** und **54,2 % Balanced Accuracy**. Der Bitcoin-Zusatz beträgt damit im Holdout **+19,8 Prozentpunkte Balanced Accuracy** und ist in sieben von acht Monaten positiv.

Das Ergebnis unterstützt die Prognosehypothese für diesen Zeitraum, beweist aber weder Kausalität noch die Profitabilität einer Handelsstrategie. Der Holdout umfasst acht Monate; insbesondere die 32 Montage erlauben keine belastbare separate Wochenendaussage.

1. Aufgabe und Untersuchungsdesign

Erklärung

Für den QQQ-Handelstag (t) berechnen wir den numerischen Eröffnungsgap als logarithmische Rendite vom Schluss der vorherigen regulären Sitzung bis zum Open des Zieltags:

$$y_t = r_t^{gap} = \log\left(\frac{Open_t^{QQQ}}{Close_{t-1}^{QQQ}}\right).$$

Die primäre Zielvariable ist die Richtung:

$$Direction_t = \mathbb{1}(y_t > 0).$$

`1` bedeutet, dass QQQ höher eröffnet; `0` bezeichnet eine gleich hohe oder tiefere Eröffnung. Der numerische Gap bleibt für die EDA und die Chronos-2-Prognose erhalten.

Für die trainierbaren Klassifikationsmodelle vergleichen wir zwei Feature-Sets:

1. **Kontrolle:** QQQ-Historie, Fear & Greed, VIX, DXY und Kalender.
2. **Mit Bitcoin:** dieselben Variablen plus BTC-Overnight-Merkmale.

Nur der Unterschied zwischen diesen Varianten misst den zusätzlichen Informationsgehalt von Bitcoin. Chronos-2 übernimmt denselben Vergleich als vortrainiertes Zero-shot-Modell für den numerischen Gap. Eine zusätzliche univariate Chronos-Variante verwendet ausschließlich die historische Zielzeitreihe als Referenz. Wir untersuchen eine Prognosebeziehung, keine Kausalität und keine fertige Handelsstrategie.

Zeitliche Evaluation

- Entwicklung und Expanding-window-Validierung: bis Ende 2025.
- Validierungsjahre: 2021 bis 2025.
- Finaler, in der EDA unberührter Holdout: 1. Januar 2026 bis zum festen Datenstichtag 1. September 2026 (exklusiv).

2. Setup

Erklärung

Alle zentralen Parameter stehen sichtbar in einer Zelle. Marktzeiten werden in `America/New_York` definiert und für die Berechnung nach UTC konvertiert. `exchange_calendars` liefert reguläre Nasdaq-Sitzungen, Feiertage und verkürzte Handelstage. Die tabellarische Verarbeitung läuft auf der CPU; MPS wird erst für Chronos-2 relevant.

```
from importlib.metadata import PackageNotFoundError, version
from pathlib import Path
from zipfile import ZipFile
import os
import platform
import random
import warnings

import exchange_calendars as xcals
from IPython.display import Markdown, display
import matplotlib.pyplot as plt
import numpy as np
import pandas as pd
import requests
import seaborn as sns
import yfinance as yf

# Keep all configuration visible and reproducible
RANDOM_SEED = 42
START_DATE = "2018-02-01"
DATA_END_DATE = "2026-09-01"  # Exclusive and fully completed
HOLDOUT_START = pd.Timestamp("2026-01-01")
VALIDATION_YEARS = [2021, 2022, 2023, 2024, 2025]
FORECAST_TIMEZONE = "America/New_York"
FORECAST_HOUR = 9
BINANCE_SYMBOL = "BTCUSDT"
BINANCE_INTERVAL = "1h"
CHRONOS_MODEL_ID = "amazon/chronos-2"
CHRONOS_BATCH_SIZE = 64
CHRONOS_QUANTILES = [0.10, 0.50, 0.90]
XGBOOST_N_JOBS = 1
os.environ["OMP_NUM_THREADS"] = str(XGBOOST_N_JOBS)

# Validate the fixed data range
data_end_timestamp = pd.Timestamp(DATA_END_DATE)
```

```
current_utc_day = pd.Timestamp.now(tz="UTC").normalize().tz_localize(None)
assert data_end_timestamp <= current_utc_day

# Resolve paths from the repository root or the notebooks folder
PROJECT_ROOT = Path.cwd()
if PROJECT_ROOT.name == "notebooks":
    PROJECT_ROOT = PROJECT_ROOT.parent

RAW_DATA_DIR = PROJECT_ROOT / "data" / "raw"
BINANCE_CACHE_DIR = RAW_DATA_DIR / "binance" / BINANCE_SYMBOL / BINANCE_INTERVAL
PROCESSED_DATA_DIR = PROJECT_ROOT / "data" / "processed"
RAW_DATA_DIR.mkdir(parents=True, exist_ok=True)
BINANCE_CACHE_DIR.mkdir(parents=True, exist_ok=True)
PROCESSED_DATA_DIR.mkdir(parents=True, exist_ok=True)

# Make random operations reproducible
random.seed(RANDOM_SEED)
np.random.seed(RANDOM_SEED)

# Use Viridis consistently for tables and plots
sns.set_theme(style="whitegrid", palette="viridis")
plt.rcParams.update(
    {
        "figure.figsize": (12, 5),
        "axes.titlesize": 14,
        "axes.labelsize": 11,
        "legend.frameon": False,
        "figure.dpi": 110,
    }
)
VIRIDIS = plt.colormaps["viridis"]
COLORS = {
    "qqq": VIRIDIS(0.12),
    "btc": VIRIDIS(0.38),
    "fear_greed": VIRIDIS(0.58),
    "vix": VIRIDIS(0.74),
    "dxy": VIRIDIS(0.90),
}

# Allow unsupported MPS operations to fall back safely to the CPU
os.environ.setdefault("PYTORCH_ENABLE_MPS_FALLBACK", "1")

# Detect Apple Silicon acceleration for the foundation model
try:
    import torch

    TORCH_VERSION = torch.__version__
    DEVICE = "mps" if torch.backends.mps.is_available() else "cpu"
except ImportError:
    torch = None
    TORCH_VERSION = "nicht installiert"
    DEVICE = "cpu"
```

```
def installed_version(package_name):
    # Return one version string for the reproducibility table
    try:
        return version(package_name)
    except PackageNotFoundError:
        return "nicht installiert"


environment_table = pd.DataFrame(
    {
        "Komponente": [
            "Python",
            "Betriebssystem",
            "Prozessor",
            "PyTorch",
            "Chronos-Gerät",
            "Forecast-Zeitzone",
            "Informations-Cutoff",
            "Erster Datentag",
            "Exklusiver Datenstichtag",
            "Holdout ab",
            "pandas",
            "exchange-calendars",
            "yfinance",
            "XGBoost",
            "chronos-forecasting",
        ],
        "Wert": [
            platform.python_version(),
            platform.platform(),
            platform.machine(),
            TORCH_VERSION,
            DEVICE,
            FORECAST_TIMEZONE,
            "09:00 Uhr ET",
            START_DATE,
            DATA_END_DATE,
            HOLDOUT_START.date(),
            installed_version("pandas"),
            installed_version("exchange-calendars"),
            installed_version("yfinance"),
            installed_version("xgboost"),
            installed_version("chronos-forecasting"),
        ],
    }
)
display(environment_table)
```

	Komponente	Wert
0	Python	3.11.13

	Komponente	Wert
1	Betriebssystem	macOS-26.6.2-arm64-arm-64bit
2	Prozessor	arm64
3	PyTorch	2.13.0
4	Chronos-Gerät	mps
5	Forecast-Zeitzone	America/New_York
6	Informations-Cutoff	09:00 Uhr ET
7	Erster Datentag	2018-02-01
8	Exklusiver Datenstichtag	2026-09-01
9	Holdout ab	2026-01-01
10	pandas	None
11	exchange-calendars	4.13.2
12	yfinance	1.5.1
13	XGBoost	3.2.0
14	chronos-forecasting	2.3.1

Interpretation

Die Tabelle dokumentiert den festen Informationsstand und die tatsächlich verwendete Umgebung. Der Prognose-Cutoff liegt immer vor dem Ziel-Open. Dadurch können spätere Modellprognosen realistisch und ohne Zugriff auf den QQQ-Eröffnungskurs erzeugt werden.

3. Daten beschaffen und Rohdaten prüfen

Erklärung

Wir laden stündliche `BTCUSDT`-Kerzen aus dem öffentlichen Binance-Archiv. QQQ, VIX und DXY stammen über `yfinance` von Yahoo Finance; Fear & Greed beziehen wir über die API von Alternative.me. Nach dem ersten erfolgreichen Lauf werden die Rohdaten lokal zwischengespeichert.

Inhalt	Quelle / Symbol	Verwendung
Bitcoin OHLCV	Binance `BTCUSDT`, 1 Stunde	Overnight-Merkmale
Nasdaq-100 ETF	Yahoo `QQQ`	Ziel und eigene Historie
Volatilitätsindex	Yahoo `^VIX`	Marktunsicherheit
US-Dollar-Index	Yahoo `DX-Y.NYB`	Makroumfeld
Fear & Greed	Alternative.me	Krypto-Sentiment

Binance verwendet in älteren Archivdateien Millisekunden und in neueren Dateien teilweise Mikrosekunden. Die Einheit wird pro Datei anhand der Grössenordnung erkannt.

```
BINANCE_COLUMNS = [
    "open_time",
    "open",
    "high",
    "low",
    "close",
    "volume",
    "close_time",
    "quote_volume",
    "trade_count",
    "taker_buy_base_volume",
    "taker_buy_quote_volume",
    "ignore",
]


def parse_binance_time(values):
    # Detect millisecond or microsecond Unix timestamps per archive file
    numeric_values = pd.to_numeric(values, errors="coerce")
    non_missing = numeric_values.dropna()
    assert not non_missing.empty, "Binance-Datei ohne gültige Zeitstempel"
    unit = "us" if non_missing.median() >= 10**14 else "ms"
    return pd.to_datetime(numeric_values, unit=unit, utc=True)


def read_binance_archive(cache_path, url, filename):
    # Download and parse one official Binance ZIP archive
    if not cache_path.exists():
        response = requests.get(
            url,
            headers={"User-Agent": "CSP1 educational time-series project"},
            timeout=60,
        )
        if response.status_code == 404:
            return None
        response.raise_for_status()
        cache_path.write_bytes(response.content)

    with ZipFile(cache_path) as archive:
        csv_names = [name for name in archive.namelist() if name.endswith(".csv")]
        assert len(csv_names) == 1, f"Unerwarteter Inhalt in {filename}"
        with archive.open(csv_names[0]) as stream:
            frame = pd.read_csv(stream, header=None, names=BINANCE_COLUMNS)

    frame["open_time"] = parse_binance_time(frame["open_time"])
    frame["close_time"] = parse_binance_time(frame["close_time"])
    frame = frame.dropna(subset=["open_time", "close_time"]).copy()
    frame = frame.loc[frame["close_time"] > frame["open_time"]].copy()
    numeric_columns = ["open", "high", "low", "close", "volume"]
    frame[numeric_columns] = frame[numeric_columns].apply(
        pd.to_numeric, errors="coerce"
    )
    return frame[["open_time", "close_time", *numeric_columns]]
```

```
def read_binance_month(month_start):
    # Prefer the compact monthly archive and fall back to daily archives
    month_label = month_start.strftime("%Y-%m")
    filename = f"{BINANCE_SYMBOL}-{BINANCE_INTERVAL}-{month_label}.zip"
    cache_path = BINANCE_CACHE_DIR / filename
    url = (
        "https://data.binance.vision/data/spot/monthly/klines/"
        f"{BINANCE_SYMBOL}/{BINANCE_INTERVAL}/{filename}"
    )
    monthly_frame = read_binance_archive(cache_path, url, filename)
    if monthly_frame is not None:
        return monthly_frame

    # A completed month can briefly be available only as daily archives
    month_end = month_start + pd.offsets.MonthEnd(0)
    daily_frames = []
    for day_start in pd.date_range(month_start, month_end, freq="D"):
        day_label = day_start.strftime("%Y-%m-%d")
        daily_filename = (
            f"{BINANCE_SYMBOL}-{BINANCE_INTERVAL}-{day_label}.zip"
        )
        daily_cache_path = BINANCE_CACHE_DIR / daily_filename
        daily_url = (
            "https://data.binance.vision/data/spot/daily/klines/"
            f"{BINANCE_SYMBOL}/{BINANCE_INTERVAL}/{daily_filename}"
        )
        daily_frame = read_binance_archive(
            daily_cache_path, daily_url, daily_filename
        )
        assert daily_frame is not None, (
            f"Binance-Archiv fehlt für {day_label}"
        )
        daily_frames.append(daily_frame)

    return pd.concat(daily_frames, ignore_index=True)


def validate_bitcoin_hourly(frame):
    # Check the market-data contract before feature construction
    assert not frame.empty, "Bitcoin: keine Daten"
    assert frame.index.is_monotonic_increasing, "Bitcoin: Zeit nicht sortiert"
    assert frame.index.is_unique, "Bitcoin: doppelte Stunden"
    assert frame.notna().all().all(), "Bitcoin: fehlende Werte"
    assert np.isfinite(
        frame[["open", "high", "low", "close", "volume"]].to_numpy()
    ).all(), "Bitcoin: nicht endliche Werte"
    assert (frame["close_time"] > frame.index).all()
    assert (frame[["open", "high", "low", "close"]] > 0).all().all()
    assert (frame["volume"] >= 0).all()
    assert (
        frame["high"] >= frame[["open", "close", "low"]].max(axis=1)
```

```
    ).all()
    assert (
        frame["low"] <= frame[["open", "close", "high"]].min(axis=1)
    ).all()


def load_binance_hourly():
    # Prefer one compact combined cache after the first successful run
    combined_cache = (
        RAW_DATA_DIR
        / f"btc_{BINANCE_SYMBOL}_{BINANCE_INTERVAL}_{START_DATE}_{DATA_END_DATE}.csv.gz"
    )
    if combined_cache.exists():
        cached = pd.read_csv(combined_cache)
        required_cache_columns = {
            "open_time", "close_time", "open", "high", "low", "close", "volume"
        }
        if required_cache_columns.issubset(cached.columns):
            cached["open_time"] = pd.to_datetime(
                cached["open_time"], utc=True, format="mixed"
            )
            cached["close_time"] = pd.to_datetime(
                cached["close_time"], utc=True, format="mixed"
            )
            cached = cached.set_index("open_time").sort_index()
            validate_bitcoin_hourly(cached)
            return cached

    # Download every complete calendar month in the fixed range
    first_month = pd.Timestamp(START_DATE).to_period("M").start_time
    last_month = (pd.Timestamp(DATA_END_DATE) - pd.Timedelta(days=1)).to_period(
        "M"
    ).start_time
    month_starts = pd.date_range(first_month, last_month, freq="MS")
    monthly_frames = [read_binance_month(month) for month in month_starts]

    frame = pd.concat(monthly_frames, ignore_index=True)
    frame = frame.set_index("open_time").sort_index()
    frame = frame.loc[
        (frame.index >= pd.Timestamp(START_DATE, tz="UTC"))
        & (frame.index < pd.Timestamp(DATA_END_DATE, tz="UTC"))
    ]
    validate_bitcoin_hourly(frame)
    frame.reset_index().to_csv(combined_cache, index=False, compression="gzip")
    return frame


YAHOO_SERIES = {
    "qqq": {
        "ticker": "QQQ",
        "columns": ["Open", "High", "Low", "Close", "Volume"],
    },
    "vix": {"ticker": "^VIX", "columns": ["Close"]},
```

```
    "dxy": {"ticker": "DX-Y.NYB", "columns": ["Close"]},
}


def validate_yahoo_frame(frame, series_name):
    # Keep source checks simple, explicit and visible
    assert not frame.empty, f"{series_name}: keine Daten"
    assert frame.index.is_monotonic_increasing, f"{series_name}: nicht sortiert"
    assert frame.index.is_unique, f"{series_name}: doppelte Tage"
    assert frame.notna().all().all(), f"{series_name}: fehlende Rohwerte"
    assert np.isfinite(frame.select_dtypes("number")).all().all()
    assert frame.index.min() >= pd.Timestamp(START_DATE)
    assert frame.index.max() < pd.Timestamp(DATA_END_DATE)
    assert (frame.select_dtypes("number") >= 0).all().all()

    if series_name == "qqq":
        assert (
            frame["qqq_high"]
            >= frame[["qqq_open", "qqq_close", "qqq_low"]].max(axis=1)
        ).all()
        assert (
            frame["qqq_low"]
            <= frame[["qqq_open", "qqq_close", "qqq_high"]].min(axis=1)
        ).all()


def find_latest_month_boundary_cache(filename_prefix):
    # Reuse the newest compatible range cache before fetching missing dates
    target_end = pd.Timestamp(DATA_END_DATE)
    candidates = []
    for candidate_path in RAW_DATA_DIR.glob(f"{filename_prefix}*.csv"):
        end_label = candidate_path.stem.removeprefix(filename_prefix)
        try:
            candidate_end = pd.Timestamp(end_label)
        except ValueError:
            continue
        if candidate_end.day == 1 and candidate_end < target_end:
            candidates.append((candidate_end, candidate_path))
    return max(candidates, default=(None, None), key=lambda item: item[0])


def load_yahoo_series(series_name, ticker, columns):
    # Use adjusted OHLC consistently across all sessions
    safe_ticker = ticker.replace("^", "").replace("=", "_").replace(".", "_")
    filename_prefix = f"{series_name}_{safe_ticker}_{START_DATE}_"
    cache_path = RAW_DATA_DIR / f"{filename_prefix}{DATA_END_DATE}.csv"

    if cache_path.exists():
        cached = pd.read_csv(cache_path, parse_dates=["date"]).set_index("date")
        validate_yahoo_frame(cached, series_name)
        return cached

    cached_end, base_cache_path = find_latest_month_boundary_cache(
```

```
        filename_prefix
    )
    base_frame = None
    download_start = START_DATE
    if base_cache_path is not None:
        base_frame = pd.read_csv(
            base_cache_path, parse_dates=["date"]
        ).set_index("date")
        validate_yahoo_frame(base_frame, series_name)
        download_start = cached_end.strftime("%Y-%m-%d")

    downloaded = yf.download(
        ticker,
        start=download_start,
        end=DATA_END_DATE,
        interval="1d",
        auto_adjust=True,
        repair=False,
        progress=False,
        threads=False,
        timeout=30,
        multi_level_index=False,
    )
    if downloaded.empty:
        raise RuntimeError(f"Keine Yahoo-Daten für {ticker} erhalten")

    downloaded.index = pd.to_datetime(downloaded.index).tz_localize(None).normalize()
    downloaded.index.name = "date"
    downloaded_frame = downloaded.loc[:, columns].copy()
    downloaded_frame.columns = [
        f"{series_name}_{column.lower().replace(' ', '_')}" for column in columns
    ]
    frame = downloaded_frame
    if base_frame is not None:
        frame = pd.concat([base_frame, downloaded_frame]).sort_index()
        frame = frame[~frame.index.duplicated(keep="last")]

    validate_yahoo_frame(frame, series_name)
    frame.reset_index().to_csv(cache_path, index=False)
    return frame


def load_fear_greed():
    # Keep publication timestamps for a leakage-safe as-of merge
    filename_prefix = f"fear_greed_{START_DATE}_"
    cache_path = RAW_DATA_DIR / f"{filename_prefix}{DATA_END_DATE}.csv"
    if cache_path.exists():
        cached = pd.read_csv(cache_path, parse_dates=["timestamp_utc"])
        cached["timestamp_utc"] = pd.to_datetime(cached["timestamp_utc"], utc=True)
        return cached.sort_values("timestamp_utc")

    response = requests.get(
        "https://api.alternative.me/fng/",
```

```
        params={"limit": 0, "format": "json"},
        headers={"User-Agent": "CSP1 educational time-series project"},
        timeout=30,
    )
    response.raise_for_status()
    payload = response.json()
    assert "data" in payload and payload["data"], "Fear & Greed API ohne Daten"

    downloaded = pd.DataFrame(payload["data"])
    downloaded["timestamp_utc"] = pd.to_datetime(
        downloaded["timestamp"].astype("int64"), unit="s", utc=True
    )
    downloaded["fear_greed"] = pd.to_numeric(
        downloaded["value"], errors="coerce"
    )
    downloaded = downloaded.loc[
        (downloaded["timestamp_utc"] >= pd.Timestamp(START_DATE, tz="UTC"))
        & (downloaded["timestamp_utc"] < pd.Timestamp(DATA_END_DATE, tz="UTC")),
        ["timestamp_utc", "fear_greed"],
    ]

    cached_end, base_cache_path = find_latest_month_boundary_cache(
        filename_prefix
    )
    frame = downloaded
    if base_cache_path is not None:
        base_frame = pd.read_csv(
            base_cache_path, parse_dates=["timestamp_utc"]
        )
        base_frame["timestamp_utc"] = pd.to_datetime(
            base_frame["timestamp_utc"], utc=True
        )
        extension_start = pd.Timestamp(cached_end, tz="UTC")
        frame = pd.concat(
            [
                base_frame,
                downloaded[downloaded["timestamp_utc"] >= extension_start],
            ],
            ignore_index=True,
        )

    frame = frame.sort_values("timestamp_utc")
    frame = frame.drop_duplicates("timestamp_utc", keep="last")
    assert frame["timestamp_utc"].is_unique
    assert frame["fear_greed"].between(0, 100).all()
    frame.to_csv(cache_path, index=False)
    return frame
```

```
# Download or reuse each source in the fixed data range
with warnings.catch_warnings():
    warnings.simplefilter("ignore", category=FutureWarning)
    btc_hourly = load_binance_hourly()
    yahoo_data = {
```

```
        name: load_yahoo_series(name, settings["ticker"], settings["columns"])
        for name, settings in YAHOO_SERIES.items()
    }
    fear_greed = load_fear_greed()

qqq = yahoo_data["qqq"]
vix = yahoo_data["vix"]
dxy = yahoo_data["dxy"]

# Count material BTC gaps without filling them
observed_hour_gaps = btc_hourly.index.to_series().diff() / pd.Timedelta(hours=1)
missing_btc_hours = int(
    np.floor((observed_hour_gaps[observed_hour_gaps > 1.5] - 1).sum())
)

source_summary = pd.DataFrame(
    [
        {
            "Quelle": "Bitcoin (Binance, 1h)",
            "Erste Beobachtung": btc_hourly.index.min(),
            "Letzte Beobachtung": btc_hourly.index.max(),
            "Zeilen": len(btc_hourly),
            "Duplikate": int(btc_hourly.index.duplicated().sum()),
            "Fehlende Werte": int(btc_hourly.isna().sum().sum()),
            "Erwartete Lücken": missing_btc_hours,
        },
        *[
            {
                "Quelle": name.upper(),
                "Erste Beobachtung": frame.index.min(),
                "Letzte Beobachtung": frame.index.max(),
                "Zeilen": len(frame),
                "Duplikate": int(frame.index.duplicated().sum()),
                "Fehlende Werte": int(frame.isna().sum().sum()),
                "Erwartete Lücken": "Wochenenden/Feiertage",
            }
            for name, frame in yahoo_data.items()
        ],
        {
            "Quelle": "Fear & Greed",
            "Erste Beobachtung": fear_greed["timestamp_utc"].min(),
            "Letzte Beobachtung": fear_greed["timestamp_utc"].max(),
            "Zeilen": len(fear_greed),
            "Duplikate": int(fear_greed["timestamp_utc"].duplicated().sum()),
            "Fehlende Werte": int(fear_greed.isna().sum().sum()),
            "Erwartete Lücken": "As-of-Merge",
        },
    ]
)
display(source_summary)
btc_preview = btc_hourly.head(3).copy()
btc_preview_numeric = btc_preview.select_dtypes(include="number").columns
btc_preview[btc_preview_numeric] = btc_preview[btc_preview_numeric].round(2)
```

```
display(btc_preview)
display(qqq.head(3).round(2))
```

	Quelle	Erste Beobachtung	Letzte Beobachtung	Zeilen	Duplikate	Fehlende Werte	Erwartete Lücken
0	Bitcoin (Binance, 1h)	2018-02-01 00:00:00+00:00	2026-08-31 23:00:00+00:00	75096	0	0	120
1	QQQ	2018-02-01 00:00:00	2026-08-31 00:00:00	2156	0	0	Wochenenden/Feiertage
2	VIX	2018-02-01 00:00:00	2026-08-31 00:00:00	2157	0	0	Wochenenden/Feiertage
3	DXY	2018-02-01 00:00:00	2026-08-31 00:00:00	2158	0	0	Wochenenden/Feiertage
4	Fear & Greed	2018-02-01 00:00:00+00:00	2026-08-31 00:00:00+00:00	3130	0	0	As-of-Merge

	close_time	open	high	low	close	volume
open_time						
2018-02-01 00:00:00+00:00	2018-02-01 00:59:59.999000+00:00	10285.10	10335.00	10215.07	10263.18	594.44
2018-02-01 01:00:00+00:00	2018-02-01 01:59:59.999000+00:00	10263.18	10328.98	10216.00	10247.49	591.52
2018-02-01 02:00:00+00:00	2018-02-01 02:59:59.999000+00:00	10249.43	10317.73	10176.89	10199.61	479.41

	qqq_open	qqq_high	qqq_low	qqq_close	qqq_volume
date					
2018-02-01	159.16	160.70	158.51	159.02	38037900
2018-02-02	158.40	158.78	155.72	155.85	68478100
2018-02-05	154.39	156.93	149.59	149.71	105372200

```
# Derive the interpretation from validated source frames
btc_rows_display = f"{len(btc_hourly):,}".replace(",", "'")
qqq_rows_display = f"{len(qqq):,}".replace(",", "'")

display(
    Markdown(
        f'''
### Interpretation

Alle Quellen wurden erfolgreich geladen und bestehen die Prüfungen auf
Chronologie, eindeutige Zeitstempel, fehlende Werte und plausible
Wertebereiche. Wir verfügen über **{btc_rows_display} Bitcoin-Stunden**
und **{qqq_rows_display} QQQ-Handelstage**. Im Bitcoin-Stundenraster
```

```
fehlen **{missing_btc_hours} Zeitstempel**. Solche Lücken werden nicht
interpoliert; ein betroffenes Overnight-Fenster wird später als
unvollständig markiert und entfernt.
        '''
    )
)
```

Interpretation

Alle Quellen wurden erfolgreich geladen und bestehen die Prüfungen auf Chronologie, eindeutige Zeitstempel, fehlende Werte und plausible Wertebereiche. Wir verfügen über **75’096 Bitcoin-Stunden** und **2’156 QQQ-Handelstage**. Im Bitcoin-Stundenraster fehlen **120 Zeitstempel**. Solche Lücken werden nicht interpoliert; ein betroffenes Overnight-Fenster wird später als unvollständig markiert und entfernt.

Quellen und methodische Grundlagen

- Binance Public Data für stündliche `BTCUSDT`-OHLCV-Daten.
- Yahoo Finance über yfinance für QQQ, VIX und DXY.
- Alternative.me Fear & Greed API.
- exchange_calendars für Nasdaq-Sitzungen, Feiertage und verkürzte Handelstage.
- Hyndman und Athanasopoulos, Forecasting: Principles and Practice.
- Marco Peixeiro: Statistical forecasting baseline notebook.
- Chen und Guestrin (2016), XGBoost.
- Chronos-2 Technical Report und offizielles Chronos-Repository.
- MachineLearningMastery: 2026 Time Series Toolkit als ergänzender Überblick.

Die Marktdaten verwenden wir ausschliesslich für Ausbildung und Forschung unter den jeweiligen Nutzungsbedingungen.

4. Nasdaq-Sitzungen und QQQ-Ziel konstruieren

Erklärung

Eine Zeile verbindet zwei aufeinanderfolgende QQQ-Handelstage. Für den Zieltages (t) verwenden wir den Schlusskurs der vorherigen regulären Sitzung (t-1) und den offiziellen QQQ-Open von (t).

Der Börsenkalender liefert die tatsächlichen UTC-Zeitpunkte für Sitzungsschluss und -eröffnung. Damit werden Feiertage und verkürzte Sitzungen korrekt behandelt. QQQ-Historienmerkmale werden auf der vorherigen abgeschlossenen Sitzung gemessen. Gap-Lags werden zusätzlich um eine Beobachtung verschoben, sodass der aktuelle Ziel-Gap niemals in seinen eigenen Features vorkommt.

```
# Build the official Nasdaq schedule for all QQQ dates
nasdaq_calendar = xcals.get_calendar("XNAS")
schedule = nasdaq_calendar.schedule.loc[
    pd.Timestamp(START_DATE): pd.Timestamp(DATA_END_DATE) - pd.Timedelta(days=1),
    ["open", "close"],
].copy()
```

```
schedule.index = pd.to_datetime(schedule.index).tz_localize(None).normalize()

missing_schedule_dates = qqq.index.difference(schedule.index)
assert missing_schedule_dates.empty, (
    f"QQQ-Tage ohne Nasdaq-Kalender: {missing_schedule_dates.tolist()}"
)

# Calculate QQQ history only from completed sessions
qqq_history = qqq.copy()
qqq_history["qqq_return_1d"] = np.log(
    qqq_history["qqq_close"] / qqq_history["qqq_close"].shift(1)
)
qqq_history["qqq_momentum_5d"] = np.log(
    qqq_history["qqq_close"] / qqq_history["qqq_close"].shift(5)
)
qqq_history["qqq_volatility_20d"] = (
    qqq_history["qqq_return_1d"].rolling(20).std() * np.sqrt(252)
)

weekday_names = {
    0: "Montag",
    1: "Dienstag",
    2: "Mittwoch",
    3: "Donnerstag",
    4: "Freitag",
}

target_rows = []
for position in range(1, len(qqq_history)):
    # Pair every target session with the previous observed QQQ session
    previous_date = qqq_history.index[position - 1]
    target_date = qqq_history.index[position]
    previous_row = qqq_history.iloc[position - 1]
    target_row = qqq_history.iloc[position]

    previous_close_utc = schedule.loc[previous_date, "close"]
    target_open_utc = schedule.loc[target_date, "open"]
    forecast_cutoff_local = (
        pd.Timestamp(target_date).tz_localize(FORECAST_TIMEZONE)
        + pd.Timedelta(hours=FORECAST_HOUR)
    )
    forecast_cutoff_utc = forecast_cutoff_local.tz_convert("UTC")
    gap_log_return = np.log(target_row["qqq_open"] / previous_row["qqq_close"])

    target_rows.append(
        {
            "previous_session_date": previous_date,
            "target_session_date": target_date,
            "previous_close_utc": previous_close_utc,
            "forecast_cutoff_utc": forecast_cutoff_utc,
            "target_open_utc": target_open_utc,
            "overnight_hours": (
                forecast_cutoff_utc - previous_close_utc
```

```
            ) / pd.Timedelta(hours=1),
            "target_weekday": weekday_names[target_date.dayofweek],
            "target_is_monday": int(target_date.dayofweek == 0),
            "qqq_previous_close": previous_row["qqq_close"],
            "qqq_target_open": target_row["qqq_open"],
            "qqq_gap_log_return": gap_log_return,
            "qqq_gap_percent": 100 * np.expm1(gap_log_return),
            "qqq_gap_direction": int(gap_log_return > 0),
            "qqq_return_1d": previous_row["qqq_return_1d"],
            "qqq_momentum_5d": previous_row["qqq_momentum_5d"],
            "qqq_volatility_20d": previous_row["qqq_volatility_20d"],
        }
    )

target_table = pd.DataFrame(target_rows)

# Shift target history so only previously observed gaps become features
target_table["qqq_gap_lag_1"] = target_table["qqq_gap_log_return"].shift(1)
target_table["qqq_gap_mean_5"] = (
    target_table["qqq_gap_log_return"].shift(1).rolling(5).mean()
)

# Enforce the timing contract before adding Bitcoin
assert target_table["target_session_date"].is_monotonic_increasing
assert target_table["target_session_date"].is_unique
assert (
    target_table["previous_session_date"] < target_table["target_session_date"]
).all()
assert (
    target_table["previous_close_utc"] < target_table["forecast_cutoff_utc"]
).all()
assert (
    target_table["forecast_cutoff_utc"] < target_table["target_open_utc"]
).all()
assert (
    target_table["target_open_utc"] - target_table["forecast_cutoff_utc"]
    == pd.Timedelta(minutes=30)
).all()

target_preview = target_table[
    [
        "previous_session_date",
        "target_session_date",
        "previous_close_utc",
        "forecast_cutoff_utc",
        "overnight_hours",
        "qqq_gap_percent",
        "qqq_gap_direction",
    ]
].head(6)
target_preview_numeric = target_preview.select_dtypes(include="number").columns
target_preview[target_preview_numeric] = target_preview[
    target_preview_numeric
```

```
].round(4)
display(target_preview)

session_summary = pd.DataFrame(
    {
        "Kennzahl": [
            "QQQ-Zieltage",
            "Kürzestes Informationsfenster (Stunden)",
            "Längstes Informationsfenster (Stunden)",
            "Verkürzte vorherige Sitzungen",
        ],
        "Wert": [
            len(target_table),
            target_table["overnight_hours"].min(),
            target_table["overnight_hours"].max(),
            int(
                (
                    (schedule["close"] - schedule["open"])
                    < pd.Timedelta(hours=6, minutes=30)
                ).sum()
            ),
        ],
    }
)
display(session_summary)
```

	previous_session_date	target_session_date	previous_close_utc	forecast_cutoff_utc	overnight_hours	q
0	2018-02-01	2018-02-02	2018-02-01 21:00:00+00:00	2018-02-02 14:00:00+00:00	17.0	-(
1	2018-02-02	2018-02-05	2018-02-02 21:00:00+00:00	2018-02-05 14:00:00+00:00	65.0	-(
2	2018-02-05	2018-02-06	2018-02-05 21:00:00+00:00	2018-02-06 14:00:00+00:00	17.0	-1
3	2018-02-06	2018-02-07	2018-02-06 21:00:00+00:00	2018-02-07 14:00:00+00:00	17.0	-(
4	2018-02-07	2018-02-08	2018-02-07 21:00:00+00:00	2018-02-08 14:00:00+00:00	17.0	0.
5	2018-02-08	2018-02-09	2018-02-08 21:00:00+00:00	2018-02-09 14:00:00+00:00	17.0	1.

	Kennzahl	Wert
0	QQQ-Zieltage	2155.0
1	Kürzestes Informationsfenster (Stunden)	17.0
2	Längstes Informationsfenster (Stunden)	92.0
3	Verkürzte vorherige Sitzungen	18.0

```
# Explain the target construction from the validated table
regular_overnights = int((target_table["overnight_hours"] == 17).sum())
longer_overnights = int((target_table["overnight_hours"] > 17).sum())

display(
    Markdown(
        f'''
### Interpretation

Aus den QQQ-Tagesdaten entstehen **{len(target_table)} chronologische
Zielbeobachtungen**. Davon besitzen **{regular_overnights}** das normale
17-Stunden-Fenster vom regulären Schluss um 16:00 Uhr bis zum Cutoff um
09:00 Uhr. **{longer_overnights}** Fenster sind wegen Wochenenden,
Feiertagen oder verkürzten Sitzungen länger. Der Kalender bildet diese
Unterschiede explizit ab; es werden keine Handelstage künstlich
ergänzt.
        '''
    )
)
```

Interpretation

Aus den QQQ-Tagesdaten entstehen **2155 chronologische Zielbeobachtungen**. Davon besitzen **1683** das normale 17-Stunden-Fenster vom regulären Schluss um 16:00 Uhr bis zum Cutoff um 09:00 Uhr. **472** Fenster sind wegen Wochenenden, Feiertagen oder verkürzten Sitzungen länger. Der Kalender bildet diese Unterschiede explizit ab; es werden keine Handelstage künstlich ergänzt.

5. Bitcoin-Overnight-Merkmale konstruieren

Erklärung

Für jede Zielbeobachtung aggregieren wir Bitcoin vom tatsächlichen Schluss der vorherigen regulären Nasdaq-Sitzung bis 09:00 Uhr am Zieltag. Nur vollständig abgeschlossene Stundenkerzen sind erlaubt.

Die Bitcoin-Rendite lautet:

$$r_t^{BTC} = \log\left(\frac{P_{cutoff,t}^{BTC}}{P_{close,t-1}^{BTC}}\right).$$

Da normale Nächte, Wochenenden und Feiertage unterschiedlich lang sind, messen wir die Volatilitätsintensität als Wurzel des mittleren quadrierten Stundenreturns:

$$RV_t^{BTC} = \sqrt{\frac{1}{H_t}\sum_{h=1}^{H_t}(r_{t,h}^{BTC})^2}.$$

Das Volumen wird ebenfalls pro Stunde normiert. Return, Range und Drawdown dürfen dagegen die gesamte Informationsperiode abbilden, weil auch der QQQ-Gap über dieselbe unterschiedlich lange

Periode entsteht.

```
def aggregate_bitcoin_overnight(previous_close_utc, forecast_cutoff_utc):
    # Select only candles fully contained in the information window
    window = btc_hourly.loc[
        (btc_hourly.index >= previous_close_utc)
        & (btc_hourly["close_time"] <= forecast_cutoff_utc)
    ]
    expected_hours_float = (
        forecast_cutoff_utc - previous_close_utc
    ) / pd.Timedelta(hours=1)
    assert float(expected_hours_float).is_integer()
    expected_hours = int(expected_hours_float)

    if window.empty:
        return {
            "btc_hour_count": 0,
            "btc_expected_hours": expected_hours,
            "btc_window_complete": False,
        }

    # Include the first candle open and every completed candle close
    price_path = np.concatenate(
        [[window.iloc[0]["open"]], window["close"].to_numpy()]
    )
    hourly_log_returns = np.diff(np.log(price_path))
    running_max = np.maximum.accumulate(price_path)
    drawdowns = price_path / running_max - 1
    first_start_delay = window.index.min() - previous_close_utc
    final_end_delay = forecast_cutoff_utc - window["close_time"].max()
    internal_gaps = window.index.to_series().diff().dropna()
    largest_internal_gap = (
        internal_gaps.max() if not internal_gaps.empty else pd.Timedelta(0)
    )
    candle_durations = window["close_time"] - window.index
    boundary_tolerance = pd.Timedelta(seconds=1)

    # Reject each missing or malformed hour instead of smoothing it
    window_complete = (
        len(window) == expected_hours
        and first_start_delay <= boundary_tolerance
        and final_end_delay <= boundary_tolerance
        and largest_internal_gap
        <= pd.Timedelta(hours=1) + boundary_tolerance
        and candle_durations.between(
            pd.Timedelta(minutes=59),
            pd.Timedelta(hours=1) + boundary_tolerance,
        ).all()
    )

    return {
        "btc_hour_count": len(window),
        "btc_expected_hours": expected_hours,
```

```
        "btc_window_complete": window_complete,
        "btc_overnight_return": np.log(price_path[-1] / price_path[0]),
        "btc_overnight_rv_intensity": np.sqrt(
            np.square(hourly_log_returns).mean()
        ),
        "btc_overnight_range": np.log(
            window["high"].max() / window["low"].min()
        ),
        "btc_overnight_log_volume_per_hour": np.log1p(
            window["volume"].sum() / len(window)
        ),
        "btc_overnight_max_drawdown": drawdowns.min(),
    }


# Aggregate one independent BTC window for each QQQ target session
bitcoin_features = pd.DataFrame(
    [
        aggregate_bitcoin_overnight(
            row.previous_close_utc, row.forecast_cutoff_utc
        )
        for row in target_table.itertuples(index=False)
    ]
)
target_table = pd.concat(
    [target_table.reset_index(drop=True), bitcoin_features], axis=1
)

bitcoin_window_summary = (
    target_table.groupby(
        ["btc_expected_hours", "btc_window_complete"], dropna=False
    )
    .size()
    .rename("Beobachtungen")
    .reset_index()
    .sort_values(["btc_expected_hours", "btc_window_complete"])
    .rename(
        columns={
            "btc_expected_hours": "Erwartete Stunden",
            "btc_window_complete": "Fenster vollständig",
        }
    )
)
display(bitcoin_window_summary.head(15))

bitcoin_preview = target_table[
    [
        "previous_session_date",
        "target_session_date",
        "btc_hour_count",
        "btc_overnight_return",
        "btc_overnight_rv_intensity",
        "btc_overnight_range",
```

```
        "btc_overnight_max_drawdown",
    ]
].head(6)
bitcoin_preview_numeric = bitcoin_preview.select_dtypes(include="number").columns
bitcoin_preview[bitcoin_preview_numeric] = bitcoin_preview[
    bitcoin_preview_numeric
].round(5)
display(bitcoin_preview)
```

	Erwartete Stunden	Fenster vollständig	Beobachtungen
0	17	False	16
1	17	True	1667
2	41	True	16
3	44	False	1
4	44	True	7
5	64	True	9
6	65	False	8
7	65	True	357
8	66	True	8
9	68	False	1
10	68	True	7
11	89	True	56
12	92	False	1
13	92	True	1

	previous_session_date	target_session_date	btc_hour_count	btc_overnight_return	btc_overnight_rv_int
0	2018-02-01	2018-02-02	17	-0.05712	0.02219
1	2018-02-02	2018-02-05	65	-0.12605	0.01602
2	2018-02-05	2018-02-06	17	-0.00308	0.04097
3	2018-02-06	2018-02-07	17	0.09175	0.02217
4	2018-02-07	2018-02-08	4	-0.04311	0.02547
5	2018-02-08	2018-02-09	4	0.05970	0.02617

```
# Report completeness before any rows are removed
incomplete_windows = int((~target_table["btc_window_complete"]).sum())
complete_share = target_table["btc_window_complete"].mean()
window_lengths = sorted(
    target_table["btc_expected_hours"].dropna().unique().astype(int).tolist()
)

display(
    Markdown(
        f'''
```

```
### Interpretation

Die Aggregation findet **{len(window_lengths)} unterschiedliche
Fensterlängen** zwischen **{min(window_lengths)} und
{max(window_lengths)} Stunden**. Diese Variation entsteht durch
Wochentage, Wochenenden, Feiertage, verkürzte Sitzungen und
Zeitumstellungen. **{incomplete_windows} Fenster** sind unvollständig;
insgesamt sind **{complete_share:.1%}** der Fenster vollständig.
Unvollständige Beobachtungen werden vor der Modellierung entfernt und
nicht interpoliert.
        '''
    )
)
```

Interpretation

Die Aggregation findet **9 unterschiedliche Fensterlängen** zwischen **17 und 92 Stunden**. Diese Variation entsteht durch Wochentage, Wochenenden, Feiertage, verkürzte Sitzungen und Zeitumstellungen. **27 Fenster** sind unvollständig; insgesamt sind **98.7%** der Fenster vollständig. Unvollständige Beobachtungen werden vor der Modellierung entfernt und nicht interpoliert.

6. Sentiment, Makro und Modellierungstabelle

Erklärung

QQQ-, VIX- und DXY-Merkmale werden auf der vorherigen abgeschlossenen regulären Sitzung gemessen. Fear & Greed wird per As-of-Merge mit dem letzten Zeitstempel verknüpft, der nicht nach dem Cutoff um 09:00 Uhr liegt.

Wir definieren bereits jetzt zwei feste Feature-Sets. Damit verhindern wir, dass die spätere Modellierung Features nach dem Ergebnis auswählt.

1. **Kontrolle:** QQQ-Historie, Sentiment, VIX, DXY, Montag-Indikator und Fensterlänge.
2. **Mit Bitcoin:** Kontrollvariablen plus Return, Volatilitätsintensität, Range, Volumenintensität und Drawdown von BTC.

```
# Build backward-looking VIX and DXY features
vix_features = vix.copy()
vix_features["vix_change_5d"] = np.log(
    vix_features["vix_close"] / vix_features["vix_close"].shift(5)
)
dxy_features = dxy.copy()
dxy_features["dxy_return_1d"] = np.log(
    dxy_features["dxy_close"] / dxy_features["dxy_close"].shift(1)
)
dxy_features["dxy_change_5d"] = np.log(
    dxy_features["dxy_close"] / dxy_features["dxy_close"].shift(5)
)
```

```
# Join market information by the previous completed QQQ session
target_table = target_table.merge(
    vix_features[["vix_close", "vix_change_5d"]],
    left_on="previous_session_date",
    right_index=True,
    how="left",
    validate="many_to_one",
)
target_table = target_table.merge(
    dxy_features[["dxy_return_1d", "dxy_change_5d"]],
    left_on="previous_session_date",
    right_index=True,
    how="left",
    validate="many_to_one",
)

# Normalize datetime precision before the as-of merge
target_table["forecast_cutoff_utc"] = pd.to_datetime(
    target_table["forecast_cutoff_utc"], utc=True
).astype("datetime64[ns, UTC]")
fear_greed["timestamp_utc"] = pd.to_datetime(
    fear_greed["timestamp_utc"], utc=True
).astype("datetime64[ns, UTC]")

# Match the latest sentiment observation known before each cutoff
target_table = pd.merge_asof(
    target_table.sort_values("forecast_cutoff_utc"),
    fear_greed.sort_values("timestamp_utc"),
    left_on="forecast_cutoff_utc",
    right_on="timestamp_utc",
    direction="backward",
    allow_exact_matches=True,
).sort_values("target_session_date")
target_table["fear_greed_age_hours"] = (
    target_table["forecast_cutoff_utc"] - target_table["timestamp_utc"]
).dt.total_seconds() / 3600

CONTROL_FEATURES = [
    "qqq_gap_lag_1",
    "qqq_gap_mean_5",
    "qqq_return_1d",
    "qqq_momentum_5d",
    "qqq_volatility_20d",
    "fear_greed",
    "vix_close",
    "vix_change_5d",
    "dxy_return_1d",
    "dxy_change_5d",
    "target_is_monday",
    "overnight_hours",
]
BITCOIN_FEATURES = [
    "btc_overnight_return",
```

```
    "btc_overnight_rv_intensity",
    "btc_overnight_range",
    "btc_overnight_log_volume_per_hour",
    "btc_overnight_max_drawdown",
]
FULL_FEATURES = [*CONTROL_FEATURES, *BITCOIN_FEATURES]
CLASSIFICATION_TARGET = "qqq_gap_direction"
NUMERIC_TARGET = "qqq_gap_log_return"

# Remove only rows that cannot be modeled safely
required_columns = [CLASSIFICATION_TARGET, NUMERIC_TARGET, *FULL_FEATURES]
complete_mask = (
    target_table["btc_window_complete"]
    & target_table[required_columns].notna().all(axis=1)
    & np.isfinite(target_table[required_columns]).all(axis=1)
)
modeling_data = target_table.loc[complete_mask].copy()
modeling_data = modeling_data.sort_values("target_session_date").reset_index(
    drop=True
)

# Enforce chronology and leakage contracts
assert modeling_data["target_session_date"].is_monotonic_increasing
assert modeling_data["target_session_date"].is_unique
assert (
    modeling_data["previous_session_date"]
    < modeling_data["target_session_date"]
).all()
assert (
    modeling_data["previous_close_utc"]
    < modeling_data["forecast_cutoff_utc"]
).all()
assert (
    modeling_data["forecast_cutoff_utc"]
    < modeling_data["target_open_utc"]
).all()
assert (
    modeling_data["timestamp_utc"] <= modeling_data["forecast_cutoff_utc"]
).all()
assert modeling_data[required_columns].notna().all().all()

# Save one transparent row per QQQ target session
processed_path = PROCESSED_DATA_DIR / "btc_overnight_qqq_modeling_table.csv"
modeling_data.to_csv(processed_path, index=False)

split_summary = pd.DataFrame(
    {
        "Teil": ["Entwicklung", "Finaler Holdout"],
        "Von": [
            modeling_data.loc[
                modeling_data["target_session_date"] < HOLDOUT_START,
                "target_session_date",
            ].min(),
```

```
            modeling_data.loc[
                modeling_data["target_session_date"] >= HOLDOUT_START,
                "target_session_date",
            ].min(),
        ],
        "Bis": [
            modeling_data.loc[
                modeling_data["target_session_date"] < HOLDOUT_START,
                "target_session_date",
            ].max(),
            modeling_data.loc[
                modeling_data["target_session_date"] >= HOLDOUT_START,
                "target_session_date",
            ].max(),
        ],
        "Beobachtungen": [
            int((modeling_data["target_session_date"] < HOLDOUT_START).sum()),
            int((modeling_data["target_session_date"] >= HOLDOUT_START).sum()),
        ],
    }
)
display(split_summary)

year_summary = (
    modeling_data.assign(
        Jahr=modeling_data["target_session_date"].dt.year,
        Teil=np.where(
            modeling_data["target_session_date"] < HOLDOUT_START,
            "Entwicklung",
            "Holdout",
        ),
    )
    .groupby(["Jahr", "Teil"], observed=False)
    .size()
    .rename("Beobachtungen")
    .reset_index()
)
display(year_summary)

modeling_preview = modeling_data[
    [
        "previous_session_date",
        "target_session_date",
        "forecast_cutoff_utc",
        "qqq_gap_percent",
        CLASSIFICATION_TARGET,
        *FULL_FEATURES,
    ]
].head(6)
modeling_preview_numeric = modeling_preview.select_dtypes(include="number").columns
modeling_preview[modeling_preview_numeric] = modeling_preview[
    modeling_preview_numeric
```

```
].round(4)
display(modeling_preview)
```

	Teil	Von	Bis	Beobachtungen
0	Entwicklung	2018-03-05	2025-12-31	1945
1	Finaler Holdout	2026-01-02	2026-08-31	166

	Jahr	Teil	Beobachtungen
0	2018	Entwicklung	205
1	2019	Entwicklung	246
2	2020	Entwicklung	246
3	2021	Entwicklung	246
4	2022	Entwicklung	251
5	2023	Entwicklung	249
6	2024	Entwicklung	252
7	2025	Entwicklung	250
8	2026	Holdout	166

	previous_session_date	target_session_date	forecast_cutoff_utc	qqq_gap_percent	qqq_gap_direction	c
0	2018-03-02	2018-03-05	2018-03-05 14:00:00+00:00	-0.4699	0	-
1	2018-03-05	2018-03-06	2018-03-06 14:00:00+00:00	0.4886	1	-
2	2018-03-06	2018-03-07	2018-03-07 14:00:00+00:00	-0.7654	0	(
3	2018-03-07	2018-03-08	2018-03-08 14:00:00+00:00	0.4144	1	-
4	2018-03-08	2018-03-09	2018-03-09 14:00:00+00:00	0.7124	1	(
5	2018-03-09	2018-03-12	2018-03-12 13:00:00+00:00	0.2945	1	(

6 rows × 22 columns

```
# Summarize the final handoff without inspecting holdout outcomes
removed_rows = len(target_table) - len(modeling_data)
max_sentiment_age = modeling_data["fear_greed_age_hours"].max()
development_rows = int(
    (modeling_data["target_session_date"] < HOLDOUT_START).sum()
)
holdout_rows = int(
    (modeling_data["target_session_date"] >= HOLDOUT_START).sum()
)
validation_rows = int(
```

```
    modeling_data["target_session_date"].dt.year.isin(VALIDATION_YEARS).sum()
)

display(
    Markdown(
        f'''
### Interpretation

Die finale Modellierungstabelle enthält **{len(modeling_data)}
Tagesbeobachtungen**: **{development_rows}** für Entwicklung und
Walk-forward-Validierung sowie **{holdout_rows}** im unberührten
Holdout. Die fünf späteren Validierungsjahre 2021 bis 2025 umfassen
zusammen **{validation_rows} Out-of-sample-Termine**. Wir entfernen
**{removed_rows} Zeilen** wegen unvollständiger
BTC-Fenster oder noch nicht verfügbarer Rolling Features. Der
zugeordnete Fear-&-Greed-Wert ist höchstens
**{max_sentiment_age:.1f} Stunden** älter als der Prognose-Cutoff. Die
Zeitprüfungen bestätigen, dass der QQQ-Open des Zieltags in keinem
Feature enthalten ist.
        '''
    )
)
```

Interpretation

Die finale Modellierungstabelle enthält **2111 Tagesbeobachtungen**: **1945** für Entwicklung und Walk-forward-Validierung sowie **166** im unberührten Holdout. Die fünf späteren Validierungsjahre 2021 bis 2025 umfassen zusammen **1248 Out-of-sample-Termine**. Wir entfernen **44 Zeilen** wegen unvollständiger BTC-Fenster oder noch nicht verfügbarer Rolling Features. Der zugeordnete Fear-&-Greed-Wert ist höchstens **85.0 Stunden** älter als der Prognose-Cutoff. Die Zeitprüfungen bestätigen, dass der QQQ-Open des Zieltags in keinem Feature enthalten ist.

7. Explorative Datenanalyse

Erklärung

Die EDA verwendet ausschliesslich Beobachtungen vor 2026. Wir untersuchen Zielverteilung, Klassenbalance, Fensterlängen und die deskriptive Beziehung zwischen BTC-Overnight-Aktivität und dem QQQ-Eröffnungsgap. Der Holdout bleibt vollständig ausgeschlossen.

Diese Ergebnisse zeigen Strukturen im Entwicklungszeitraum, aber noch keine Out-of-sample-Prognosekraft. Darüber entscheidet erst die spätere Expanding-window-Validierung.

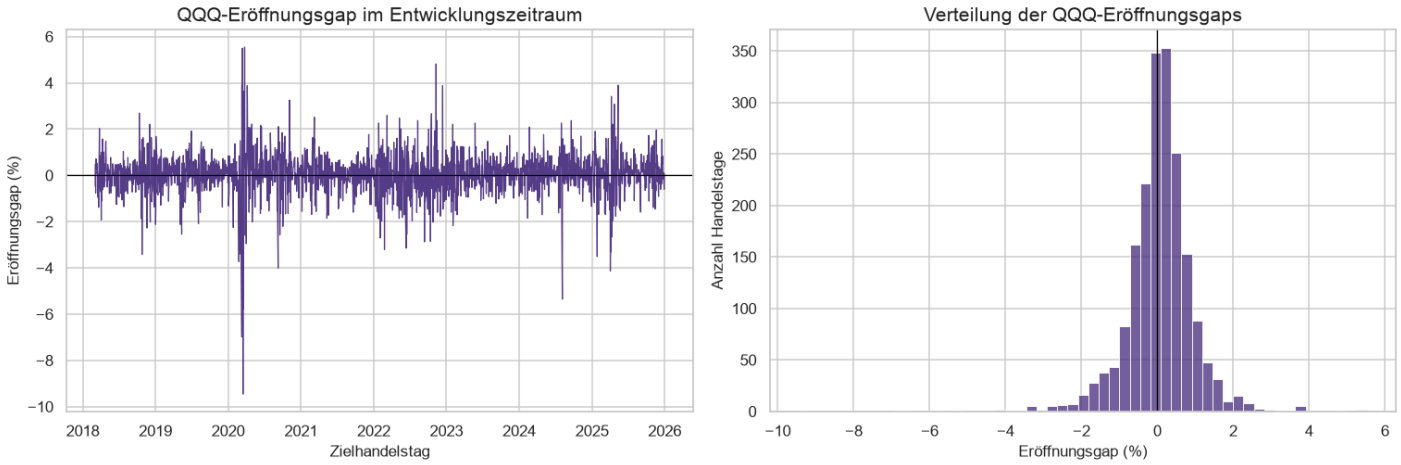
```
# Restrict every exploratory result to the development period
development_data = modeling_data[
    modeling_data["target_session_date"] < HOLDOUT_START
].copy()
assert development_data["target_session_date"].max() < HOLDOUT_START
```

```
fig, axes = plt.subplots(1, 2, figsize=(14, 4.8))

axes[0].plot(
    development_data["target_session_date"],
    development_data["qqq_gap_percent"],
    color=COLORS["qqq"],
    linewidth=0.8,
    alpha=0.9,
)
axes[0].axhline(0, color="black", linewidth=0.8)
axes[0].set_title("QQQ-Eröffnungsgap im Entwicklungszeitraum")
axes[0].set_xlabel("Zielhandelstag")
axes[0].set_ylabel("Eröffnungsgap (%)")

sns.histplot(
    data=development_data,
    x="qqq_gap_percent",
    bins=55,
    color=COLORS["qqq"],
    ax=axes[1],
)
axes[1].axvline(0, color="black", linewidth=0.8)
axes[1].set_title("Verteilung der QQQ-Eröffnungsgaps")
axes[1].set_xlabel("Eröffnungsgap (%)")
axes[1].set_ylabel("Anzahl Handelstage")

fig.tight_layout()
plt.show()
```




```
# Quantify target location, tails and class balance
mean_gap = development_data["qqq_gap_percent"].mean()
median_gap = development_data["qqq_gap_percent"].median()
positive_share = development_data[CLASSIFICATION_TARGET].mean()
absolute_gap_95 = development_data["qqq_gap_percent"].abs().quantile(0.95)

display(
    Markdown(
        f'''
```

```
### Interpretation

Der mittlere QQQ-Eröffnungsgap beträgt **{mean_gap:.3f}%**, der Median
**{median_gap:.3f}%**. In **{positive_share:.1%}** der
Entwicklungsbeobachtungen eröffnet QQQ höher als am vorherigen
Schluss. 95% der absoluten Gaps liegen unter **{absolute_gap_95:.2f}%**.
Einzelne starke Ausschläge und die Klassenverteilung müssen bei der
späteren Bewertung berücksichtigt werden; Accuracy wird deshalb gegen
eine historische Mehrheitsbaseline und zusätzlich mit Balanced
Accuracy beurteilt.
        '''
    )
)
```

Interpretation

Der mittlere QQQ-Eröffnungsgap beträgt **0.049%**, der Median **0.089%**. In **56.5%** der Entwicklungsbeobachtungen eröffnet QQQ höher als am vorherigen Schluss. 95% der absoluten Gaps liegen unter **1.77%**. Einzelne starke Ausschläge und die Klassenverteilung müssen bei der späteren Bewertung berücksichtigt werden; Accuracy wird deshalb gegen eine historische Mehrheitsbaseline und zusätzlich mit Balanced Accuracy beurteilt.

7.1 Richtung und Fensterlänge nach Wochentag

Wir prüfen, ob die positive Gap-Rate und die Dauer des Informationsfensters systematisch mit dem Ziel-Wochentag variieren. Montage enthalten in der Regel das gesamte Wochenende; Feiertage und verkürzte Sitzungen können zusätzliche längere Fenster erzeugen.

```
weekday_order = ["Montag", "Dienstag", "Mittwoch", "Donnerstag", "Freitag"]
weekday_summary = (
    development_data.groupby("target_weekday", observed=False)
    .agg(
        Beobachtungen=(CLASSIFICATION_TARGET, "size"),
        Positive_Rate=(CLASSIFICATION_TARGET, "mean"),
        Median_Fensterstunden=("overnight_hours", "median"),
        Max_Fensterstunden=("overnight_hours", "max"),
    )
    .reindex(weekday_order)
)
display(weekday_summary.round(3))

fig, axes = plt.subplots(1, 2, figsize=(14, 4.8))
viridis_weekdays = [VIRIDIS(value) for value in np.linspace(0.15, 0.85, 5)]

axes[0].bar(
    weekday_summary.index,
    100 * weekday_summary["Positive_Rate"],
    color=viridis_weekdays,
)
axes[0].axhline(
```

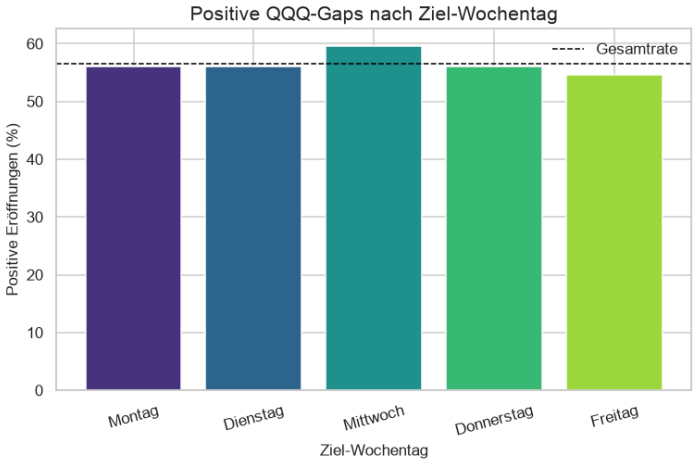
```
    100 * positive_share,
    color="black",
    linewidth=1,
    linestyle="--",
    label="Gesamtrate",
)
axes[0].set_title("Positive QQQ-Gaps nach Ziel-Wochentag")
axes[0].set_xlabel("Ziel-Wochentag")
axes[0].set_ylabel("Positive Eröffnungen (%)")
axes[0].legend()

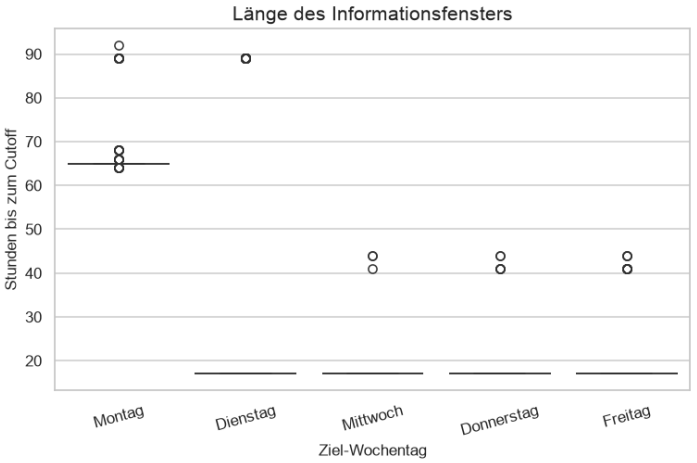
sns.boxplot(
    data=development_data,
    x="target_weekday",
    y="overnight_hours",
    order=weekday_order,
    hue="target_weekday",
    palette="viridis",
    legend=False,
    ax=axes[1],
)
axes[1].set_title("Länge des Informationsfensters")
axes[1].set_xlabel("Ziel-Wochentag")
axes[1].set_ylabel("Stunden bis zum Cutoff")

for axis in axes:
    axis.tick_params(axis="x", rotation=15)

fig.tight_layout()
plt.show()
```

	Beobachtungen	Positive_Rate	Median_Fensterstunden	Max_Fensterstunden
target_weekday				
Montag	362	0.561	65.0	92.0
Dienstag	403	0.561	17.0	89.0
Mittwoch	396	0.596	17.0	44.0
Donnerstag	392	0.561	17.0	44.0
Freitag	392	0.546	17.0	44.0






```
# Describe observed weekday differences without causal interpretation
highest_weekday = weekday_summary["Positive_Rate"].idxmax()
lowest_weekday = weekday_summary["Positive_Rate"].idxmin()
monday_median_hours = weekday_summary.loc["Montag", "Median_Fensterstunden"]
weekday_median_hours = weekday_summary.loc[
    ["Dienstag", "Mittwoch", "Donnerstag", "Freitag"],
    "Median_Fensterstunden",
].median()

display(
    Markdown(
        f'''
### Interpretation

Die höchste positive Gap-Rate zeigt **{highest_weekday}**, die tiefste
**{lowest_weekday}**. Das mediane Montagsfenster umfasst
**{monday_median_hours:.0f} Stunden**, gegenüber
**{weekday_median_hours:.0f} Stunden** an den übrigen Handelstagen.
Diese Kalenderunterschiede rechtfertigen den Montag-Indikator und die
Fensterlänge im Kontrollmodell. Sie sind keine Evidenz für einen
Bitcoin-Effekt.
        '''
    )
)
```

Interpretation

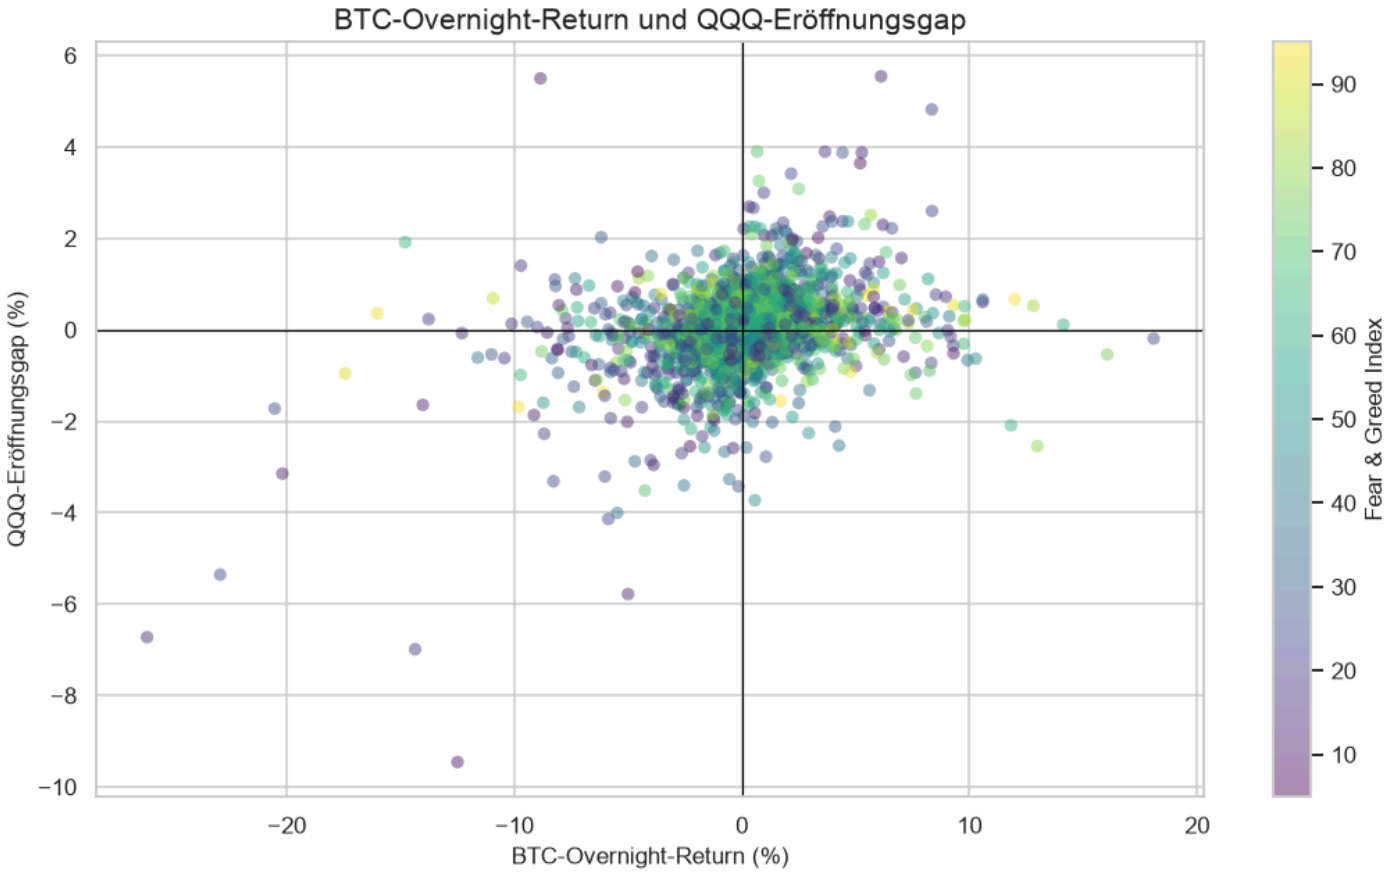
Die höchste positive Gap-Rate zeigt **Mittwoch**, die tiefste **Freitag**. Das mediane Montagsfenster umfasst **65 Stunden**, gegenüber **17 Stunden** an den übrigen Handelstagen. Diese Kalenderunterschiede rechtfertigen den Montag-Indikator und die Fensterlänge im Kontrollmodell. Sie sind keine Evidenz für einen Bitcoin-Effekt.

7.2 BTC-Overnight-Return und QQQ-Gap

Der Scatterplot zeigt den direkten linearen Zusammenhang. Fear & Greed dient als Farbdimension, um mögliche Sentimentregime sichtbar zu machen. Danach vergleichen wir alle Tage, Montage und die

übrigen Handelstage getrennt.

```
# Plot the direct relationship without fitting a predictive model
plt.figure(figsize=(10, 6))
scatter = plt.scatter(
    100 * development_data["btc_overnight_return"],
    development_data["qqq_gap_percent"],
    c=development_data["fear_greed"],
    cmap="viridis",
    alpha=0.45,
    edgecolor="none",
)
plt.axhline(0, color="black", linewidth=0.8)
plt.axvline(0, color="black", linewidth=0.8)
plt.title("BTC-Overnight-Return und QQQ-Eröffnungsgap")
plt.xlabel("BTC-Overnight-Return (%)")
plt.ylabel("QQQ-Eröffnungsgap (%)")
colorbar = plt.colorbar(scatter)
colorbar.set_label("Fear & Greed Index")
plt.tight_layout()
plt.show()
```




```
# Compare correlations overall and by the main calendar regime
monday_data = development_data[development_data["target_is_monday"] == 1]
other_days_data = development_data[development_data["target_is_monday"] == 0]

def target_correlation(frame):
```

```
    # Return the linear BTC-return relationship for one subset
    return frame[["btc_overnight_return", NUMERIC_TARGET]].corr().iloc[0, 1]


correlation_by_period = pd.DataFrame(
    {
        "Teilmenge": ["Alle Handelstage", "Montage", "Dienstag bis Freitag"],
        "Beobachtungen": [
            len(development_data),
            len(monday_data),
            len(other_days_data),
        ],
        "Korrelation": [
            target_correlation(development_data),
            target_correlation(monday_data),
            target_correlation(other_days_data),
        ],
    }
)
display(correlation_by_period.round(3))

overall_correlation = correlation_by_period.loc[0, "Korrelation"]
monday_correlation = correlation_by_period.loc[1, "Korrelation"]
other_days_correlation = correlation_by_period.loc[2, "Korrelation"]

display(
    Markdown(
        f'''
### Interpretation

Im gesamten Entwicklungszeitraum beträgt die lineare Korrelation
zwischen BTC-Overnight-Return und numerischem QQQ-Gap
**{overall_correlation:.3f}**. Für Montage liegt sie bei
**{monday_correlation:.3f}**, für Dienstag bis Freitag bei
**{other_days_correlation:.3f}**. Die grössere Stichprobe erlaubt damit
eine getrennte Beschreibung längerer und normaler Fenster. Ob die
Beziehung gegenüber Kontrollmerkmalen stabilen Zusatznutzen besitzt,
muss die spätere Walk-forward-Validierung zeigen.
        '''
    )
)
```

	Teilmenge	Beobachtungen	Korrelation
0	Alle Handelstage	1945	0.316
1	Montage	362	0.345
2	Dienstag bis Freitag	1583	0.306

Interpretation

Im gesamten Entwicklungszeitraum beträgt die lineare Korrelation zwischen BTC-Overnight-Return und numerischem QQQ-Gap **0.316**. Für Montage liegt sie bei **0.345**, für Dienstag bis Freitag bei **0.306**. Die grössere Stichprobe erlaubt damit eine getrennte Beschreibung längerer und normaler Fenster. Ob die Beziehung gegenüber Kontrollmerkmalen stabilen Zusatznutzen besitzt, muss die spätere Walk-forward-Validierung zeigen.

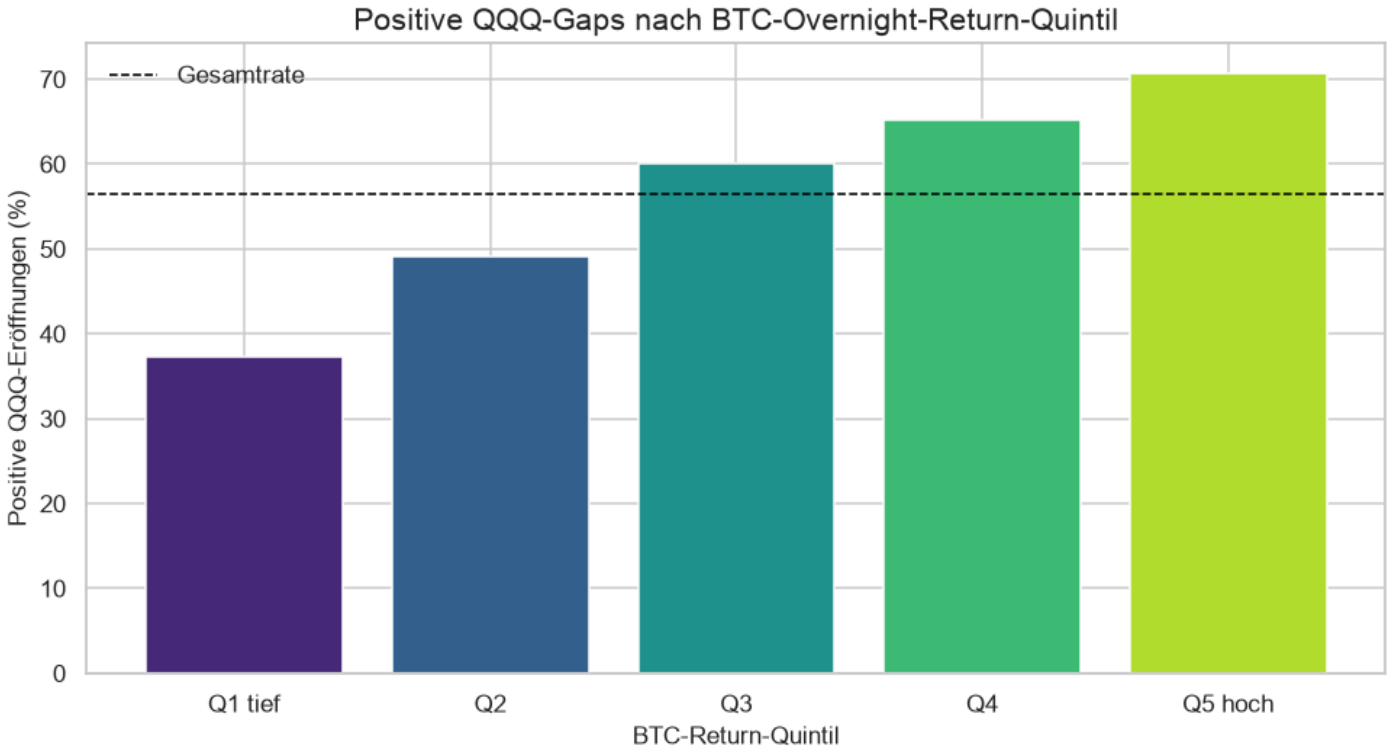
7.3 Richtungsanteil nach BTC-Return-Quintil

Eine reine Korrelation kann nichtlineare oder schwellenartige Beziehungen übersehen. Deshalb teilen wir die BTC-Overnight-Returns im Entwicklungszeitraum in fünf gleich grosse Gruppen und berechnen je Gruppe den Anteil positiver QQQ-Gaps. Die Quintile werden nur für diese deskriptive EDA verwendet und nicht als nachträglich ausgewählte Modellfeatures übernommen.

```
# Create equal-frequency bins for a descriptive monotonicity check
quintile_labels = ["Q1 tief", "Q2", "Q3", "Q4", "Q5 hoch"]
development_data["btc_return_quintile"] = pd.qcut(
    development_data["btc_overnight_return"],
    q=5,
    labels=quintile_labels,
)
quintile_summary = (
    development_data.groupby("btc_return_quintile", observed=False)
    .agg(
        Beobachtungen=(CLASSIFICATION_TARGET, "size"),
        BTC_Return_Median=("btc_overnight_return", "median"),
        Positive_QQQ_Rate=(CLASSIFICATION_TARGET, "mean"),
        QQQ_Gap_Median=("qqq_gap_percent", "median"),
    )
)
display(quintile_summary.round(4))

plt.figure(figsize=(9, 5))
plt.bar(
    quintile_summary.index.astype(str),
    100 * quintile_summary["Positive_QQQ_Rate"],
    color=[VIRIDIS(value) for value in np.linspace(0.12, 0.88, 5)],
)
plt.axhline(
    100 * positive_share,
    color="black",
    linewidth=1,
    linestyle="--",
    label="Gesamtrate",
)
plt.title("Positive QQQ-Gaps nach BTC-Overnight-Return-Quintil")
plt.xlabel("BTC-Return-Quintil")
plt.ylabel("Positive QQQ-Eröffnungen (%)")
plt.legend()
plt.tight_layout()
plt.show()
```

	Beobachtungen	BTC_Return_Median	Positive_QQQ_Rate	QQQ_Gap_Median
btc_return_quintile				
Q1 tief	389	-0.0289	0.3728	-0.1816
Q2	389	-0.0085	0.4910	-0.0118
Q3	389	0.0012	0.6015	0.1125
Q4	389	0.0115	0.6530	0.1888
Q5 hoch	389	0.0338	0.7069	0.2995




```
# Summarize the observed range without selecting a threshold
lowest_quintile_rate = quintile_summary["Positive_QQQ_Rate"].iloc[0]
highest_quintile_rate = quintile_summary["Positive_QQQ_Rate"].iloc[-1]
quintile_rate_difference = highest_quintile_rate - lowest_quintile_rate
quintile_rates_are_ordered = quintile_summary[
    "Positive_QQQ_Rate"
].is_monotonic_increasing
quintile_pattern_text = (
    "Die positive QQQ-Rate steigt über alle fünf Quintile geordnet an."
    if quintile_rates_are_ordered
    else "Die positive QQQ-Rate verläuft über die fünf Quintile nicht geordnet."
)

display(
    Markdown(
        f'''
### Interpretation

Im tiefsten BTC-Return-Quintil sind **{lowest_quintile_rate:.1%}** der
QQQ-Gaps positiv, im höchsten Quintil **{highest_quintile_rate:.1%}**.
```

```
Die Differenz beträgt **{quintile_rate_difference:.1%}**.
{quintile_pattern_text} Das ist ein klarer deskriptiver Hinweis zugunsten
unserer Hypothese, bleibt aber eine In-Sample-Beschreibung und kein
Beleg für Out-of-sample-Prognosekraft. Die Quintile werden nicht als
nachträglich optimierte Schwellenwerte in die Modelle übernommen.
        '''
    )
)
```

Interpretation

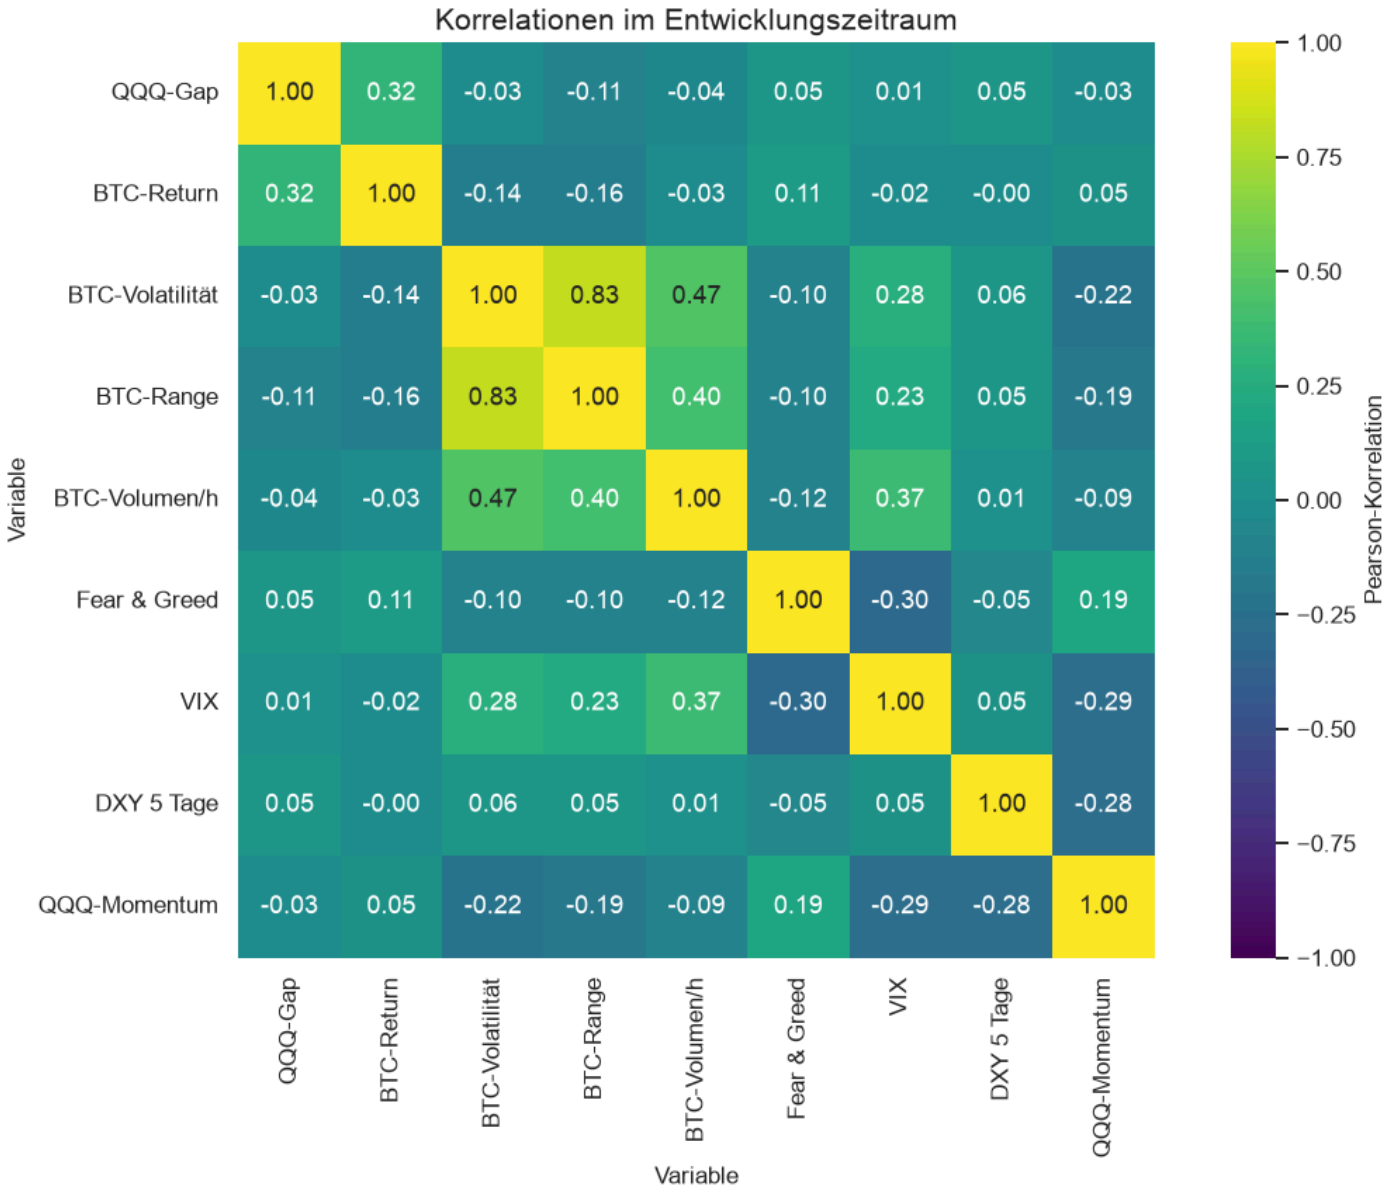
Im tiefsten BTC-Return-Quintil sind **37.3%** der QQQ-Gaps positiv, im höchsten Quintil **70.7%**. Die Differenz beträgt **33.4%**. Die positive QQQ-Rate steigt über alle fünf Quintile geordnet an. Das ist ein klarer deskriptiver Hinweis zugunsten unserer Hypothese, bleibt aber eine In-Sample-Beschreibung und kein Beleg für Out-of-sample-Prognosekraft. Die Quintile werden nicht als nachträglich optimierte Schwellenwerte in die Modelle übernommen.

7.4 Kompakte Korrelationsübersicht

Die Heatmap vergleicht den numerischen Gap mit einer kleinen, vorab definierten Auswahl von Bitcoin-, Sentiment-, Makro- und QQQ-Merkmalen. Sie dient der Plausibilitätsprüfung, nicht der automatischen Feature-Auswahl.

```
# Keep the heatmap focused on the research question
correlation_columns = [
    NUMERIC_TARGET,
    "btc_overnight_return",
    "btc_overnight_rv_intensity",
    "btc_overnight_range",
    "btc_overnight_log_volume_per_hour",
    "fear_greed",
    "vix_close",
    "dxy_change_5d",
    "qqq_momentum_5d",
]
correlation_labels = {
    NUMERIC_TARGET: "QQQ-Gap",
    "btc_overnight_return": "BTC-Return",
    "btc_overnight_rv_intensity": "BTC-Volatilität",
    "btc_overnight_range": "BTC-Range",
    "btc_overnight_log_volume_per_hour": "BTC-Volumen/h",
    "fear_greed": "Fear & Greed",
    "vix_close": "VIX",
    "dxy_change_5d": "DXY 5 Tage",
    "qqq_momentum_5d": "QQQ-Momentum",
}
correlation_matrix = development_data[correlation_columns].corr().rename(
    index=correlation_labels, columns=correlation_labels
)
```

```
plt.figure(figsize=(11, 8))
sns.heatmap(
    correlation_matrix,
    cmap="viridis",
    vmin=-1,
    vmax=1,
    center=0,
    annot=True,
    fmt=".2f",
    square=True,
    cbar_kws={"label": "Pearson-Korrelation"},
)
plt.title("Korrelationen im Entwicklungszeitraum")
plt.xlabel("Variable")
plt.ylabel("Variable")
plt.tight_layout()
plt.show()
```



```
# Rank target correlations for a concise evidence-based interpretation
target_correlations = (
    development_data[correlation_columns]
    .corr()[NUMERIC_TARGET]
    .drop(NUMERIC_TARGET)
    .sort_values(key=lambda values: values.abs(), ascending=False)
)
strongest_feature = target_correlations.index[0]
strongest_value = target_correlations.iloc[0]

display(target_correlations.rename("Korrelation mit QQQ-Gap").round(3).to_frame())
display(
    Markdown(
        f'''
### Interpretation

Die stärkste absolute lineare Zielkorrelation in dieser bewusst kleinen
Auswahl besitzt **`{strongest_feature}`** mit
**{strongest_value:.3f}**. Die Grössenordnung ist eine
In-Sample-Beschreibung. Stark korrelierte Features können redundant
sein; schwach korrelierte Features können in nichtlinearen Modellen
gemeinsam nützlich werden. Deshalb bleiben die Feature-Sets wie vorab
definiert bestehen.
        '''
    )
)
```

	Korrelation mit QQQ-Gap
btc_overnight_return	0.316
btc_overnight_range	-0.108
dxy_change_5d	0.052
fear_greed	0.051
btc_overnight_log_volume_per_hour	-0.041
qqq_momentum_5d	-0.029
btc_overnight_rv_intensity	-0.029
vix_close	0.008

Interpretation

Die stärkste absolute lineare Zielkorrelation in dieser bewusst kleinen Auswahl besitzt `btc_overnight_return` mit **0.316**. Die Grössenordnung ist eine In-Sample-Beschreibung. Stark korrelierte Features können redundant sein; schwach korrelierte Features können in nichtlinearen Modellen gemeinsam nützlich werden. Deshalb bleiben die Feature-Sets wie vorab definiert bestehen.

8. Expanding-window-Validierung und Mehrheitsbaseline

8.1 Jährliche Expanding-window-Folds

Erklärung

Ein zufälliger Split würde zukünftige Marktregime in das Training mischen. Wir verwenden deshalb fünf chronologische Folds. Für das Validierungsjahr (v) besteht das Training aus allen Beobachtungen vor dem 1. Januar von (v):

$$\mathcal{T}_v = \{(x_t, y_t) : date_t < 1.\ Januar\ v\}, \qquad \mathcal{V}_v = \{(x_t, y_t) : year(date_t) = v\}.$$

Innerhalb eines Validierungsjahres darf eine Walk-forward-Methode nach jedem beobachteten Zieltag auch diese neue Vergangenheit verwenden. Der Holdout ab 2026 bleibt vollständig ausserhalb aller Folds.

```
# Define annual folds using development data only
fold_rows = []
for validation_year in VALIDATION_YEARS:
    validation_start = pd.Timestamp(f"{validation_year}-01-01")
    validation_end = pd.Timestamp(f"{validation_year + 1}-01-01")
    training_fold = development_data[
        development_data["target_session_date"] < validation_start
    ]
    validation_fold = development_data[
        (development_data["target_session_date"] >= validation_start)
        & (development_data["target_session_date"] < validation_end)
    ]

    # Enforce strict chronology and non-empty annual folds
    assert not training_fold.empty
    assert not validation_fold.empty
    assert (
        training_fold["target_session_date"].max()
        < validation_fold["target_session_date"].min()
    )
    assert validation_fold["target_session_date"].max() < HOLDOUT_START

    fold_rows.append(
        {
            "Validierungsjahr": validation_year,
            "Training von": training_fold["target_session_date"].min(),
            "Training bis": training_fold["target_session_date"].max(),
            "Training Beobachtungen": len(training_fold),
            "Training Positivrate": training_fold[
                CLASSIFICATION_TARGET
            ].mean(),
            "Validierung von": validation_fold[
                "target_session_date"
            ].min(),
            "Validierung bis": validation_fold[
                "target_session_date"
            ].max(),
            "Validierung Beobachtungen": len(validation_fold),
```

```
        }
    )

fold_summary = pd.DataFrame(fold_rows)
assert fold_summary["Validierung Beobachtungen"].sum() == 1248
display(fold_summary.round({"Training Positivrate": 3}))
```

	Validierungsjahr	Training von	Training bis	Training Beobachtungen	Training Positivrate	Validierung von	Validierung bis	Validierung Beobachtungen
0	2021	2018-03-05	2020-12-31	697	0.590	2021-01-04	2021-12-31	246
1	2022	2018-03-05	2021-12-31	943	0.587	2022-01-03	2022-12-30	251
2	2023	2018-03-05	2022-12-30	1194	0.559	2023-01-03	2023-12-29	249
3	2024	2018-03-05	2023-12-29	1443	0.554	2024-01-02	2024-12-31	252
4	2025	2018-03-05	2024-12-31	1695	0.560	2025-01-02	2025-12-31	250

```
# Summarize the executed fold boundaries
first_training_size = int(fold_summary.iloc[0]["Training Beobachtungen"])
last_training_size = int(fold_summary.iloc[-1]["Training Beobachtungen"])
validation_forecasts = int(
    fold_summary["Validierung Beobachtungen"].sum()
)

display(
    Markdown(
        f'''
### Interpretation

Der erste Fold trainiert auf **{first_training_size} Handelstagen** aus
2018 bis 2020 und validiert auf 2021. Bis zum letzten Fold wächst das
Starttraining auf **{last_training_size} Beobachtungen**. Insgesamt
enthalten die fünf Validierungsjahre **{validation_forecasts}
chronologische Prognosetermine**. Jede Trainingsperiode endet strikt
vor ihrer Validierung; Daten ab 2026 werden nicht verwendet.
        '''
    )
)
```

Interpretation

Der erste Fold trainiert auf **697 Handelstagen** aus 2018 bis 2020 und validiert auf 2021. Bis zum letzten Fold wächst das Starttraining auf **1695 Beobachtungen**. Insgesamt enthalten die fünf Validierungsjahre **1248 chronologische Prognosetermine**. Jede Trainingsperiode endet strikt vor ihrer Validierung; Daten ab 2026 werden nicht verwendet.

8.2 Vorab festgelegte Modellkonfigurationen

Wir verzichten bewusst auf eine Hyperparametersuche, weil der Schwerpunkt nicht auf der Optimierung eines möglichst leistungsfähigen Modells liegt, sondern auf dem Vergleich derselben Modellklasse mit und ohne Bitcoin-Merkmale. Innerhalb jeder Modellfamilie verwenden beide Varianten deshalb identische, bewusst konservative Hyperparameter. Der beobachtete Unterschied lässt sich damit klarer dem zusätzlichen Informationsgehalt der BTC-Features zuordnen.

Eine methodisch korrekte Optimierung hätte als verschachtelte zeitliche Validierung innerhalb der jeweils verfügbaren Trainingshistorie durchgeführt werden müssen. Eine Auswahl anhand der Walk-forward-Ergebnisse oder des Holdouts hätte dagegen das Risiko einer Überanpassung erhöht. Entsprechend interpretieren wir die Resultate als Leistung der vorab festgelegten Modellkonfigurationen und erheben keinen Anspruch, die jeweils optimale Hyperparameterkombination gefunden zu haben.

8.3 Historische Mehrheitsklasse

Erklärung

Die naive Baseline verwendet keine Features. Vor jedem Prognosetag (t) berechnen wir den Anteil positiver QQQ-Gaps in allen bereits beobachteten Zielwerten:

$$\hat{p}_t = \frac{1}{N_t} \sum_{i:date_i<date_t} Direction_i, \qquad \widehat{Direction}_t = \mathbb{1}(\hat{p}_t \geq 0.5).$$

Bei einem exakten Gleichstand wählen wir die positive Klasse. Die Baseline wird vor jedem Handelstag aktualisiert und ist damit strenger als eine einmal auf dem gesamten Entwicklungszeitraum bestimmte Mehrheitsklasse.

Wir berichten Accuracy und Balanced Accuracy:

$$Balanced\ Accuracy = \frac{1}{2}(TPR + TNR).$$

Balanced Accuracy zeigt, ob ein Modell beide Richtungen erkennt, statt nur von der häufigeren Klasse zu profitieren.

```
from sklearn.metrics import accuracy_score, balanced_accuracy_score

# Generate one strictly historical majority forecast per validation day
majority_rows = []
for validation_year in VALIDATION_YEARS:
    validation_fold = development_data[
        development_data["target_session_date"].dt.year
        == validation_year
    ]

    for observation in validation_fold.itertuples(index=False):
        training_history = development_data[
            development_data["target_session_date"]
            < observation.target_session_date
        ]
```

```
        historical_positive_rate = training_history[
            CLASSIFICATION_TARGET
        ].mean()

        majority_rows.append(
            {
                "model": "Historische Mehrheitsklasse",
                "fold_year": validation_year,
                "forecast_date": observation.target_session_date,
                "train_start": training_history[
                    "target_session_date"
                ].min(),
                "train_end": training_history[
                    "target_session_date"
                ].max(),
                "train_size": len(training_history),
                "historical_positive_rate": historical_positive_rate,
                "positive_probability": historical_positive_rate,
                "prediction": int(historical_positive_rate >= 0.5),
                "actual": observation.qqq_gap_direction,
                "target_is_monday": observation.target_is_monday,
            }
        )

majority_predictions = pd.DataFrame(majority_rows).sort_values(
    "forecast_date"
).reset_index(drop=True)

# Validate the expanding handoff and protect the holdout
assert len(majority_predictions) == 1248
assert majority_predictions["forecast_date"].is_monotonic_increasing
assert majority_predictions["forecast_date"].is_unique
assert (
    majority_predictions["train_end"]
    < majority_predictions["forecast_date"]
).all()
assert (majority_predictions["forecast_date"] < HOLDOUT_START).all()
assert majority_predictions["prediction"].isin([0, 1]).all()
assert majority_predictions["actual"].isin([0, 1]).all()
```

```
CLASSIFIER_UNCERTAINTY_BAND = 0.10
MARGIN_AUDIT_COLUMNS = [
    "model",
    "fold_year",
    "forecast_date",
    "prediction",
    "actual",
    "target_is_monday",
    "actual_direction",
    "decision_score",
    "signed_margin",
    "boundary_l1_loss",
```

```
    "boundary_uncertain",
    "score_type",
    "score_unit",
]


def add_classifier_margin_columns(frame):
    # Center positive-class probabilities on the decision boundary at zero
    result = frame.copy()
    result["actual_direction"] = np.where(result["actual"].eq(1), 1.0, -1.0)
    result["decision_score"] = 2 * result["positive_probability"] - 1
    result["signed_margin"] = (
        result["actual_direction"] * result["decision_score"]
    )
    result["boundary_l1_loss"] = np.maximum(
        0.0, -result["signed_margin"]
    )
    result["boundary_uncertain"] = (
        result["positive_probability"].sub(0.5).abs()
        < CLASSIFIER_UNCERTAINTY_BAND
    )
    result["score_type"] = "Probabilistischer Klassifikator"
    result["score_unit"] = "Zentrierte Wahrscheinlichkeit [-1, 1]"

    # Validate sign convention and every derived margin quantity
    assert result["prediction"].eq(
        result["decision_score"].ge(0).astype(int)
    ).all()
    assert np.allclose(
        result["signed_margin"],
        result["actual_direction"] * result["decision_score"],
    )
    assert np.allclose(
        result["boundary_l1_loss"],
        np.maximum(0.0, -result["signed_margin"]),
    )
    assert result["decision_score"].between(-1, 1).all()
    return result


def add_chronos_margin_columns(frame):
    # Keep the Chronos score in predicted gap percentage points
    result = frame.copy()
    result["actual_direction"] = np.where(result["actual"].eq(1), 1.0, -1.0)
    result["decision_score"] = result["predicted_gap_percent"]
    result["signed_margin"] = (
        result["actual_direction"] * result["decision_score"]
    )
    result["boundary_l1_loss"] = np.maximum(
        0.0, -result["signed_margin"]
    )
    result["boundary_uncertain"] = (
        result["q10_gap_log_return"].le(0)
```

```
        & result["q90_gap_log_return"].ge(0)
    )
    result["score_type"] = "Chronos-2"
    result["score_unit"] = "Prognostizierter Gap (Prozentpunkte)"

    # Validate sign convention and the interval-based uncertainty rule
    assert result["prediction"].eq(
        result["decision_score"].gt(0).astype(int)
    ).all()
    assert np.allclose(
        result["signed_margin"],
        result["actual_direction"] * result["decision_score"],
    )
    assert np.allclose(
        result["boundary_l1_loss"],
        np.maximum(0.0, -result["signed_margin"]),
    )
    assert result["boundary_uncertain"].eq(
        result["q10_gap_log_return"].le(0)
        & result["q90_gap_log_return"].ge(0)
    ).all()
    return result


def summarize_classification(frame):
    # Calculate the shared classification metrics across all model families
    return pd.Series(
        {
            "Beobachtungen": len(frame),
            "Positivrate Ziel": frame["actual"].mean(),
            "Positivrate Prognose": frame["prediction"].mean(),
            "Accuracy": accuracy_score(
                frame["actual"], frame["prediction"]
            ),
            "Balanced Accuracy": balanced_accuracy_score(
                frame["actual"], frame["prediction"]
            ),
        }
    )


def summarize_margin(frame):
    # Summarize boundary behavior without mixing score units
    assert frame["score_type"].nunique() == 1
    assert frame["score_unit"].nunique() == 1
    return pd.Series(
        {
            "Beobachtungen": len(frame),
            "Scoretyp": frame["score_type"].iloc[0],
            "Scoreeinheit": frame["score_unit"].iloc[0],
            "Mittlere Boundary-L1-Loss": frame[
                "boundary_l1_loss"
            ].mean(),
```

```
            "Median Signed Margin": frame["signed_margin"].median(),
            "Anteil negative Signed Margin": frame[
                "signed_margin"
            ].lt(0).mean(),
            "Anteil grenznah unsicher": frame[
                "boundary_uncertain"
            ].mean(),
        }
    )


# Add the centered probability score to the historical majority baseline
majority_predictions = add_classifier_margin_columns(majority_predictions)

# Save the transparent forecast-level audit trail including margins
majority_output_path = (
    PROCESSED_DATA_DIR / "btc_overnight_qqq_majority_baseline.csv"
)
majority_predictions.to_csv(majority_output_path, index=False)

majority_head = majority_predictions.head(6).copy()
majority_tail = majority_predictions.tail(3).copy()
for preview in [majority_head, majority_tail]:
    numeric_columns = preview.select_dtypes(include="number").columns
    preview[numeric_columns] = preview[numeric_columns].round(3)
    display(preview)

# Report overall and calendar-subgroup results
baseline_scope_metrics = pd.DataFrame(
    {
        "Alle Handelstage": summarize_classification(
            majority_predictions
        ),
        "Montage": summarize_classification(
            majority_predictions[
                majority_predictions["target_is_monday"] == 1
            ]
        ),
        "Dienstag bis Freitag": summarize_classification(
            majority_predictions[
                majority_predictions["target_is_monday"] == 0
            ]
        ),
    }
).T

baseline_year_metrics = (
    majority_predictions.groupby("fold_year", observed=False)
    .apply(summarize_classification, include_groups=False)
    .reset_index()
    .rename(columns={"fold_year": "Validierungsjahr"})
)
```

```
display(baseline_scope_metrics.round(3))
display(baseline_year_metrics.round(3))

# Visualize annual performance on a common percentage scale
plot_metrics = baseline_year_metrics.melt(
    id_vars="Validierungsjahr",
    value_vars=["Accuracy", "Balanced Accuracy"],
    var_name="Metrik",
    value_name="Wert",
)
plot_metrics["Wert (%)"] = 100 * plot_metrics["Wert"]

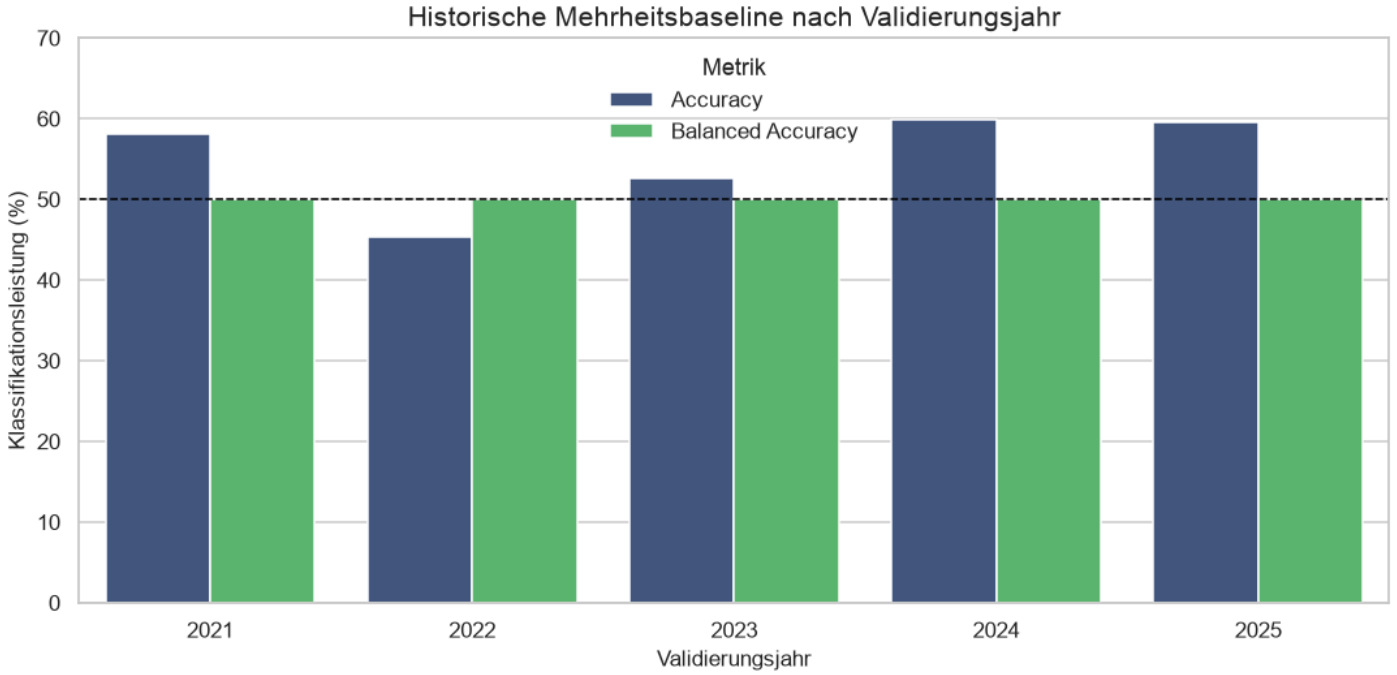
plt.figure(figsize=(10, 5))
sns.barplot(
    data=plot_metrics,
    x="Validierungsjahr",
    y="Wert (%)",
    hue="Metrik",
    palette=[VIRIDIS(0.25), VIRIDIS(0.72)],
)
plt.axhline(50, color="black", linewidth=1, linestyle="--")
plt.ylim(0, 70)
plt.title("Historische Mehrheitsbaseline nach Validierungsjahr")
plt.xlabel("Validierungsjahr")
plt.ylabel("Klassifikationsleistung (%)")
plt.legend(title="Metrik")
plt.tight_layout()
plt.show()
```

	model	fold_year	forecast_date	train_start	train_end	train_size	historical_positive_rate	positiv
0	Historische Mehrheitsklasse	2021	2021-01-04	2018-03-05	2020-12-31	697	0.590	0.590
1	Historische Mehrheitsklasse	2021	2021-01-05	2018-03-05	2021-01-04	698	0.590	0.590
2	Historische Mehrheitsklasse	2021	2021-01-06	2018-03-05	2021-01-05	699	0.589	0.589
3	Historische Mehrheitsklasse	2021	2021-01-07	2018-03-05	2021-01-06	700	0.589	0.589
4	Historische Mehrheitsklasse	2021	2021-01-08	2018-03-05	2021-01-07	701	0.589	0.589
5	Historische Mehrheitsklasse	2021	2021-01-11	2018-03-05	2021-01-08	702	0.590	0.590

	model	fold_year	forecast_date	train_start	train_end	train_size	historical_positive_rate	po
1245	Historische Mehrheitsklasse	2025	2025-12-29	2018-03-05	2025-12-26	1942	0.565	0.5
1246	Historische Mehrheitsklasse	2025	2025-12-30	2018-03-05	2025-12-29	1943	0.565	0.5
1247	Historische Mehrheitsklasse	2025	2025-12-31	2018-03-05	2025-12-30	1944	0.565	0.5

	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy
Alle Handelstage	1248.0	0.551	1.0	0.551	0.5
Montage	231.0	0.558	1.0	0.558	0.5
Dienstag bis Freitag	1017.0	0.550	1.0	0.550	0.5

	Validierungsjahr	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy
0	2021	246.0	0.581	1.0	0.581	0.5
1	2022	251.0	0.454	1.0	0.454	0.5
2	2023	249.0	0.526	1.0	0.526	0.5
3	2024	252.0	0.599	1.0	0.599	0.5
4	2025	250.0	0.596	1.0	0.596	0.5




```
# Interpret the executed baseline without overstating skill
overall_accuracy = baseline_scope_metrics.loc[
    "Alle Handelstage", "Accuracy"
]
```

```
overall_balanced_accuracy = baseline_scope_metrics.loc[
    "Alle Handelstage", "Balanced Accuracy"
]
predicted_positive_count = int(majority_predictions["prediction"].sum())
best_year_row = baseline_year_metrics.loc[
    baseline_year_metrics["Accuracy"].idxmax()
]
worst_year_row = baseline_year_metrics.loc[
    baseline_year_metrics["Accuracy"].idxmin()
]

display(
    Markdown(
        f'''
### Interpretation

Die historische Positivrate bleibt an allen Prognoseterminen über 50%.
Deshalb sagt die Baseline für **{predicted_positive_count} von
{len(majority_predictions)} Terminen** eine positive Eröffnung voraus.
Ihre gesamte Accuracy beträgt **{overall_accuracy:.1%}**, die Balanced
Accuracy erwartungsgemäss **{overall_balanced_accuracy:.1%}**. Die
höhere Accuracy entsteht ausschliesslich aus der leicht häufigeren
positiven Klasse; die Baseline erkennt keine negativen Gaps.

Die jährliche Accuracy schwankt von
**{worst_year_row['Accuracy']:.1%} im Jahr
{int(worst_year_row['Validierungsjahr'])}** bis
**{best_year_row['Accuracy']:.1%} im Jahr
{int(best_year_row['Validierungsjahr'])}**. Diese Baseline ist damit die
Mindesthürde: Ein nützliches Richtungsmodell sollte nicht nur ihre
Accuracy übertreffen, sondern auch eine Balanced Accuracy klar über
50% erreichen.
        '''
    )
)
```

Interpretation

Die historische Positivrate bleibt an allen Prognoseterminen über 50%. Deshalb sagt die Baseline für **1248 von 1248 Terminen** eine positive Eröffnung voraus. Ihre gesamte Accuracy beträgt **55.1%**, die Balanced Accuracy erwartungsgemäss **50.0%**. Die höhere Accuracy entsteht ausschliesslich aus der leicht häufigeren positiven Klasse; die Baseline erkennt keine negativen Gaps.

Die jährliche Accuracy schwankt von **45.4% im Jahr 2022** bis **59.9% im Jahr 2024**. Diese Baseline ist damit die Mindesthürde: Ein nützliches Richtungsmodell sollte nicht nur ihre Accuracy übertreffen, sondern auch eine Balanced Accuracy klar über 50% erreichen.

9. Logistische Regression

9.1 Methode und Walk-forward-Training

Erklärung

Die logistische Regression modelliert direkt die Wahrscheinlichkeit eines positiven QQQ-Gaps. Für standardisierte Features (z_{t,j}) gilt:

$$P(Direction_t = 1 \mid z_t) = \sigma\left(\beta_0 + \sum_{j=1}^{p} \beta_j z_{t,j}\right), \qquad \sigma(a) = \frac{1}{1 + e^{-a}}.$$

Die Standardisierung wird vor jedem Prognosetag ausschliesslich auf der damaligen Trainingshistorie geschätzt:

$$z_{t,j} = \frac{x_{t,j} - \mu_{j,train}}{s_{j,train}}.$$

Wir verwenden eine L2-Regularisierung mit festem (C=1). Weil die EDA eine leichte Klassenverschiebung zeigt, berechnet `class_weight="balanced"` in jedem Trainingsfenster Gewichte aus den dort verfügbaren Zielwerten. Dadurch erhalten positive und negative Beobachtungen im Fit dasselbe Gesamtgewicht.

Wir vergleichen zwei vorab definierte Varianten:

1. **Logistische Regression Kontrolle:** QQQ, Fear & Greed, VIX, DXY, Montag-Indikator und Fensterlänge.
2. **Logistische Regression + Bitcoin:** dieselben Variablen plus die fünf BTC-Overnight-Merkmale.

Beide Modelle werden vor jedem Validierungstag neu auf allen früheren Beobachtungen geschätzt. Es gibt keine Hyperparametersuche und keinen Zugriff auf den Holdout ab 2026.

```
from sklearn.linear_model import LogisticRegression
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import StandardScaler

LOGISTIC_MODEL_FEATURES = {
    "Logistische Regression Kontrolle": CONTROL_FEATURES,
    "Logistische Regression + Bitcoin": FULL_FEATURES,
}
LOGISTIC_PARAMETERS = {
    "C": 1.0,
    "solver": "lbfgs",
    "class_weight": "balanced",
    "max_iter": 2000,
    "random_state": RANDOM_SEED,
}

logistic_rows = []
for model_name, feature_columns in LOGISTIC_MODEL_FEATURES.items():
    for validation_year in VALIDATION_YEARS:
        validation_fold = development_data[
            development_data["target_session_date"].dt.year
```

```
            == validation_year
        ]

        for _, observation in validation_fold.iterrows():
            forecast_date = observation["target_session_date"]
            training_history = development_data[
                development_data["target_session_date"] < forecast_date
            ]

            # Fit scaling and classification only on historical rows
            classifier = make_pipeline(
                StandardScaler(),
                LogisticRegression(**LOGISTIC_PARAMETERS),
            )
            classifier.fit(
                training_history[feature_columns],
                training_history[CLASSIFICATION_TARGET],
            )

            forecast_features = (
                observation[feature_columns].to_frame().T.astype(float)
            )
            positive_probability = classifier.predict_proba(
                forecast_features
            )[0, 1]
            prediction = int(positive_probability >= 0.5)
            fitted_logistic = classifier.named_steps[
                "logisticregression"
            ]

            logistic_rows.append(
                {
                    "model": model_name,
                    "fold_year": validation_year,
                    "forecast_date": forecast_date,
                    "train_start": training_history[
                        "target_session_date"
                    ].min(),
                    "train_end": training_history[
                        "target_session_date"
                    ].max(),
                    "train_size": len(training_history),
                    "train_positive_rate": training_history[
                        CLASSIFICATION_TARGET
                    ].mean(),
                    "positive_probability": positive_probability,
                    "prediction": prediction,
                    "actual": observation[CLASSIFICATION_TARGET],
                    "target_is_monday": observation["target_is_monday"],
                    "iterations": int(fitted_logistic.n_iter_.max()),
                }
            )
```

```
logistic_predictions = pd.DataFrame(logistic_rows).sort_values(
    ["model", "forecast_date"]
).reset_index(drop=True)

# Validate identical dates, chronology and numerical convergence
expected_forecast_dates = majority_predictions["forecast_date"].tolist()
for model_name in LOGISTIC_MODEL_FEATURES:
    model_predictions = logistic_predictions[
        logistic_predictions["model"] == model_name
    ]
    assert len(model_predictions) == len(majority_predictions)
    assert model_predictions["forecast_date"].tolist() == expected_forecast_dates
    assert model_predictions["actual"].tolist() == majority_predictions[
        "actual"
    ].tolist()
    assert (
        model_predictions["train_end"]
        < model_predictions["forecast_date"]
    ).all()

assert (logistic_predictions["forecast_date"] < HOLDOUT_START).all()
assert logistic_predictions["positive_probability"].between(0, 1).all()
assert logistic_predictions["prediction"].isin([0, 1]).all()
assert logistic_predictions["iterations"].max() < LOGISTIC_PARAMETERS[
    "max_iter"
]

logistic_predictions = add_classifier_margin_columns(logistic_predictions)

# Save one transparent forecast-level audit trail for both variants
logistic_output_path = (
    PROCESSED_DATA_DIR / "btc_overnight_qqq_logistic_backtest.csv"
)
logistic_predictions.to_csv(logistic_output_path, index=False)

logistic_preview = logistic_predictions.groupby(
    "model", observed=False, sort=False
).head(3).copy()
logistic_numeric = logistic_preview.select_dtypes(include="number").columns
logistic_preview[logistic_numeric] = logistic_preview[
    logistic_numeric
].round(3)
display(logistic_preview)
```

	model	fold_year	forecast_date	train_start	train_end	train_size	train_positive_rate	positive_pr
0	Logistische Regression + Bitcoin	2021	2021-01-04	2018-03-05	2020-12-31	697	0.590	0.270
1	Logistische Regression + Bitcoin	2021	2021-01-05	2018-03-05	2021-01-04	698	0.590	0.437

	model	fold_year	forecast_date	train_start	train_end	train_size	train_positive_rate	positive_pr
2	Logistische Regression + Bitcoin	2021	2021-01-06	2018-03-05	2021-01-05	699	0.589	0.652
1248	Logistische Regression Kontrolle	2021	2021-01-04	2018-03-05	2020-12-31	697	0.590	0.388
1249	Logistische Regression Kontrolle	2021	2021-01-05	2018-03-05	2021-01-04	698	0.590	0.506
1250	Logistische Regression Kontrolle	2021	2021-01-06	2018-03-05	2021-01-05	699	0.589	0.630

```
# Confirm the shared expanding-window handoff
logistic_handoff = (
    logistic_predictions.groupby("model", observed=False, sort=False)
    .agg(
        Prognosen=("forecast_date", "size"),
        Erste_Prognose=("forecast_date", "min"),
        Letzte_Prognose=("forecast_date", "max"),
        Erstes_Training=("train_size", "min"),
        Letztes_Training=("train_size", "max"),
        Max_Iterationen=("iterations", "max"),
    )
    .reset_index()
)
display(logistic_handoff)

maximum_iterations = int(logistic_predictions["iterations"].max())
display(
    Markdown(
        f'''
### Interpretation

Beide Varianten erzeugen dieselben **{len(majority_predictions)}
Prognosetermine** wie die Mehrheitsbaseline. Das Training wächst vor
jedem Handelstag um den neu bekannten Zielwert. Die Fits benötigen
höchstens **{maximum_iterations} Optimierungsschritte** und bleiben
damit deutlich unter dem Limit von
**{LOGISTIC_PARAMETERS['max_iter']}**; es gibt keinen Hinweis auf ein
Konvergenzproblem.
        '''
    )
)
```

	model	Prognosen	Erste_Prognose	Letzte_Prognose	Erstes_Training	Letztes_Training	Max_Iteratior
0	Logistische Regression	1248	2021-01-04	2025-12-31	697	1944	23

	model	Prognosen	Erste_Prognose	Letzte_Prognose	Erstes_Training	Letztes_Training	Max_Iteratior
	+ Bitcoin						
1	Logistische Regression Kontrolle	1248	2021-01-04	2025-12-31	697	1944	15

Interpretation

Beide Varianten erzeugen dieselben **1248 Prognosetermine** wie die Mehrheitsbaseline. Das Training wächst vor jedem Handelstag um den neu bekannten Zielwert. Die Fits benötigen höchstens **23 Optimierungsschritte** und bleiben damit deutlich unter dem Limit von **2000**; es gibt keinen Hinweis auf ein Konvergenzproblem.

9.2 Ergebnisse und Bitcoin-Zusatznutzen

Erklärung

Wir vergleichen die beiden logistischen Varianten und die Mehrheitsbaseline auf identischen 1'248 Prognoseterminen. Neben dem Gesamtergebnis zeigen wir die Montagsgruppe sowie jedes Validierungsjahr. Entscheidend für die Forschungsfrage ist der direkte Unterschied zwischen Kontrolle und `+ Bitcoin`.

```
# Combine baseline and logistic predictions on the shared dates
comparison_predictions = pd.concat(
    [
        majority_predictions[
            [
                "model",
                "fold_year",
                "forecast_date",
                "prediction",
                "actual",
                "target_is_monday",
            ]
        ],
        logistic_predictions[
            [
                "model",
                "fold_year",
                "forecast_date",
                "prediction",
                "actual",
                "target_is_monday",
            ]
        ],
    ],
    ignore_index=True,
)

model_order = [
```

```
    "Historische Mehrheitsklasse",
    "Logistische Regression Kontrolle",
    "Logistische Regression + Bitcoin",
]

overall_model_metrics = (
    comparison_predictions.groupby("model", observed=False, sort=False)
    .apply(summarize_classification, include_groups=False)
    .reindex(model_order)
    .reset_index()
)

logistic_year_metrics = (
    logistic_predictions.groupby(
        ["model", "fold_year"], observed=False, sort=False
    )
    .apply(summarize_classification, include_groups=False)
    .reset_index()
    .rename(columns={"fold_year": "Validierungsjahr"})
)

scope_rows = []
for model_name in model_order:
    model_predictions = comparison_predictions[
        comparison_predictions["model"] == model_name
    ]
    for scope_name, scope_frame in [
        ("Alle Handelstage", model_predictions),
        (
            "Montage",
            model_predictions[model_predictions["target_is_monday"] == 1],
        ),
        (
            "Dienstag bis Freitag",
            model_predictions[model_predictions["target_is_monday"] == 0],
        ),
    ]:
        metrics = summarize_classification(scope_frame).to_dict()
        scope_rows.append(
            {"Modell": model_name, "Teilmenge": scope_name, **metrics}
        )

model_scope_metrics = pd.DataFrame(scope_rows)

display(overall_model_metrics.round(3))
display(logistic_year_metrics.round(3))
display(model_scope_metrics.round(3))
```

	model	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy
0	Historische Mehrheitsklasse	1248.0	0.551	1.000	0.551	0.500

	model	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy
1	Logistische Regression Kontrolle	1248.0	0.551	0.585	0.524	0.515
2	Logistische Regression + Bitcoin	1248.0	0.551	0.622	0.607	0.596

	model	Validierungsjahr	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy
0	Logistische Regression + Bitcoin	2021	246.0	0.581	0.646	0.553	0.530
1	Logistische Regression + Bitcoin	2022	251.0	0.454	0.430	0.633	0.628
2	Logistische Regression + Bitcoin	2023	249.0	0.526	0.558	0.534	0.531
3	Logistische Regression + Bitcoin	2024	252.0	0.599	0.706	0.631	0.594
4	Logistische Regression + Bitcoin	2025	250.0	0.596	0.768	0.684	0.638
5	Logistische Regression Kontrolle	2021	246.0	0.581	0.671	0.488	0.459
6	Logistische Regression Kontrolle	2022	251.0	0.454	0.458	0.526	0.522
7	Logistische Regression Kontrolle	2023	249.0	0.526	0.622	0.502	0.496
8	Logistische Regression Kontrolle	2024	252.0	0.599	0.611	0.504	0.481
9	Logistische Regression Kontrolle	2025	250.0	0.596	0.564	0.600	0.591

	Modell	Teilmenge	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy
0	Historische Mehrheitsklasse	Alle Handelstage	1248.0	0.551	1.000	0.551	0.500
1	Historische Mehrheitsklasse	Montage	231.0	0.558	1.000	0.558	0.500

	Modell	Teilmenge	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy
2	Historische Mehrheitsklasse	Dienstag bis Freitag	1017.0	0.550	1.000	0.550	0.500
3	Logistische Regression Kontrolle	Alle Handelstage	1248.0	0.551	0.585	0.524	0.515
4	Logistische Regression Kontrolle	Montage	231.0	0.558	0.429	0.437	0.445
5	Logistische Regression Kontrolle	Dienstag bis Freitag	1017.0	0.550	0.620	0.544	0.532
6	Logistische Regression + Bitcoin	Alle Handelstage	1248.0	0.551	0.622	0.607	0.596
7	Logistische Regression + Bitcoin	Montage	231.0	0.558	0.550	0.610	0.606
8	Logistische Regression + Bitcoin	Dienstag bis Freitag	1017.0	0.550	0.638	0.607	0.594

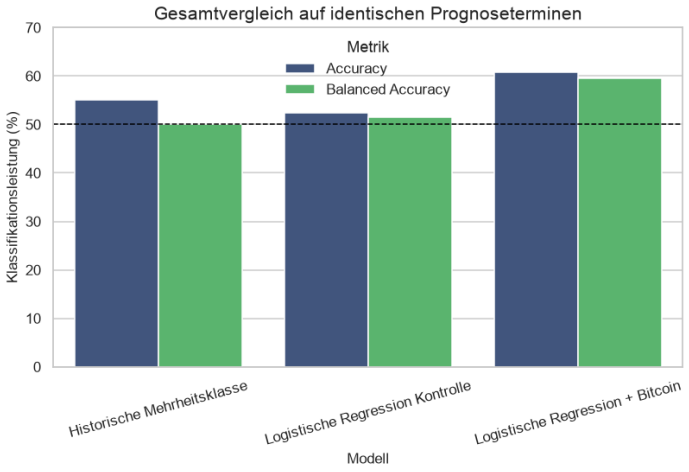
```
# Plot overall and annual metrics on a shared percentage scale
overall_plot = overall_model_metrics.melt(
    id_vars="model",
    value_vars=["Accuracy", "Balanced Accuracy"],
    var_name="Metrik",
    value_name="Wert",
)
overall_plot["Wert (%)"] = 100 * overall_plot["Wert"]

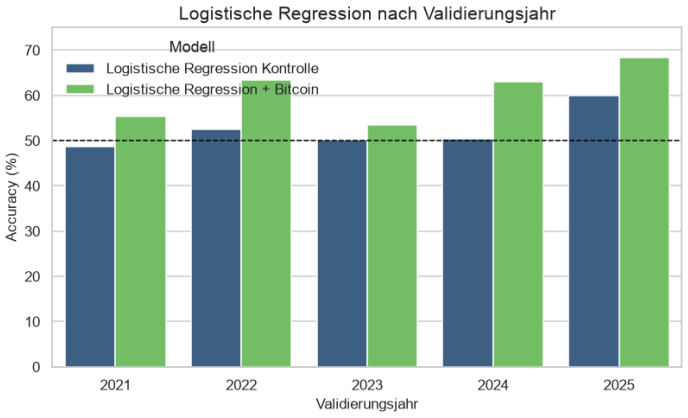
fig, axes = plt.subplots(1, 2, figsize=(15, 5.2))
sns.barplot(
    data=overall_plot,
    x="model",
    y="Wert (%)",
    hue="Metrik",
    order=model_order,
    palette=[VIRIDIS(0.25), VIRIDIS(0.72)],
    ax=axes[0],
)
axes[0].axhline(50, color="black", linewidth=1, linestyle="--")
axes[0].set_ylim(0, 70)
axes[0].set_title("Gesamtvergleich auf identischen Prognoseterminen")
axes[0].set_xlabel("Modell")
axes[0].set_ylabel("Klassifikationsleistung (%)")
axes[0].tick_params(axis="x", rotation=15)
axes[0].legend(title="Metrik")

yearly_plot = logistic_year_metrics.copy()
yearly_plot["Accuracy (%)"] = 100 * yearly_plot["Accuracy"]
sns.barplot(
    data=yearly_plot,
    x="Validierungsjahr",
```

```
    y="Accuracy (%)",
    hue="model",
    hue_order=[
        "Logistische Regression Kontrolle",
        "Logistische Regression + Bitcoin",
    ],
    palette=[VIRIDIS(0.30), VIRIDIS(0.78)],
    ax=axes[1],
)
axes[1].axhline(50, color="black", linewidth=1, linestyle="--")
axes[1].set_ylim(0, 75)
axes[1].set_title("Logistische Regression nach Validierungsjahr")
axes[1].set_xlabel("Validierungsjahr")
axes[1].set_ylabel("Accuracy (%)")
axes[1].legend(title="Modell")

fig.tight_layout()
plt.show()
```






```
# Derive the written comparison only from executed predictions
overall_by_model = overall_model_metrics.set_index("model")
control_accuracy = overall_by_model.loc[
    "Logistische Regression Kontrolle", "Accuracy"
]
bitcoin_accuracy = overall_by_model.loc[
    "Logistische Regression + Bitcoin", "Accuracy"
]
control_balanced = overall_by_model.loc[
    "Logistische Regression Kontrolle", "Balanced Accuracy"
]
bitcoin_balanced = overall_by_model.loc[
    "Logistische Regression + Bitcoin", "Balanced Accuracy"
]
bitcoin_predicted_positive_rate = overall_by_model.loc[
    "Logistische Regression + Bitcoin", "Positivrate Prognose"
]
scope_by_model = model_scope_metrics.set_index(["Modell", "Teilmenge"])
monday_control_accuracy = scope_by_model.loc[
```

```
    ("Logistische Regression Kontrolle", "Montage"), "Accuracy"
]
monday_bitcoin_accuracy = scope_by_model.loc[
    ("Logistische Regression + Bitcoin", "Montage"), "Accuracy"
]
monday_bitcoin_balanced = scope_by_model.loc[
    ("Logistische Regression + Bitcoin", "Montage"),
    "Balanced Accuracy",
]

yearly_pivot = logistic_year_metrics.pivot(
    index="Validierungsjahr", columns="model", values="Accuracy"
)
bitcoin_year_wins = int(
    (
        yearly_pivot["Logistische Regression + Bitcoin"]
        > yearly_pivot["Logistische Regression Kontrolle"]
    ).sum()
)

display(
    Markdown(
        f'''
### Interpretation

Die Kontrollvariante erreicht **{control_accuracy:.1%} Accuracy** und
**{control_balanced:.1%} Balanced Accuracy**. Mit den fünf
Bitcoin-Merkmalen steigen die Werte auf **{bitcoin_accuracy:.1%}** und
**{bitcoin_balanced:.1%}**. Der direkte Zusatz beträgt damit
**{bitcoin_accuracy - control_accuracy:.1%}-Punkte bei Accuracy** und
**{bitcoin_balanced - control_balanced:.1%}-Punkte bei Balanced
Accuracy**.

Die Bitcoin-Variante prognostiziert in
**{bitcoin_predicted_positive_rate:.1%}** der Fälle positiv und erkennt
somit beide Klassen. Sie übertrifft die Kontrollvariante in
**{bitcoin_year_wins} von {len(VALIDATION_YEARS)} Validierungsjahren**
bei der Accuracy. Das ist ein konsistenter Out-of-sample-Hinweis auf
zusätzlichen Informationsgehalt der BTC-Overnight-Merkmale innerhalb
der logistischen Regression.

An den **{int((majority_predictions['target_is_monday'] == 1).sum())}
Montagen** steigt die Accuracy von
**{monday_control_accuracy:.1%} ohne Bitcoin** auf
**{monday_bitcoin_accuracy:.1%} mit Bitcoin**; die Bitcoin-Variante
erreicht dort **{monday_bitcoin_balanced:.1%} Balanced Accuracy**. Die
längeren Wochenendfenster widersprechen dem Gesamtergebnis somit nicht.
Es ist dennoch kein finaler Beweis: Die Modellparameter sind bewusst
einfach, weitere Modellklassen fehlen, und der Holdout 2026 bleibt
unangetastet.
        '''
    )
)
```

Interpretation

Die Kontrollvariante erreicht **52.4% Accuracy** und **51.5% Balanced Accuracy**. Mit den fünf Bitcoin-Merkmalen steigen die Werte auf **60.7%** und **59.6%**. Der direkte Zusatz beträgt damit **8.3%-Punkte bei Accuracy** und **8.0%-Punkte bei Balanced Accuracy**.

Die Bitcoin-Variante prognostiziert in **62.2%** der Fälle positiv und erkennt somit beide Klassen. Sie übertrifft die Kontrollvariante in **5 von 5 Validierungsjahren** bei der Accuracy. Das ist ein konsistenter Out-of-sample-Hinweis auf zusätzlichen Informationsgehalt der BTC-Overnight-Merkmale innerhalb der logistischen Regression.

An den **231 Montagen** steigt die Accuracy von **43.7% ohne Bitcoin** auf **61.0% mit Bitcoin**; die Bitcoin-Variante erreicht dort **60.6% Balanced Accuracy**. Die längeren Wochenendfenster widersprechen dem Gesamtergebnis somit nicht. Es ist dennoch kein finaler Beweis: Die Modellparameter sind bewusst einfach, weitere Modellklassen fehlen, und der Holdout 2026 bleibt unangetastet.

10. XGBoost

10.1 Methode und Walk-forward-Training

Erklärung

XGBoost kombiniert viele kleine Entscheidungsbäume schrittweise zu einem nichtlinearen Klassifikationsmodell. In Iteration m wird ein neuer Baum f_m ergänzt, der die bisherigen Fehler reduziert:

$$\widehat{p}_t^{(m)} = \sigma\left(\sum_{k=1}^{m} \eta f_k(x_t)\right), \qquad \sigma(a) = \frac{1}{1+e^{-a}}.$$

Die Lernrate η begrenzt den Beitrag jedes neuen Baums. Unsere Bäume bleiben mit Tiefe 2 bewusst flach. Subsampling, Spaltenauswahl und Regularisierung reduzieren das Overfitting bei der begrenzten Datenmenge.

Analog zur logistischen Regression vergleichen wir:

1. **XGBoost Kontrolle:** QQQ, Fear & Greed, VIX, DXY, Montag-Indikator und Fensterlänge.
2. **XGBoost + Bitcoin:** dieselben Variablen plus die fünf BTC-Overnight-Merkmale.

Vor jedem Validierungstag wird das Modell auf allen früheren Beobachtungen neu geschätzt. Das Verhältnis negativer zu positiver Trainingsbeobachtungen bestimmt dabei `scale_pos_weight` ausschließlich aus der jeweiligen Historie:

$$w_{+,t} = \frac{N_{-,train,t}}{N_{+,train,t}}.$$

Wir verwenden feste konservative Parameter und keine Hyperparametersuche. XGBoost nutzt auf Apple Silicon die optimierte CPU-Implementierung `tree_method="hist"`; MPS wird von XGBoost nicht benötigt. Der Holdout ab 2026 wird in diesem Entwicklungsabschnitt nicht verwendet.

```
from xgboost import XGBClassifier

XGBOOST_MODEL_FEATURES = {
    "XGBoost Kontrolle": CONTROL_FEATURES,
    "XGBoost + Bitcoin": FULL_FEATURES,
}
XGBOOST_PARAMETERS = {
    "n_estimators": 150,
    "max_depth": 2,
    "learning_rate": 0.04,
    "min_child_weight": 10,
    "subsample": 0.80,
    "colsample_bytree": 0.80,
    "reg_alpha": 0.10,
    "reg_lambda": 5.0,
    "gamma": 0.05,
    "objective": "binary:logistic",
    "eval_metric": "logloss",
    "tree_method": "hist",
    "n_jobs": -1,
    "random_state": RANDOM_SEED,
    "verbosity": 0,
}

xgboost_rows = []
for model_name, feature_columns in XGBOOST_MODEL_FEATURES.items():
    for validation_year in VALIDATION_YEARS:
        validation_fold = development_data[
            development_data["target_session_date"].dt.year
            == validation_year
        ]

        for _, observation in validation_fold.iterrows():
            forecast_date = observation["target_session_date"]
            training_history = development_data[
                development_data["target_session_date"] < forecast_date
            ]

            # Derive class weighting from the current historical window only
            positive_count = training_history[CLASSIFICATION_TARGET].sum()
            negative_count = len(training_history) - positive_count
            scale_pos_weight = negative_count / positive_count

            # Fit one deterministic model using only information known at t
            classifier = XGBClassifier(
                **XGBOOST_PARAMETERS,
                scale_pos_weight=scale_pos_weight,
            )
            classifier.fit(
                training_history[feature_columns],
                training_history[CLASSIFICATION_TARGET],
            )
```

```
            forecast_features = (
                observation[feature_columns].to_frame().T.astype(float)
            )
            positive_probability = classifier.predict_proba(
                forecast_features
            )[0, 1]
            prediction = int(positive_probability >= 0.5)

            xgboost_rows.append(
                {
                    "model": model_name,
                    "fold_year": validation_year,
                    "forecast_date": forecast_date,
                    "train_start": training_history[
                        "target_session_date"
                    ].min(),
                    "train_end": training_history[
                        "target_session_date"
                    ].max(),
                    "train_size": len(training_history),
                    "train_positive_rate": training_history[
                        CLASSIFICATION_TARGET
                    ].mean(),
                    "scale_pos_weight": scale_pos_weight,
                    "positive_probability": positive_probability,
                    "prediction": prediction,
                    "actual": observation[CLASSIFICATION_TARGET],
                    "target_is_monday": observation["target_is_monday"],
                }
            )

xgboost_predictions = pd.DataFrame(xgboost_rows).sort_values(
    ["model", "forecast_date"]
).reset_index(drop=True)

# Validate identical dates, labels, chronology and probability bounds
expected_forecast_dates = majority_predictions["forecast_date"].tolist()
for model_name in XGBOOST_MODEL_FEATURES:
    model_predictions = xgboost_predictions[
        xgboost_predictions["model"] == model_name
    ]
    assert len(model_predictions) == len(majority_predictions)
    assert model_predictions["forecast_date"].tolist() == expected_forecast_dates
    assert model_predictions["actual"].tolist() == majority_predictions[
        "actual"
    ].tolist()
    assert (
        model_predictions["train_end"]
        < model_predictions["forecast_date"]
    ).all()

assert (xgboost_predictions["forecast_date"] < HOLDOUT_START).all()
assert xgboost_predictions["positive_probability"].between(0, 1).all()
```

```
assert xgboost_predictions["prediction"].isin([0, 1]).all()
assert xgboost_predictions["scale_pos_weight"].gt(0).all()

xgboost_predictions = add_classifier_margin_columns(xgboost_predictions)

# Save one forecast-level audit trail for both XGBoost variants
xgboost_output_path = (
    PROCESSED_DATA_DIR / "btc_overnight_qqq_xgboost_backtest.csv"
)
xgboost_predictions.to_csv(xgboost_output_path, index=False)

xgboost_preview = xgboost_predictions.groupby(
    "model", observed=False, sort=False
).head(3).copy()
xgboost_numeric = xgboost_preview.select_dtypes(include="number").columns
xgboost_preview[xgboost_numeric] = xgboost_preview[
    xgboost_numeric
].round(3)
display(xgboost_preview)
```

	model	fold_year	forecast_date	train_start	train_end	train_size	train_positive_rate	scale_pos_we
0	XGBoost + Bitcoin	2021	2021-01-04	2018-03-05	2020-12-31	697	0.590	0.696
1	XGBoost + Bitcoin	2021	2021-01-05	2018-03-05	2021-01-04	698	0.590	0.694
2	XGBoost + Bitcoin	2021	2021-01-06	2018-03-05	2021-01-05	699	0.589	0.697
1248	XGBoost Kontrolle	2021	2021-01-04	2018-03-05	2020-12-31	697	0.590	0.696
1249	XGBoost Kontrolle	2021	2021-01-05	2018-03-05	2021-01-04	698	0.590	0.694
1250	XGBoost Kontrolle	2021	2021-01-06	2018-03-05	2021-01-05	699	0.589	0.697

```
# Confirm the expanding training window and fixed configuration
xgboost_handoff = (
    xgboost_predictions.groupby("model", observed=False, sort=False)
    .agg(
        Prognosen=("forecast_date", "size"),
        Erste_Prognose=("forecast_date", "min"),
        Letzte_Prognose=("forecast_date", "max"),
        Erstes_Training=("train_size", "min"),
        Letztes_Training=("train_size", "max"),
```

```
        Min_Klassengewicht=("scale_pos_weight", "min"),
        Max_Klassengewicht=("scale_pos_weight", "max"),
    )
    .reset_index()
)

parameter_display = pd.DataFrame(
    {
        "Parameter": [
            "Bäume",
            "Maximale Tiefe",
            "Lernrate",
            "Zeilenanteil pro Baum",
            "Feature-Anteil pro Baum",
            "L1-Regularisierung",
            "L2-Regularisierung",
        ],
        "Wert": [
            XGBOOST_PARAMETERS["n_estimators"],
            XGBOOST_PARAMETERS["max_depth"],
            XGBOOST_PARAMETERS["learning_rate"],
            XGBOOST_PARAMETERS["subsample"],
            XGBOOST_PARAMETERS["colsample_bytree"],
            XGBOOST_PARAMETERS["reg_alpha"],
            XGBOOST_PARAMETERS["reg_lambda"],
        ],
    }
)

xgboost_handoff_display = xgboost_handoff.copy()
# Round only numeric columns and preserve the date columns unchanged
xgboost_handoff_numeric = xgboost_handoff_display.select_dtypes(
    include="number"
).columns
xgboost_handoff_display[xgboost_handoff_numeric] = xgboost_handoff_display[
    xgboost_handoff_numeric
].round(3)
display(xgboost_handoff_display)
display(parameter_display)
display(
    Markdown(
        f'''
### Interpretation

Beide XGBoost-Varianten erzeugen dieselben
**{len(majority_predictions)} Prognosetermine** wie die bisherigen Modelle.
Das Training wächst von **{int(xgboost_handoff['Erstes_Training'].min())}**
auf **{int(xgboost_handoff['Letztes_Training'].max())} Beobachtungen**.
Das positive Klassengewicht wird für jeden Prognosetag neu aus der
Trainingshistorie berechnet; Validierungslabels und der Holdout beeinflussen
es nicht.
        '''
```

```
    )
)
```

	model	Prognosen	Erste_Prognose	Letzte_Prognose	Erstes_Training	Letztes_Training	Min_Klassengev
0	XGBoost + Bitcoin	1248	2021-01-04	2025-12-31	697	1944	0.683
1	XGBoost Kontrolle	1248	2021-01-04	2025-12-31	697	1944	0.683

	Parameter	Wert
0	Bäume	150.00
1	Maximale Tiefe	2.00
2	Lernrate	0.04
3	Zeilenanteil pro Baum	0.80
4	Feature-Anteil pro Baum	0.80
5	L1-Regularisierung	0.10
6	L2-Regularisierung	5.00

Interpretation

Beide XGBoost-Varianten erzeugen dieselben **1248 Prognosetermine** wie die bisherigen Modelle. Das Training wächst von **697** auf **1944 Beobachtungen**. Das positive Klassengewicht wird für jeden Prognosetag neu aus der Trainingshistorie berechnet; Validierungslabels und der Holdout beeinflussen es nicht.

10.2 Ergebnisse und Bitcoin-Zusatznutzen

Erklärung

Wir bewerten XGBoost auf denselben Prognoseterminen und mit denselben Metriken wie die Mehrheitsklasse und die logistische Regression. Entscheidend bleibt zuerst der direkte Vergleich zwischen `XGBoost Kontrolle` und `XGBoost + Bitcoin`. Erst danach vergleichen wir die Modellklassen.

Die Feature-Importance zeigt ergänzend, welche Variablen XGBoost beim Aufbau der Bäume verwendet. Sie ist eine deskriptive Modellinterpretation und weder ein Kausalitätsnachweis noch allein ein Beleg für Prognosewert.

```
# Combine all completed models on the identical validation dates
all_comparison_predictions = pd.concat(
    [
        comparison_predictions,
        xgboost_predictions[
            [
                "model",
                "fold_year",
```

```
                "forecast_date",
                "prediction",
                "actual",
                "target_is_monday",
            ]
        ],
    ],
    ignore_index=True,
)

all_model_order = [
    "Historische Mehrheitsklasse",
    "Logistische Regression Kontrolle",
    "Logistische Regression + Bitcoin",
    "XGBoost Kontrolle",
    "XGBoost + Bitcoin",
]

all_overall_metrics = (
    all_comparison_predictions.groupby("model", observed=False, sort=False)
    .apply(summarize_classification, include_groups=False)
    .reindex(all_model_order)
    .reset_index()
)

xgboost_year_metrics = (
    xgboost_predictions.groupby(
        ["model", "fold_year"], observed=False, sort=False
    )
    .apply(summarize_classification, include_groups=False)
    .reset_index()
    .rename(columns={"fold_year": "Validierungsjahr"})
)

xgboost_scope_rows = []
for model_name in XGBOOST_MODEL_FEATURES:
    model_predictions = xgboost_predictions[
        xgboost_predictions["model"] == model_name
    ]
    for scope_name, scope_frame in [
        ("Alle Handelstage", model_predictions),
        (
            "Montage",
            model_predictions[model_predictions["target_is_monday"] == 1],
        ),
        (
            "Dienstag bis Freitag",
            model_predictions[model_predictions["target_is_monday"] == 0],
        ),
    ]:
        metrics = summarize_classification(scope_frame).to_dict()
        xgboost_scope_rows.append(
            {"Modell": model_name, "Teilmenge": scope_name, **metrics}
```

```
        )

xgboost_scope_metrics = pd.DataFrame(xgboost_scope_rows)

display(all_overall_metrics.round(3))
display(xgboost_year_metrics.round(3))
display(xgboost_scope_metrics.round(3))
```

	model	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy
0	Historische Mehrheitsklasse	1248.0	0.551	1.000	0.551	0.500
1	Logistische Regression Kontrolle	1248.0	0.551	0.585	0.524	0.515
2	Logistische Regression + Bitcoin	1248.0	0.551	0.622	0.607	0.596
3	XGBoost Kontrolle	1248.0	0.551	0.557	0.531	0.526
4	XGBoost + Bitcoin	1248.0	0.551	0.591	0.633	0.625

	model	Validierungsjahr	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy
0	XGBoost + Bitcoin	2021	246.0	0.581	0.618	0.573	0.555
1	XGBoost + Bitcoin	2022	251.0	0.454	0.534	0.657	0.662
2	XGBoost + Bitcoin	2023	249.0	0.526	0.582	0.558	0.554
3	XGBoost + Bitcoin	2024	252.0	0.599	0.647	0.659	0.635
4	XGBoost + Bitcoin	2025	250.0	0.596	0.576	0.716	0.709
5	XGBoost Kontrolle	2021	246.0	0.581	0.593	0.533	0.518
6	XGBoost Kontrolle	2022	251.0	0.454	0.498	0.558	0.558
7	XGBoost Kontrolle	2023	249.0	0.526	0.570	0.466	0.462
8	XGBoost Kontrolle	2024	252.0	0.599	0.587	0.552	0.536
9	XGBoost Kontrolle	2025	250.0	0.596	0.536	0.548	0.543

	Modell	Teilmenge	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy
0	XGBoost Kontrolle	Alle Handelstage	1248.0	0.551	0.557	0.531	0.526

	Modell	Teilmenge	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy
1	XGBoost Kontrolle	Montage	231.0	0.558	0.481	0.481	0.483
2	XGBoost Kontrolle	Dienstag bis Freitag	1017.0	0.550	0.574	0.543	0.536
3	XGBoost + Bitcoin	Alle Handelstage	1248.0	0.551	0.591	0.633	0.625
4	XGBoost + Bitcoin	Montage	231.0	0.558	0.502	0.641	0.642
5	XGBoost + Bitcoin	Dienstag bis Freitag	1017.0	0.550	0.612	0.631	0.621

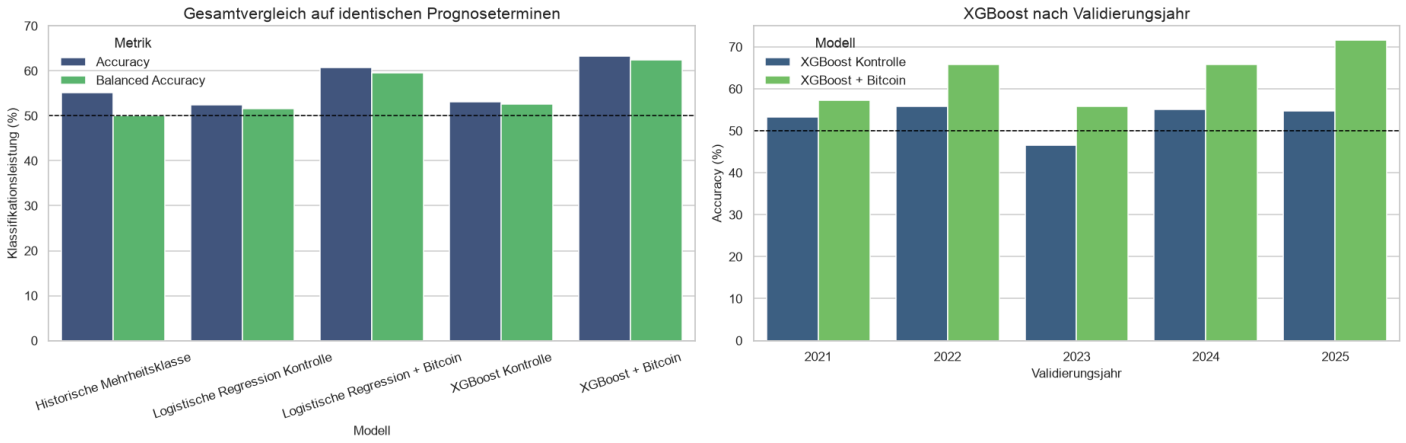
```
# Plot overall model performance and annual XGBoost stability
overall_xgboost_plot = all_overall_metrics.melt(
    id_vars="model",
    value_vars=["Accuracy", "Balanced Accuracy"],
    var_name="Metrik",
    value_name="Wert",
)
overall_xgboost_plot["Wert (%)"] = 100 * overall_xgboost_plot["Wert"]

fig, axes = plt.subplots(1, 2, figsize=(17, 5.5))
sns.barplot(
    data=overall_xgboost_plot,
    x="model",
    y="Wert (%)",
    hue="Metrik",
    order=all_model_order,
    palette=[VIRIDIS(0.25), VIRIDIS(0.72)],
    ax=axes[0],
)
axes[0].axhline(50, color="black", linewidth=1, linestyle="--")
axes[0].set_ylim(0, 70)
axes[0].set_title("Gesamtvergleich auf identischen Prognoseterminen")
axes[0].set_xlabel("Modell")
axes[0].set_ylabel("Klassifikationsleistung (%)")
axes[0].tick_params(axis="x", rotation=18)
axes[0].legend(title="Metrik")

yearly_xgboost_plot = xgboost_year_metrics.copy()
yearly_xgboost_plot["Accuracy (%)"] = 100 * yearly_xgboost_plot["Accuracy"]
sns.barplot(
    data=yearly_xgboost_plot,
    x="Validierungsjahr",
    y="Accuracy (%)",
    hue="model",
    hue_order=["XGBoost Kontrolle", "XGBoost + Bitcoin"],
    palette=[VIRIDIS(0.30), VIRIDIS(0.78)],
    ax=axes[1],
```

```
)
axes[1].axhline(50, color="black", linewidth=1, linestyle="--")
axes[1].set_ylim(0, 75)
axes[1].set_title("XGBoost nach Validierungsjahr")
axes[1].set_xlabel("Validierungsjahr")
axes[1].set_ylabel("Accuracy (%)")
axes[1].legend(title="Modell")

fig.tight_layout()
plt.show()
```




```
# Fit one descriptive end-of-development model per feature set
development_positive_count = development_data[CLASSIFICATION_TARGET].sum()
development_negative_count = len(development_data) - development_positive_count
development_scale_pos_weight = (
    development_negative_count / development_positive_count
)

importance_rows = []
for model_name, feature_columns in XGBOOST_MODEL_FEATURES.items():
    diagnostic_model = XGBClassifier(
        **XGBOOST_PARAMETERS,
        scale_pos_weight=development_scale_pos_weight,
    )
    diagnostic_model.fit(
        development_data[feature_columns],
        development_data[CLASSIFICATION_TARGET],
    )

    # XGBoost reports normalized gain-based split importance
    for feature_name, importance in zip(
        feature_columns, diagnostic_model.feature_importances_
    ):
        importance_rows.append(
            {
                "model": model_name,
                "Feature": feature_name,
                "Importance": importance,
            }
```

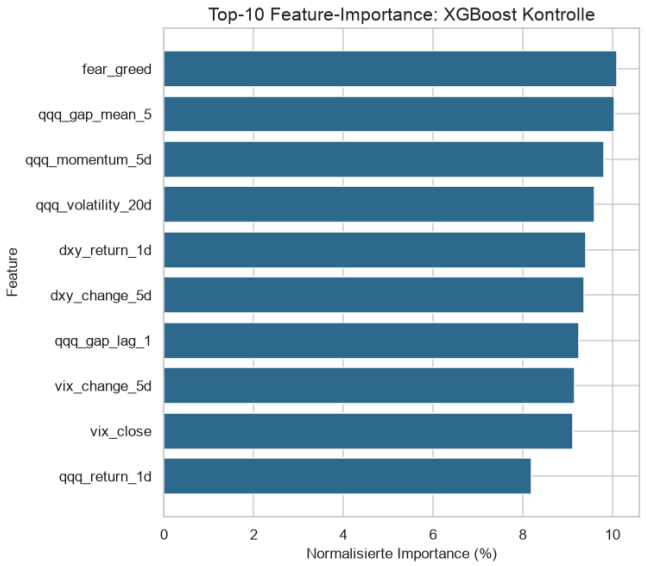
```
        )

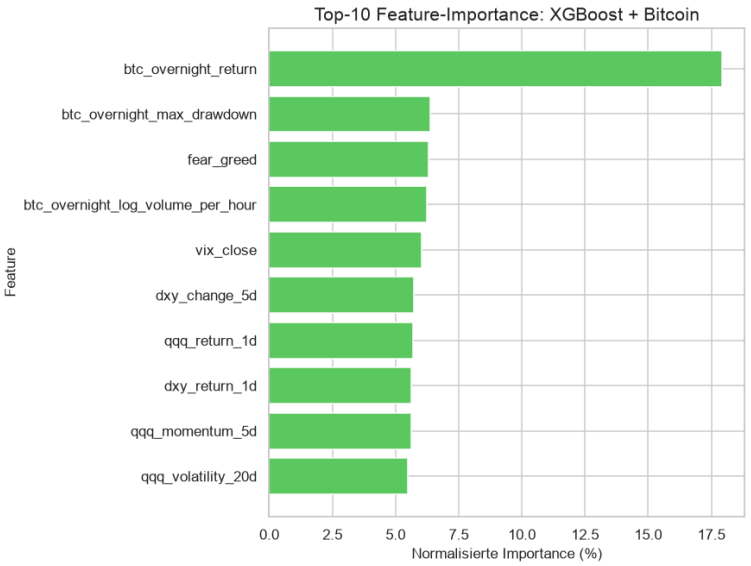
xgboost_importance = pd.DataFrame(importance_rows)
top_importance = (
    xgboost_importance.sort_values(
        ["model", "Importance"], ascending=[True, False]
    )
    .groupby("model", observed=False, sort=False)
    .head(10)
)

fig, axes = plt.subplots(1, 2, figsize=(15, 6.2))
for axis, model_name, color in zip(
    axes,
    ["XGBoost Kontrolle", "XGBoost + Bitcoin"],
    [VIRIDIS(0.35), VIRIDIS(0.75)],
):
    model_importance = top_importance[
        top_importance["model"] == model_name
    ].sort_values("Importance")
    axis.barh(
        model_importance["Feature"],
        100 * model_importance["Importance"],
        color=color,
    )
    axis.set_title(f"Top-10 Feature-Importance: {model_name}")
    axis.set_xlabel("Normalisierte Importance (%)")
    axis.set_ylabel("Feature")

fig.tight_layout()
plt.show()

display(
    xgboost_importance.sort_values(
        ["model", "Importance"], ascending=[True, False]
    )
    .groupby("model", observed=False, sort=False)
    .head(10)
    .assign(Importance=lambda frame: frame["Importance"].round(3))
)
```





	model	Feature	Importance
24	XGBoost + Bitcoin	btc_overnight_return	0.179
28	XGBoost + Bitcoin	btc_overnight_max_drawdown	0.064
17	XGBoost + Bitcoin	fear_greed	0.063
27	XGBoost + Bitcoin	btc_overnight_log_volume_per_hour	0.062
18	XGBoost + Bitcoin	vix_close	0.060
21	XGBoost + Bitcoin	dxy_change_5d	0.057
14	XGBoost + Bitcoin	qqq_return_1d	0.057
20	XGBoost + Bitcoin	dxy_return_1d	0.056
15	XGBoost + Bitcoin	qqq_momentum_5d	0.056
16	XGBoost + Bitcoin	qqq_volatility_20d	0.055
5	XGBoost Kontrolle	fear_greed	0.101
1	XGBoost Kontrolle	qqq_gap_mean_5	0.100
3	XGBoost Kontrolle	qqq_momentum_5d	0.098
4	XGBoost Kontrolle	qqq_volatility_20d	0.096
8	XGBoost Kontrolle	dxy_return_1d	0.094
9	XGBoost Kontrolle	dxy_change_5d	0.094
0	XGBoost Kontrolle	qqq_gap_lag_1	0.092
7	XGBoost Kontrolle	vix_change_5d	0.092
6	XGBoost Kontrolle	vix_close	0.091
2	XGBoost Kontrolle	qqq_return_1d	0.082

```
# Derive the interpretation from the executed XGBoost predictions
xgboost_overall = all_overall_metrics.set_index("model")
xgb_control_accuracy = xgboost_overall.loc[
    "XGBoost Kontrolle", "Accuracy"
]
```

```
xgb_bitcoin_accuracy = xgboost_overall.loc[
    "XGBoost + Bitcoin", "Accuracy"
]
xgb_control_balanced = xgboost_overall.loc[
    "XGBoost Kontrolle", "Balanced Accuracy"
]
xgb_bitcoin_balanced = xgboost_overall.loc[
    "XGBoost + Bitcoin", "Balanced Accuracy"
]
logistic_bitcoin_accuracy = xgboost_overall.loc[
    "Logistische Regression + Bitcoin", "Accuracy"
]
logistic_bitcoin_balanced = xgboost_overall.loc[
    "Logistische Regression + Bitcoin", "Balanced Accuracy"
]
xgb_bitcoin_positive_rate = xgboost_overall.loc[
    "XGBoost + Bitcoin", "Positivrate Prognose"
]

xgboost_year_pivot = xgboost_year_metrics.pivot(
    index="Validierungsjahr", columns="model", values="Accuracy"
)
xgboost_bitcoin_year_wins = int(
    (
        xgboost_year_pivot["XGBoost + Bitcoin"]
        > xgboost_year_pivot["XGBoost Kontrolle"]
    ).sum()
)

xgboost_scope_indexed = xgboost_scope_metrics.set_index(
    ["Modell", "Teilmenge"]
)
xgb_monday_control_accuracy = xgboost_scope_indexed.loc[
    ("XGBoost Kontrolle", "Montage"), "Accuracy"
]
xgb_monday_bitcoin_accuracy = xgboost_scope_indexed.loc[
    ("XGBoost + Bitcoin", "Montage"), "Accuracy"
]
xgb_monday_bitcoin_balanced = xgboost_scope_indexed.loc[
    ("XGBoost + Bitcoin", "Montage"), "Balanced Accuracy"
]

bitcoin_feature_names = set(FULL_FEATURES) - set(CONTROL_FEATURES)
bitcoin_importance_share = xgboost_importance.loc[
    (xgboost_importance["model"] == "XGBoost + Bitcoin")
    & xgboost_importance["Feature"].isin(bitcoin_feature_names),
    "Importance",
].sum()
top_bitcoin_feature_row = (
    xgboost_importance.loc[
        (xgboost_importance["model"] == "XGBoost + Bitcoin")
        & xgboost_importance["Feature"].isin(bitcoin_feature_names)
    ]
```

```
    .sort_values("Importance", ascending=False)
    .iloc[0]
)

display(
    Markdown(
        f'''
### Interpretation

Die XGBoost-Kontrollvariante erreicht **{xgb_control_accuracy:.1%}
Accuracy** und **{xgb_control_balanced:.1%} Balanced Accuracy**. Mit den
Bitcoin-Merkmalen ergeben sich **{xgb_bitcoin_accuracy:.1%} Accuracy** und
**{xgb_bitcoin_balanced:.1%} Balanced Accuracy**. Der direkte Bitcoin-Zusatz
beträgt damit **{100 * (xgb_bitcoin_accuracy - xgb_control_accuracy):.1f}
Prozentpunkte bei Accuracy** und
**{100 * (xgb_bitcoin_balanced - xgb_control_balanced):.1f} Prozentpunkte bei
Balanced Accuracy**. Die Bitcoin-Variante prognostiziert in
**{xgb_bitcoin_positive_rate:.1%}** der Fälle positiv und erkennt beide Klassen.

Sie übertrifft die XGBoost-Kontrollvariante in
**{xgboost_bitcoin_year_wins} von {len(VALIDATION_YEARS)}
Validierungsjahren**. Gegenüber der logistischen Bitcoin-Variante verändert
sich die Accuracy um
**{100 * (xgb_bitcoin_accuracy - logistic_bitcoin_accuracy):+.1f}
Prozentpunkte** und die Balanced Accuracy um
**{100 * (xgb_bitcoin_balanced - logistic_bitcoin_balanced):+.1f}
Prozentpunkte**. Damit
prüfen wir, ob nichtlineare Bäume über den bereits beobachteten linearen
Bitcoin-Zusammenhang hinausgehen.

An Montagen verändert Bitcoin die XGBoost-Accuracy von
**{xgb_monday_control_accuracy:.1%}** auf **{xgb_monday_bitcoin_accuracy:.1%}**;
die Bitcoin-Variante erreicht **{xgb_monday_bitcoin_balanced:.1%} Balanced
Accuracy**. Im deskriptiven Endmodell entfallen zusammen
**{bitcoin_importance_share:.1%} der normalisierten Importance** auf die fünf
BTC-Merkmale; davon ist **`{top_bitcoin_feature_row['Feature']}`** am höchsten
gewichtet. Diese Importance beschreibt die Nutzung durch das Modell, nicht die
Richtung eines Effekts und keine Kausalität.

Alle Resultate stammen weiterhin ausschließlich aus der Walk-forward-
Validierung 2021 bis 2025. Der Holdout 2026 wird erst nach Abschluss der
Modellentwicklung einmalig ausgewertet.
        '''
    )
)
```

Interpretation

Die XGBoost-Kontrollvariante erreicht **53.1% Accuracy** und **52.6% Balanced Accuracy**. Mit den Bitcoin-Merkmalen ergeben sich **63.3% Accuracy** und **62.5% Balanced Accuracy**. Der direkte Bitcoin-Zusatz beträgt damit **10.2 Prozentpunkte bei Accuracy** und **9.9 Prozentpunkte bei Balanced Accuracy**. Die Bitcoin-Variante prognostiziert in **59.1%** der Fälle positiv und erkennt beide Klassen.

Sie übertrifft die XGBoost-Kontrollvariante in **5 von 5 Validierungsjahren**. Gegenüber der logistischen Bitcoin-Variante verändert sich die Accuracy um **+2.6 Prozentpunkte** und die Balanced Accuracy um **+2.9 Prozentpunkte**. Damit prüfen wir, ob nichtlineare Bäume über den bereits beobachteten linearen Bitcoin-Zusammenhang hinausgehen.

An Montagen verändert Bitcoin die XGBoost-Accuracy von **48.1%** auf **64.1%**; die Bitcoin-Variante erreicht **64.2% Balanced Accuracy**. Im deskriptiven Endmodell entfallen zusammen **40.9% der normalisierten Importance** auf die fünf BTC-Merkmale; davon ist `btc_overnight_return` am höchsten gewichtet. Diese Importance beschreibt die Nutzung durch das Modell, nicht die Richtung eines Effekts und keine Kausalität.

Alle Resultate stammen weiterhin ausschließlich aus der Walk-forward- Validierung 2021 bis 2025. Der Holdout 2026 wird erst nach Abschluss der Modellentwicklung einmalig ausgewertet.

11. Chronos-2

11.1 Methode und Zero-shot-Walk-forward-Prognose

Erklärung

Chronos-2 ist ein vortrainiertes Time-Series Foundation Model. Im Gegensatz zur logistischen Regression und zu XGBoost passen wir seine Gewichte nicht an unsere Daten an. Für jeden Validierungstag t erhält das Modell die bis dahin bekannten numerischen QQQ-Gaps:

$$\mathcal{H}_t = (y_1, y_2, \ldots, y_{t-1}).$$

Chronos-2 kann zusätzlich zeitlich ausgerichtete Kovariaten berücksichtigen. Für ein Feature x_j übergeben wir seine bekannten historischen Werte als `past_covariates` und den am Prognose-Cutoff bekannten aktuellen Wert als `future_covariates`:

$$\mathcal{X}_{j,t}^{past} = (x_{j,1}, \ldots, x_{j,t-1}), \qquad \mathcal{X}_{j,t}^{future} = (x_{j,t}).$$

Der QQQ-Gap y_t selbst erscheint nicht in den zukünftigen Kovariaten. Wir vergleichen drei Varianten:

1. **Chronos-2 Zero-shot:** ausschließlich die historische Gap-Zeitreihe.
2. **Chronos-2 Kontrolle:** Gap-Historie und dieselben zwölf Kontrollfeatures wie bei XGBoost.
3. **Chronos-2 + Bitcoin:** Kontrollfeatures plus dieselben fünf BTC-Overnight-Merkmale wie bei XGBoost.

Aus jeder Variante erzeugen wir Quantilprognosen. Die Medianprognose ist der Punktschätzer und bestimmt die Richtung:

$$\hat{y}_t = \widehat{Q}_{0.50,t}, \qquad \widehat{Direction}_t = \mathbb{1}(\hat{y}_t > 0).$$

Zusätzlich bilden $\widehat{Q}_{0.10,t}$ und $\widehat{Q}_{0.90,t}$ ein zentrales 80-%-Prognoseintervall. Wir verwenden dieses Intervall sowohl für die nominale Abdeckung als auch für die richtungsbezogene Unsicherheit: Enthält das Intervall die Nullgrenze, gilt die Prognose als richtungsunsicher.

Wir verwenden für jeden Termin die gesamte verfügbare Historie. Das Batching beschleunigt lediglich die Berechnung; bei `cross_learning=False` werden keine Informationen zwischen Prognoseterminen geteilt. Es findet weder Fine-Tuning noch Hyperparametersuche statt. Auf Apple Silicon verwenden wir MPS, falls es in PyTorch verfügbar ist, ansonsten die CPU. Wegen der kleinen Gap-Werte bleibt die Berechnung in `float32`.

```
import gc
import time

# Suppress the optional notebook-widget warning during model imports
with warnings.catch_warnings():
    warnings.filterwarnings("ignore", message="IProgress not found.*")
    from chronos import Chronos2Pipeline
    from huggingface_hub import snapshot_download
    from huggingface_hub.utils import disable_progress_bars
    from transformers.utils import logging as transformers_logging

# Keep model loading quiet and use the local Hugging Face cache when possible
disable_progress_bars()
transformers_logging.set_verbosity_error()
transformers_logging.disable_progress_bar()

try:
    chronos_model_path = snapshot_download(
        CHRONOS_MODEL_ID,
        local_files_only=True,
    )
except Exception:
    # Download only when the requested model is not available locally
    chronos_model_path = snapshot_download(CHRONOS_MODEL_ID)

CHRONOS_MODEL_FEATURES = {
    "Chronos-2 Zero-shot": [],
    "Chronos-2 Kontrolle": CONTROL_FEATURES,
    "Chronos-2 + Bitcoin": FULL_FEATURES,
}

assert torch is not None, "PyTorch is required for Chronos-2"
if DEVICE == "mps":
    torch.mps.empty_cache()
torch.set_float32_matmul_precision("high")

with warnings.catch_warnings():
    warnings.simplefilter("ignore", category=FutureWarning)
    chronos_pipeline = Chronos2Pipeline.from_pretrained(
        chronos_model_path,
        device_map=DEVICE,
        dtype=torch.float32,
    )

chronos_device_used = str(chronos_pipeline.model.device)
chronos_model_revision = Path(chronos_model_path).name
```

```
chronos_rows = []
chronos_runtime_by_model = {}

for model_name, feature_columns in CHRONOS_MODEL_FEATURES.items():
    chronos_inputs = []
    chronos_metadata = []

    for _, validation_observation in development_data[
        development_data["target_session_date"].dt.year.isin(
            VALIDATION_YEARS
        )
    ].iterrows():
        forecast_date = validation_observation["target_session_date"]
        history = development_data[
            development_data["target_session_date"] < forecast_date
        ]

        target_history = history[NUMERIC_TARGET].to_numpy(dtype=np.float32)
        if feature_columns:
            # Align historical and cutoff-known covariates with the target
            chronos_input = {
                "target": target_history,
                "past_covariates": {
                    feature_name: history[feature_name].to_numpy(
                        dtype=np.float32
                    )
                    for feature_name in feature_columns
                },
                "future_covariates": {
                    feature_name: np.asarray(
                        [validation_observation[feature_name]],
                        dtype=np.float32,
                    )
                    for feature_name in feature_columns
                },
            }
        else:
            chronos_input = target_history

        chronos_inputs.append(chronos_input)
        chronos_metadata.append(
            {
                "model": model_name,
                "fold_year": forecast_date.year,
                "forecast_date": forecast_date,
                "context_start": history["target_session_date"].min(),
                "context_end": history["target_session_date"].max(),
                "context_size": len(history),
                "feature_count": len(feature_columns),
                "actual_gap_log_return": validation_observation[
                    NUMERIC_TARGET
                ],
                "actual_gap_percent": validation_observation[
```

```
                    "qqq_gap_percent"
                ],
                "actual": validation_observation[CLASSIFICATION_TARGET],
                "target_is_monday": validation_observation[
                    "target_is_monday"
                ],
            }
        )

    model_started_at = time.perf_counter()
    # Forecast each date independently while batching the forward passes
    quantile_tensors, median_tensors = chronos_pipeline.predict_quantiles(
        chronos_inputs,
        prediction_length=1,
        quantile_levels=CHRONOS_QUANTILES,
        batch_size=CHRONOS_BATCH_SIZE,
        cross_learning=False,
    )
    chronos_runtime_by_model[model_name] = (
        time.perf_counter() - model_started_at
    )

    for metadata, quantile_tensor, median_tensor in zip(
        chronos_metadata,
        quantile_tensors,
        median_tensors,
    ):
        # Convert one-step univariate tensors to transparent scalar forecasts
        quantiles = quantile_tensor[0, 0].detach().float().cpu().numpy()
        predicted_gap_log_return = float(
            median_tensor[0, 0].detach().float().cpu()
        )

        chronos_rows.append(
            {
                **metadata,
                "q10_gap_log_return": float(quantiles[0]),
                "q50_gap_log_return": float(quantiles[1]),
                "q90_gap_log_return": float(quantiles[2]),
                "predicted_gap_log_return": predicted_gap_log_return,
                "predicted_gap_percent": 100
                * np.expm1(predicted_gap_log_return),
                "prediction": int(predicted_gap_log_return > 0),
            }
        )

chronos_predictions = pd.DataFrame(chronos_rows).sort_values(
    ["model", "forecast_date"]
).reset_index(drop=True)
chronos_predictions["inside_80_interval"] = (
    chronos_predictions["actual_gap_log_return"]
    >= chronos_predictions["q10_gap_log_return"]
) & (
```

```
    chronos_predictions["actual_gap_log_return"]
    <= chronos_predictions["q90_gap_log_return"]
)
chronos_predictions = add_chronos_margin_columns(chronos_predictions)

# Release the foundation model after inference to keep the notebook lightweight
del chronos_pipeline, quantile_tensors, median_tensors
gc.collect()
if DEVICE == "mps":
    torch.mps.empty_cache()

chronos_preview = chronos_predictions.groupby(
    "model", observed=False, sort=False
).head(2).copy()
chronos_numeric = chronos_preview.select_dtypes(include="number").columns
chronos_preview[chronos_numeric] = chronos_preview[chronos_numeric].round(4)
display(chronos_preview)
```

	model	fold_year	forecast_date	context_start	context_end	context_size	feature_count	actual_ga
0	Chronos-2 + Bitcoin	2021	2021-01-04	2018-03-05	2020-12-31	697	17	0.0044
1	Chronos-2 + Bitcoin	2021	2021-01-05	2018-03-05	2021-01-04	698	17	-0.0033
1248	Chronos-2 Kontrolle	2021	2021-01-04	2018-03-05	2020-12-31	697	12	0.0044
1249	Chronos-2 Kontrolle	2021	2021-01-05	2018-03-05	2021-01-04	698	12	-0.0033
2496	Chronos-2 Zero-shot	2021	2021-01-04	2018-03-05	2020-12-31	697	0	0.0044
2497	Chronos-2 Zero-shot	2021	2021-01-05	2018-03-05	2021-01-04	698	0	-0.0033

6 rows × 25 columns

```
# Validate shared dates, chronology, labels and quantile ordering
expected_forecast_dates = majority_predictions["forecast_date"].tolist()
for model_name, feature_columns in CHRONOS_MODEL_FEATURES.items():
    model_predictions = chronos_predictions[
        chronos_predictions["model"] == model_name
    ]
    assert len(model_predictions) == len(majority_predictions)
    assert model_predictions["forecast_date"].tolist() == expected_forecast_dates
    assert model_predictions["actual"].tolist() == majority_predictions[
```

```
        "actual"
    ].tolist()
    assert model_predictions["feature_count"].eq(len(feature_columns)).all()
    assert (
        model_predictions["context_end"]
        < model_predictions["forecast_date"]
    ).all()

assert (chronos_predictions["forecast_date"] < HOLDOUT_START).all()
assert chronos_predictions["prediction"].isin([0, 1]).all()
assert np.isfinite(
    chronos_predictions[
        [
            "q10_gap_log_return",
            "q50_gap_log_return",
            "q90_gap_log_return",
            "predicted_gap_log_return",
        ]
    ].to_numpy()
).all()
assert (
    chronos_predictions["q10_gap_log_return"]
    <= chronos_predictions["q50_gap_log_return"]
).all()
assert (
    chronos_predictions["q50_gap_log_return"]
    <= chronos_predictions["q90_gap_log_return"]
).all()
assert np.allclose(
    chronos_predictions["q50_gap_log_return"],
    chronos_predictions["predicted_gap_log_return"],
)
assert chronos_predictions["prediction"].eq(
    (chronos_predictions["predicted_gap_log_return"] > 0).astype(int)
).all()

# Save one audit trail for all three zero-shot variants
chronos_output_path = (
    PROCESSED_DATA_DIR / "btc_overnight_qqq_chronos2_backtest.csv"
)
chronos_predictions.to_csv(chronos_output_path, index=False)

chronos_handoff = (
    chronos_predictions.groupby("model", observed=False, sort=False)
    .agg(
        Prognosen=("forecast_date", "size"),
        Erste_Prognose=("forecast_date", "min"),
        Letzte_Prognose=("forecast_date", "max"),
        Kleinster_Kontext=("context_size", "min"),
        Grösster_Kontext=("context_size", "max"),
        Features=("feature_count", "first"),
    )
    .reset_index()
```

```
)
chronos_handoff["Laufzeit (Sekunden)"] = chronos_handoff["model"].map(
    chronos_runtime_by_model
)
chronos_handoff["Gerät"] = chronos_device_used

chronos_handoff_display = chronos_handoff.copy()
chronos_handoff_display["Laufzeit (Sekunden)"] = chronos_handoff_display[
    "Laufzeit (Sekunden)"
].round(1)
display(chronos_handoff_display)
display(
    Markdown(
        f'''
### Interpretation

Jede Chronos-2-Variante erzeugt **{len(majority_predictions)} Prognosen** auf
exakt denselben Terminen wie die bisherigen Modelle. Der historische Kontext
wächst jeweils von **{chronos_predictions['context_size'].min()}** auf
**{chronos_predictions['context_size'].max()} bekannte Gaps**. Die Varianten
verwenden **0, {len(CONTROL_FEATURES)} beziehungsweise {len(FULL_FEATURES)}
Kovariaten**. Jeder Kontext endet vor seinem Prognosetag; der aktuelle
Feature-Vektor ist um 09:00 Uhr bekannt, während der QQQ-Open und damit das
Ziel unbekannt bleiben. Daten ab 2026 werden nicht verwendet.
        '''
    )
)
```

	model	Prognosen	Erste_Prognose	Letzte_Prognose	Kleinster_Kontext	Grösster_Kontext	Features	La (S
0	Chronos-2 + Bitcoin	1248	2021-01-04	2025-12-31	697	1944	17	10
1	Chronos-2 Kontrolle	1248	2021-01-04	2025-12-31	697	1944	12	84
2	Chronos-2 Zero-shot	1248	2021-01-04	2025-12-31	697	1944	0	6.3

Interpretation

Jede Chronos-2-Variante erzeugt **1248 Prognosen** auf exakt denselben Terminen wie die bisherigen Modelle. Der historische Kontext wächst jeweils von **697** auf **1944 bekannte Gaps**. Die Varianten verwenden **0, 12 beziehungsweise 17 Kovariaten**. Jeder Kontext endet vor seinem Prognosetag; der aktuelle Feature-Vektor ist um 09:00 Uhr bekannt, während der QQQ-Open und damit das Ziel unbekannt bleiben. Daten ab 2026 werden nicht verwendet.

11.2 Ergebnisse und gemeinsamer Modellvergleich

Erklärung

Die primäre Frage betrifft die Richtung relativ zur Nullgrenze. Deshalb bleiben Accuracy, Balanced Accuracy sowie tatsächliche und prognostizierte Positivrate die methodenübergreifend vergleichbaren Hauptmetriken. Ergänzend beschreiben wir, wie deutlich eine Entscheidung auf der richtigen oder falschen Seite der Grenze liegt.

Die tatsächliche Richtung codieren wir als

$$z_i = \begin{cases} +1, & y_i > 0, \\ -1, & y_i \leq 0. \end{cases}$$

Für Mehrheitsbaseline, logistische Regression und XGBoost zentrieren wir die prognostizierte positive Wahrscheinlichkeit um die Entscheidungsgrenze:

$$s_i = 2p_i - 1.$$

Für Chronos-2 ist der Decision Score der prognostizierte Gap in Prozentpunkten:

$$s_i = \widehat{Gap}_i^{\%}.$$

Die signed margin und die Boundary-L_1-Loss lauten

$$m_i = z_i s_i, \qquad L_i^{boundary} = \max(0, -m_i).$$

Eine positive Margin bezeichnet eine richtige Richtung, eine negative Margin eine falsche Richtung. Werte nahe null liegen an der Entscheidungsgrenze. Ein grosser negativer Wert steht für eine falsche und zugleich deutliche Entscheidung. Die Boundary-Loss ist bei richtiger Richtung null und misst bei einer Fehlklassifikation die Distanz zur Nullgrenze auf der falschen Seite.

Bei den probabilistischen Klassifikatoren kennzeichnen wir $|p_i - 0.5| < 0.10$ als grenznah unsicher. Dies ist eine einfache, vorab festgelegte heuristische Schwelle. Chronos-2 gilt als richtungsunsicher, wenn das bestehende 80-%-Intervall die Null enthält:

$$q_{10,i} \leq 0 \leq q_{90,i}.$$

Die Rohscores besitzen unterschiedliche Einheiten: zentrierte Wahrscheinlichkeiten in $[-1, 1]$ für die Klassifikatoren und Gap-Prozentpunkte für Chronos-2. Wir berichten Margin und Boundary-Loss deshalb getrennt nach Modellfamilie und vergleichen deren numerische Werte nicht direkt. Die nominale Chronos-Intervallabdeckung bleibt als zusätzliche Diagnose erhalten. Es findet keine nachträgliche Schwellenoptimierung statt.

```
def summarize_chronos(frame):
    # Keep shared classification metrics and nominal interval coverage
    return pd.Series(
        {
            "Beobachtungen": len(frame),
            "Positivrate Ziel": frame["actual"].mean(),
            "Positivrate Prognose": frame["prediction"].mean(),
            "Accuracy": accuracy_score(frame["actual"], frame["prediction"]),
            "Balanced Accuracy": balanced_accuracy_score(
```

```
                frame["actual"], frame["prediction"]
            ),
            "Abdeckung 80%-Intervall": frame["inside_80_interval"].mean(),
        }
    )


chronos_overall_metrics = (
    chronos_predictions.groupby("model", observed=False, sort=False)
    .apply(summarize_chronos, include_groups=False)
    .reset_index()
)
chronos_year_metrics = (
    chronos_predictions.groupby(
        ["model", "fold_year"], observed=False, sort=False
    )
    .apply(summarize_chronos, include_groups=False)
    .reset_index()
    .rename(columns={"fold_year": "Validierungsjahr"})
)

chronos_scope_rows = []
for model_name in CHRONOS_MODEL_FEATURES:
    model_predictions = chronos_predictions[
        chronos_predictions["model"] == model_name
    ]
    for scope_name, scope_frame in [
        ("Alle Handelstage", model_predictions),
        (
            "Montage",
            model_predictions[model_predictions["target_is_monday"] == 1],
        ),
        (
            "Dienstag bis Freitag",
            model_predictions[model_predictions["target_is_monday"] == 0],
        ),
    ]:
        chronos_scope_rows.append(
            {
                "Modell": model_name,
                "Teilmenge": scope_name,
                **summarize_chronos(scope_frame).to_dict(),
            }
        )
chronos_scope_metrics = pd.DataFrame(chronos_scope_rows)

# Keep the two score families separate throughout the margin evaluation
classifier_development_margin_predictions = pd.concat(
    [
        majority_predictions[MARGIN_AUDIT_COLUMNS],
        logistic_predictions[MARGIN_AUDIT_COLUMNS],
        xgboost_predictions[MARGIN_AUDIT_COLUMNS],
    ],
```

```
    ignore_index=True,
)
chronos_development_margin_predictions = chronos_predictions[
    MARGIN_AUDIT_COLUMNS
].copy()

classifier_development_margin_metrics = (
    classifier_development_margin_predictions.groupby(
        "model", observed=False, sort=False
    )
    .apply(summarize_margin, include_groups=False)
    .reindex(all_model_order)
    .reset_index()
)
chronos_development_margin_metrics = (
    chronos_development_margin_predictions.groupby(
        "model", observed=False, sort=False
    )
    .apply(summarize_margin, include_groups=False)
    .reindex(list(CHRONOS_MODEL_FEATURES))
    .reset_index()
)

display(chronos_overall_metrics.round(3))
display(chronos_year_metrics.round(3))
display(chronos_scope_metrics.round(3))
display(Markdown("#### Margin-Auswertung: probabilistische Klassifikatoren"))
display(classifier_development_margin_metrics.round(3))
display(Markdown("#### Margin-Auswertung: Chronos-2"))
display(chronos_development_margin_metrics.round(3))
```

	model	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy	Abdeckung 80%-Intervall
0	Chronos-2 + Bitcoin	1248.0	0.551	0.774	0.562	0.535	0.401
1	Chronos-2 Kontrolle	1248.0	0.551	0.813	0.539	0.507	0.374
2	Chronos-2 Zero-shot	1248.0	0.551	0.983	0.546	0.496	0.780

	model	Validierungsjahr	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy	Abdeckung 80%-Intervall
0	Chronos-2 + Bitcoin	2021	246.0	0.581	0.801	0.569	0.521	0.447
1	Chronos-2 + Bitcoin	2022	251.0	0.454	0.773	0.490	0.515	0.315

	model	Validierungsjahr	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy	Abdeckung 80%-Intervall
2	Chronos-2 + Bitcoin	2023	249.0	0.526	0.727	0.558	0.547	0.414
3	Chronos-2 + Bitcoin	2024	252.0	0.599	0.754	0.591	0.543	0.433
4	Chronos-2 + Bitcoin	2025	250.0	0.596	0.816	0.604	0.545	0.396
5	Chronos-2 Kontrolle	2021	246.0	0.581	0.911	0.565	0.498	0.398
6	Chronos-2 Kontrolle	2022	251.0	0.454	0.793	0.438	0.465	0.291
7	Chronos-2 Kontrolle	2023	249.0	0.526	0.759	0.550	0.537	0.394
8	Chronos-2 Kontrolle	2024	252.0	0.599	0.778	0.591	0.538	0.401
9	Chronos-2 Kontrolle	2025	250.0	0.596	0.828	0.552	0.489	0.388
10	Chronos-2 Zero-shot	2021	246.0	0.581	1.000	0.581	0.500	0.801
11	Chronos-2 Zero-shot	2022	251.0	0.454	0.968	0.446	0.489	0.725
12	Chronos-2 Zero-shot	2023	249.0	0.526	0.972	0.522	0.497	0.811
13	Chronos-2 Zero-shot	2024	252.0	0.599	0.988	0.595	0.498	0.802
14	Chronos-2 Zero-shot	2025	250.0	0.596	0.988	0.584	0.490	0.764

	Modell	Teilmenge	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy	Abdeckung 80%-Intervall
0	Chronos-2 Zero-shot	Alle Handelstage	1248.0	0.551	0.983	0.546	0.496	0.780
1	Chronos-2 Zero-shot	Montage	231.0	0.558	0.983	0.567	0.511	0.801
2	Chronos-2 Zero-shot	Dienstag bis Freitag	1017.0	0.550	0.983	0.541	0.493	0.776
3	Chronos-2 Kontrolle	Alle Handelstage	1248.0	0.551	0.813	0.539	0.507	0.374
4	Chronos-2 Kontrolle	Montage	231.0	0.558	0.801	0.541	0.506	0.377
5	Chronos-2 Kontrolle	Dienstag bis Freitag	1017.0	0.550	0.816	0.539	0.508	0.374
6	Chronos-2 + Bitcoin	Alle Handelstage	1248.0	0.551	0.774	0.562	0.535	0.401
7	Chronos-2 + Bitcoin	Montage	231.0	0.558	0.675	0.597	0.578	0.424
8	Chronos-2 + Bitcoin	Dienstag bis Freitag	1017.0	0.550	0.796	0.555	0.525	0.395

Margin-Auswertung: probabilistische Klassifikatoren

	model	Beobachtungen	Scoretyp	Scoreeinheit	Mittlere Boundary-L1-Loss	Median Signed Margin	Anteil negative Signed Margin	Anteil grenzna unsiche
0	Historische Mehrheitsklasse	1248	Probabilistischer Klassifikator	Zentrierte Wahrscheinlichkeit [-1, 1]	0.061	0.104	0.449	1.000
1	Logistische Regression Kontrolle	1248	Probabilistischer Klassifikator	Zentrierte Wahrscheinlichkeit [-1, 1]	0.047	0.007	0.476	0.885
2	Logistische Regression + Bitcoin	1248	Probabilistischer Klassifikator	Zentrierte Wahrscheinlichkeit [-1, 1]	0.054	0.047	0.393	0.704
3	XGBoost Kontrolle	1248	Probabilistischer Klassifikator	Zentrierte Wahrscheinlichkeit [-1, 1]	0.053	0.009	0.469	0.834
4	XGBoost + Bitcoin	1248	Probabilistischer Klassifikator	Zentrierte Wahrscheinlichkeit [-1, 1]	0.063	0.078	0.367	0.567

Margin-Auswertung: Chronos-2

	model	Beobachtungen	Scoretyp	Scoreeinheit	Mittlere Boundary-L1-Loss	Median Signed Margin	Anteil negative Signed Margin	Anteil grenznah unsicher
0	Chronos-2 Zero-shot	1248	Chronos-2	Prognostizierter Gap (Prozentpunkte)	0.040	0.045	0.454	1.000
1	Chronos-2 Kontrolle	1248	Chronos-2	Prognostizierter Gap (Prozentpunkte)	0.072	0.017	0.461	0.832
2	Chronos-2 + Bitcoin	1248	Chronos-2	Prognostizierter Gap (Prozentpunkte)	0.075	0.032	0.438	0.817

```
# Add all Chronos-2 variants to the shared classification comparison
chronos_classification_predictions = chronos_predictions[
    [
        "model",
        "fold_year",
        "forecast_date",
        "prediction",
        "actual",
        "target_is_monday",
    ]
]
final_development_predictions = pd.concat(
    [all_comparison_predictions, chronos_classification_predictions],
    ignore_index=True,
)
final_model_order = [
    *all_model_order,
    "Chronos-2 Zero-shot",
    "Chronos-2 Kontrolle",
    "Chronos-2 + Bitcoin",
]
final_development_metrics = (
    final_development_predictions.groupby(
        "model", observed=False, sort=False
    )
    .apply(summarize_classification, include_groups=False)
    .reindex(final_model_order)
    .reset_index()
)

final_metric_plot = final_development_metrics.melt(
    id_vars="model",
    value_vars=["Accuracy", "Balanced Accuracy"],
    var_name="Metrik",
    value_name="Wert",
)
```

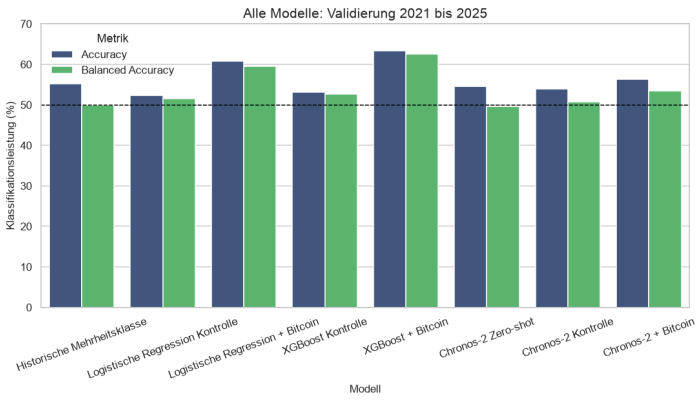
```
final_metric_plot["Wert (%)"] = 100 * final_metric_plot["Wert"]

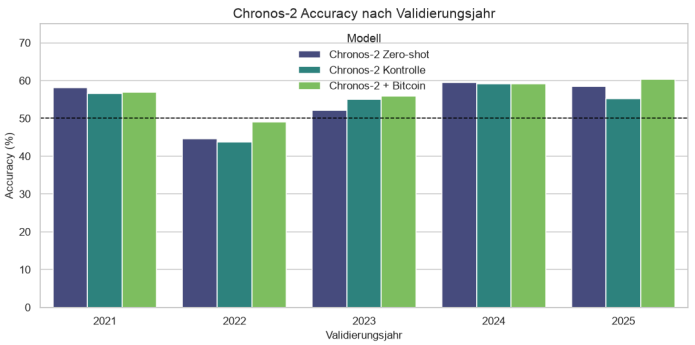
fig, axes = plt.subplots(1, 2, figsize=(20, 5.8))
sns.barplot(
    data=final_metric_plot,
    x="model",
    y="Wert (%)",
    hue="Metrik",
    order=final_model_order,
    palette=[VIRIDIS(0.25), VIRIDIS(0.72)],
    ax=axes[0],
)
axes[0].axhline(50, color="black", linewidth=1, linestyle="--")
axes[0].set_ylim(0, 70)
axes[0].set_title("Alle Modelle: Validierung 2021 bis 2025")
axes[0].set_xlabel("Modell")
axes[0].set_ylabel("Klassifikationsleistung (%)")
axes[0].tick_params(axis="x", rotation=20)
axes[0].legend(title="Metrik")

chronos_accuracy_plot = chronos_year_metrics.copy()
chronos_accuracy_plot["Accuracy (%)"] = (
    100 * chronos_accuracy_plot["Accuracy"]
)
sns.barplot(
    data=chronos_accuracy_plot,
    x="Validierungsjahr",
    y="Accuracy (%)",
    hue="model",
    hue_order=list(CHRONOS_MODEL_FEATURES),
    palette=[VIRIDIS(0.20), VIRIDIS(0.50), VIRIDIS(0.80)],
    ax=axes[1],
)
axes[1].axhline(50, color="black", linewidth=1, linestyle="--")
axes[1].set_ylim(0, 75)
axes[1].set_title("Chronos-2 Accuracy nach Validierungsjahr")
axes[1].set_xlabel("Validierungsjahr")
axes[1].set_ylabel("Accuracy (%)")
axes[1].legend(title="Modell")

fig.tight_layout()
plt.show()

display(final_development_metrics.round(3))
```





	model	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy
0	Historische Mehrheitsklasse	1248.0	0.551	1.000	0.551	0.500
1	Logistische Regression Kontrolle	1248.0	0.551	0.585	0.524	0.515
2	Logistische Regression + Bitcoin	1248.0	0.551	0.622	0.607	0.596
3	XGBoost Kontrolle	1248.0	0.551	0.557	0.531	0.526
4	XGBoost + Bitcoin	1248.0	0.551	0.591	0.633	0.625
5	Chronos-2 Zero-shot	1248.0	0.551	0.983	0.546	0.496
6	Chronos-2 Kontrolle	1248.0	0.551	0.813	0.539	0.507
7	Chronos-2 + Bitcoin	1248.0	0.551	0.774	0.562	0.535

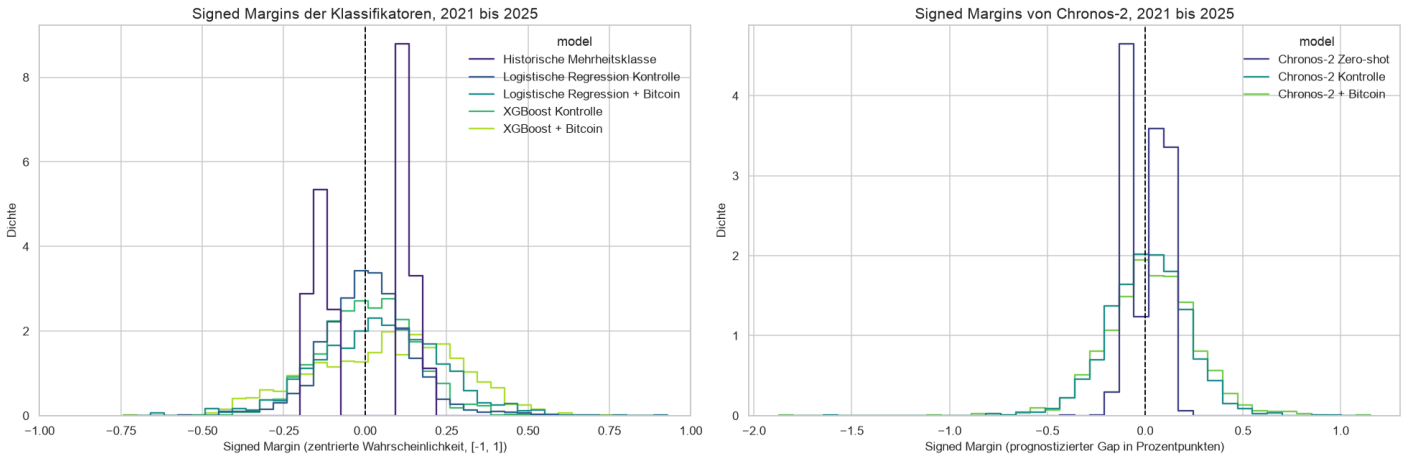
```
# Compare signed-margin distributions without mixing score scales
fig, axes = plt.subplots(1, 2, figsize=(18, 6), sharex=False, sharey=False)

sns.histplot(
    data=classifier_development_margin_predictions,
    x="signed_margin",
    hue="model",
    hue_order=all_model_order,
    stat="density",
    common_norm=False,
    element="step",
    fill=False,
    bins=40,
    palette=[VIRIDIS(value) for value in np.linspace(0.12, 0.88, 5)],
    ax=axes[0],
)
axes[0].axvline(0, color="black", linewidth=1.2, linestyle="--")
axes[0].set_xlim(-1, 1)
axes[0].set_title("Signed Margins der Klassifikatoren, 2021 bis 2025")
axes[0].set_xlabel("Signed Margin (zentrierte Wahrscheinlichkeit, [-1, 1])")
axes[0].set_ylabel("Dichte")

sns.histplot(
    data=chronos_development_margin_predictions,
```

```
    x="signed_margin",
    hue="model",
    hue_order=list(CHRONOS_MODEL_FEATURES),
    stat="density",
    common_norm=False,
    element="step",
    fill=False,
    bins=40,
    palette=[VIRIDIS(0.20), VIRIDIS(0.50), VIRIDIS(0.80)],
    ax=axes[1],
)
axes[1].axvline(0, color="black", linewidth=1.2, linestyle="--")
axes[1].set_title("Signed Margins von Chronos-2, 2021 bis 2025")
axes[1].set_xlabel("Signed Margin (prognostizierter Gap in Prozentpunkten)")
axes[1].set_ylabel("Dichte")

fig.tight_layout()
plt.show()
```




```
# Derive conclusions only from executed forecast-level results
chronos_overall_indexed = chronos_overall_metrics.set_index("model")
chronos_zero_accuracy = chronos_overall_indexed.loc[
    "Chronos-2 Zero-shot", "Accuracy"
]
chronos_zero_balanced = chronos_overall_indexed.loc[
    "Chronos-2 Zero-shot", "Balanced Accuracy"
]
chronos_control_accuracy = chronos_overall_indexed.loc[
    "Chronos-2 Kontrolle", "Accuracy"
]
chronos_control_balanced = chronos_overall_indexed.loc[
    "Chronos-2 Kontrolle", "Balanced Accuracy"
]
chronos_bitcoin_accuracy = chronos_overall_indexed.loc[
    "Chronos-2 + Bitcoin", "Accuracy"
]
chronos_bitcoin_balanced = chronos_overall_indexed.loc[
    "Chronos-2 + Bitcoin", "Balanced Accuracy"
]
```

```
chronos_bitcoin_positive_rate = chronos_overall_indexed.loc[
    "Chronos-2 + Bitcoin", "Positivrate Prognose"
]
chronos_zero_coverage = chronos_overall_indexed.loc[
    "Chronos-2 Zero-shot", "Abdeckung 80%-Intervall"
]
chronos_control_coverage = chronos_overall_indexed.loc[
    "Chronos-2 Kontrolle", "Abdeckung 80%-Intervall"
]
chronos_bitcoin_coverage = chronos_overall_indexed.loc[
    "Chronos-2 + Bitcoin", "Abdeckung 80%-Intervall"
]

chronos_year_accuracy = chronos_year_metrics.pivot(
    index="Validierungsjahr", columns="model", values="Accuracy"
)
chronos_bitcoin_year_wins = int(
    (
        chronos_year_accuracy["Chronos-2 + Bitcoin"]
        > chronos_year_accuracy["Chronos-2 Kontrolle"]
    ).sum()
)
chronos_bitcoin_year_ties = int(
    np.isclose(
        chronos_year_accuracy["Chronos-2 + Bitcoin"],
        chronos_year_accuracy["Chronos-2 Kontrolle"],
    ).sum()
)

final_metrics_indexed = final_development_metrics.set_index("model")
xgboost_bitcoin_accuracy = final_metrics_indexed.loc[
    "XGBoost + Bitcoin", "Accuracy"
]
xgboost_bitcoin_balanced = final_metrics_indexed.loc[
    "XGBoost + Bitcoin", "Balanced Accuracy"
]

classifier_margin_indexed = classifier_development_margin_metrics.set_index(
    "model"
)
chronos_margin_indexed = chronos_development_margin_metrics.set_index("model")
xgboost_bitcoin_boundary = classifier_margin_indexed.loc[
    "XGBoost + Bitcoin", "Mittlere Boundary-L1-Loss"
]
xgboost_bitcoin_median_margin = classifier_margin_indexed.loc[
    "XGBoost + Bitcoin", "Median Signed Margin"
]
xgboost_bitcoin_negative_margin = classifier_margin_indexed.loc[
    "XGBoost + Bitcoin", "Anteil negative Signed Margin"
]
xgboost_bitcoin_uncertain = classifier_margin_indexed.loc[
    "XGBoost + Bitcoin", "Anteil grenznah unsicher"
]
```

```
chronos_bitcoin_boundary = chronos_margin_indexed.loc[
    "Chronos-2 + Bitcoin", "Mittlere Boundary-L1-Loss"
]
chronos_bitcoin_median_margin = chronos_margin_indexed.loc[
    "Chronos-2 + Bitcoin", "Median Signed Margin"
]
chronos_bitcoin_negative_margin = chronos_margin_indexed.loc[
    "Chronos-2 + Bitcoin", "Anteil negative Signed Margin"
]
chronos_bitcoin_uncertain = chronos_margin_indexed.loc[
    "Chronos-2 + Bitcoin", "Anteil grenznah unsicher"
]

display(
    Markdown(
        f'''### Interpretation

Die reine Zero-shot-Variante erreicht **{chronos_zero_accuracy:.1%} Accuracy**
und **{chronos_zero_balanced:.1%} Balanced Accuracy**. Mit den Kontrollfeatures
ergeben sich **{chronos_control_accuracy:.1%}** und
**{chronos_control_balanced:.1%}**. Nach Ergänzung der fünf Bitcoin-Merkmale
erreicht Chronos-2 **{chronos_bitcoin_accuracy:.1%} Accuracy** und
**{chronos_bitcoin_balanced:.1%} Balanced Accuracy**. Der direkte
Bitcoin-Zusatz innerhalb von Chronos-2 beträgt damit
**{100 * (chronos_bitcoin_accuracy - chronos_control_accuracy):+.1f}
Prozentpunkte bei Accuracy** und
**{100 * (chronos_bitcoin_balanced - chronos_control_balanced):+.1f}
Prozentpunkte bei Balanced Accuracy**.

Die Bitcoin-Variante übertrifft die Kontrollvariante in
**{chronos_bitcoin_year_wins} von {len(VALIDATION_YEARS)}
Validierungsjahren**; in **{chronos_bitcoin_year_ties} Jahren** sind beide
gleich. Sie prognostiziert in **{chronos_bitcoin_positive_rate:.1%}** der Fälle
positiv. Bei der Unsicherheit ist das Ergebnis schwach: Das nominelle
80-%-Intervall deckt univariat **{chronos_zero_coverage:.1%}**, mit
Kontrollfeatures **{chronos_control_coverage:.1%}** und mit Bitcoin
**{chronos_bitcoin_coverage:.1%}** der tatsächlichen Gaps ab. Die
Kovariatenvarianten sind damit deutlich unterkalibriert; ihre Intervalle sind
keine verlässlichen Risikobänder.

Eine rein betragsbasierte Fehlerkennzahl passt nicht zur primären
Richtungsfrage: Eine betragsmässig ungenaue Prognose kann trotzdem die richtige
Richtung nennen, während eine numerisch kleine Abweichung die falsche Seite der
Nullgrenze treffen kann. Die Margin ergänzt deshalb die harte Klassifikation
um die Deutlichkeit der Entscheidung. XGBoost + Bitcoin weist eine mittlere
Boundary-L1-Loss von **{xgboost_bitcoin_boundary:.3f}**, eine mediane signed
margin von **{xgboost_bitcoin_median_margin:.3f}**,
**{xgboost_bitcoin_negative_margin:.1%} negative Margins** und
**{xgboost_bitcoin_uncertain:.1%} grenznahe Prognosen** auf.

Chronos-2 + Bitcoin erreicht auf seiner eigenen Skala eine mittlere
Boundary-L1-Loss von **{chronos_bitcoin_boundary:.3f} Gap-Prozentpunkten** und
eine mediane signed margin von **{chronos_bitcoin_median_margin:.3f}
```

```
Gap-Prozentpunkten**. **{chronos_bitcoin_negative_margin:.1%}** der Margins
sind negativ; bei **{chronos_bitcoin_uncertain:.1%}** der Prognosen umfasst das
80-%-Intervall die Null. Diese Rohwerte werden nicht mit den
Klassifikator-Margins verglichen, weil ihre Scoreeinheiten verschieden sind.

XGBoost mit Bitcoin bleibt bei **{xgboost_bitcoin_accuracy:.1%} Accuracy** und
**{xgboost_bitcoin_balanced:.1%} Balanced Accuracy** die überwachte Referenz.
Der Chronos-Vergleich beantwortet dieselbe Zusatznutzenfrage mit identischen
Features, aber ohne Fine-Tuning. Unterschiede zwischen beiden Methoden sind
als Modellunterschiede und nicht als unterschiedliche verfügbare Information
zu interpretieren. Der Holdout 2026 bleibt weiterhin unangetastet.
        '''
    )
)
```

Interpretation

Die reine Zero-shot-Variante erreicht **54.6% Accuracy** und **49.6% Balanced Accuracy**. Mit den Kontrollfeatures ergeben sich **53.9%** und **50.7%**. Nach Ergänzung der fünf Bitcoin-Merkmale erreicht Chronos-2 **56.2% Accuracy** und **53.5% Balanced Accuracy**. Der direkte Bitcoin-Zusatz innerhalb von Chronos-2 beträgt damit **+2.3 Prozentpunkte bei Accuracy** und **+2.8 Prozentpunkte bei Balanced Accuracy**.

Die Bitcoin-Variante übertrifft die Kontrollvariante in **4 von 5 Validierungsjahren**; in **1 Jahren** sind beide gleich. Sie prognostiziert in **77.4%** der Fälle positiv. Bei der Unsicherheit ist das Ergebnis schwach: Das nominelle 80-%-Intervall deckt univariat **78.0%**, mit Kontrollfeatures **37.4%** und mit Bitcoin **40.1%** der tatsächlichen Gaps ab. Die Kovariatenvarianten sind damit deutlich unterkalibriert; ihre Intervalle sind keine verlässlichen Risikobänder.

Eine rein betragsbasierte Fehlerkennzahl passt nicht zur primären Richtungsfrage: Eine betragsmässig ungenaue Prognose kann trotzdem die richtige Richtung nennen, während eine numerisch kleine Abweichung die falsche Seite der Nullgrenze treffen kann. Die Margin ergänzt deshalb die harte Klassifikation um die Deutlichkeit der Entscheidung. XGBoost + Bitcoin weist eine mittlere Boundary-L1-Loss von **0.063**, eine mediane signed margin von **0.078**, **36.7% negative Margins** und **56.7% grenznahe Prognosen** auf.

Chronos-2 + Bitcoin erreicht auf seiner eigenen Skala eine mittlere Boundary-L1-Loss von **0.075 Gap-Prozentpunkten** und eine mediane signed margin von **0.032 Gap-Prozentpunkten**. **43.8%** der Margins sind negativ; bei **81.7%** der Prognosen umfasst das 80-%-Intervall die Null. Diese Rohwerte werden nicht mit den Klassifikator-Margins verglichen, weil ihre Scoreeinheiten verschieden sind.

XGBoost mit Bitcoin bleibt bei **63.3% Accuracy** und **62.5% Balanced Accuracy** die überwachte Referenz. Der Chronos-Vergleich beantwortet dieselbe Zusatznutzenfrage mit identischen Features, aber ohne Fine-Tuning. Unterschiede zwischen beiden Methoden sind als Modellunterschiede und nicht als unterschiedliche verfügbare Information zu interpretieren. Der Holdout 2026 bleibt weiterhin unangetastet.

12. Finaler Holdout 2026

12.1 Eingefrorene Methodik und überwachte Modelle

Erklärung

Nach Abschluss der Modellentwicklung frieren wir Features, Modellparameter und Entscheidungsregeln ein. Der Holdout umfasst alle im festen Datenbestand verfügbaren QQQ-Handelstage vom 2. Januar bis 31. August 2026. Es handelt sich damit um einen **partiellen 2026-Holdout**, nicht um das vollständige Kalenderjahr.

Auf Basis der vollständig abgeschlossenen Validierung 2021 bis 2025 legen wir **XGBoost + Bitcoin** vor der Auswertung des Holdouts als Hauptmodell fest. Es erreichte dort unter den verglichenen Modellen die höchste Balanced Accuracy. Alle weiteren Varianten bleiben als vorab definierte Benchmarks im finalen Vergleich; die Holdout-Ergebnisse verändern die Modellauswahl nicht.

Wir führen genau einen sequenziellen Walk-forward-Lauf durch. Für jeden Holdout-Tag (t) trainieren wir die überwachten Modelle ausschließlich auf Beobachtungen mit früherem Zieltag:

$$\mathcal{D}_t^{train} = \{(x_i, y_i) : i < t\}.$$

Nach einem Handelstag darf dessen bekannt gewordenes Ziel in die Historie des nächsten Tages eingehen. Dieses Expanding-window-Verfahren entspricht exakt der Validierung 2021 bis 2025. Der aktuelle QQQ-Open bleibt bei jeder Prognose unbekannt. Wir nehmen keine Auswahl, Kalibrierung oder Parameteränderung anhand der Holdout-Ergebnisse vor.

```
# Isolate the final partial holdout only after model development is complete
holdout_data = modeling_data[
    modeling_data["target_session_date"] >= HOLDOUT_START
].copy()
holdout_data = holdout_data.sort_values("target_session_date").reset_index(
    drop=True
)

assert not holdout_data.empty
assert holdout_data["target_session_date"].min() >= HOLDOUT_START
assert holdout_data["target_session_date"].max() < pd.Timestamp(DATA_END_DATE)
assert holdout_data["target_session_date"].is_unique

holdout_supervised_rows = []
for _, observation in holdout_data.iterrows():
    forecast_date = observation["target_session_date"]
    training_history = modeling_data[
        modeling_data["target_session_date"] < forecast_date
    ]

    # The historical majority class uses only labels already observed
    historical_positive_rate = training_history[
        CLASSIFICATION_TARGET
    ].mean()
    holdout_supervised_rows.append(
```

```
        {
            "model": "Historische Mehrheitsklasse",
            "fold_year": forecast_date.year,
            "forecast_date": forecast_date,
            "train_start": training_history["target_session_date"].min(),
            "train_end": training_history["target_session_date"].max(),
            "train_size": len(training_history),
            "train_positive_rate": historical_positive_rate,
            "positive_probability": historical_positive_rate,
            "prediction": int(historical_positive_rate >= 0.5),
            "actual": observation[CLASSIFICATION_TARGET],
            "target_is_monday": observation["target_is_monday"],
        }
    )

    for model_name, feature_columns in LOGISTIC_MODEL_FEATURES.items():
        # Refit the fixed pipeline on the expanding historical window
        classifier = make_pipeline(
            StandardScaler(),
            LogisticRegression(**LOGISTIC_PARAMETERS),
        )
        classifier.fit(
            training_history[feature_columns],
            training_history[CLASSIFICATION_TARGET],
        )
        forecast_features = (
            observation[feature_columns].to_frame().T.astype(float)
        )
        positive_probability = classifier.predict_proba(
            forecast_features
        )[0, 1]
        holdout_supervised_rows.append(
            {
                "model": model_name,
                "fold_year": forecast_date.year,
                "forecast_date": forecast_date,
                "train_start": training_history[
                    "target_session_date"
                ].min(),
                "train_end": training_history[
                    "target_session_date"
                ].max(),
                "train_size": len(training_history),
                "train_positive_rate": training_history[
                    CLASSIFICATION_TARGET
                ].mean(),
                "positive_probability": positive_probability,
                "prediction": int(positive_probability >= 0.5),
                "actual": observation[CLASSIFICATION_TARGET],
                "target_is_monday": observation["target_is_monday"],
            }
        )
```

```
    for model_name, feature_columns in XGBOOST_MODEL_FEATURES.items():
        # Preserve the fixed class weighting and XGBoost configuration
        positive_count = training_history[CLASSIFICATION_TARGET].sum()
        negative_count = len(training_history) - positive_count
        scale_pos_weight = negative_count / positive_count
        classifier = XGBClassifier(
            **XGBOOST_PARAMETERS,
            scale_pos_weight=scale_pos_weight,
        )
        classifier.fit(
            training_history[feature_columns],
            training_history[CLASSIFICATION_TARGET],
        )
        forecast_features = (
            observation[feature_columns].to_frame().T.astype(float)
        )
        positive_probability = classifier.predict_proba(
            forecast_features
        )[0, 1]
        holdout_supervised_rows.append(
            {
                "model": model_name,
                "fold_year": forecast_date.year,
                "forecast_date": forecast_date,
                "train_start": training_history[
                    "target_session_date"
                ].min(),
                "train_end": training_history[
                    "target_session_date"
                ].max(),
                "train_size": len(training_history),
                "train_positive_rate": training_history[
                    CLASSIFICATION_TARGET
                ].mean(),
                "scale_pos_weight": scale_pos_weight,
                "positive_probability": positive_probability,
                "prediction": int(positive_probability >= 0.5),
                "actual": observation[CLASSIFICATION_TARGET],
                "target_is_monday": observation["target_is_monday"],
            }
        )

holdout_supervised_predictions = pd.DataFrame(
    holdout_supervised_rows
).sort_values(["model", "forecast_date"]).reset_index(drop=True)

# Validate shared dates, labels and strict chronology for all five variants
expected_holdout_dates = holdout_data["target_session_date"].tolist()
for model_name in [
    "Historische Mehrheitsklasse",
    *LOGISTIC_MODEL_FEATURES.keys(),
    *XGBOOST_MODEL_FEATURES.keys(),
]:
```

```
    model_predictions = holdout_supervised_predictions[
        holdout_supervised_predictions["model"] == model_name
    ]
    assert len(model_predictions) == len(holdout_data)
    assert model_predictions["forecast_date"].tolist() == expected_holdout_dates
    assert model_predictions["actual"].tolist() == holdout_data[
        CLASSIFICATION_TARGET
    ].tolist()
    assert (
        model_predictions["train_end"]
        < model_predictions["forecast_date"]
    ).all()

assert holdout_supervised_predictions["positive_probability"].between(
    0, 1
).all()
assert holdout_supervised_predictions["prediction"].isin([0, 1]).all()
holdout_supervised_predictions = add_classifier_margin_columns(
    holdout_supervised_predictions
)

supervised_handoff = (
    holdout_supervised_predictions.groupby("model", sort=False)
    .agg(
        Prognosen=("forecast_date", "size"),
        Erste_Prognose=("forecast_date", "min"),
        Letzte_Prognose=("forecast_date", "max"),
        Erstes_Training=("train_size", "min"),
        Letztes_Training=("train_size", "max"),
    )
    .reset_index()
)
display(supervised_handoff)
```

	model	Prognosen	Erste_Prognose	Letzte_Prognose	Erstes_Training	Letztes_Training
0	Historische Mehrheitsklasse	166	2026-01-02	2026-08-31	1945	2110
1	Logistische Regression + Bitcoin	166	2026-01-02	2026-08-31	1945	2110
2	Logistische Regression Kontrolle	166	2026-01-02	2026-08-31	1945	2110
3	XGBoost + Bitcoin	166	2026-01-02	2026-08-31	1945	2110
4	XGBoost Kontrolle	166	2026-01-02	2026-08-31	1945	2110

```
# Explain the supervised holdout handoff from executed checks
holdout_start_date = holdout_data["target_session_date"].min()
holdout_end_date = holdout_data["target_session_date"].max()
holdout_mondays = int(holdout_data["target_is_monday"].sum())
```

```
display(
    Markdown(
        f'''### Interpretation

Der partielle Holdout enthält **{len(holdout_data)} Handelstage** vom
**{holdout_start_date:%d.%m.%Y}** bis **{holdout_end_date:%d.%m.%Y}**, davon
**{holdout_mondays} Montage**. Alle fünf überwachten Varianten prognostizieren
exakt dieselben Termine. Das Expanding Window wächst von
**{int(holdout_supervised_predictions['train_size'].min())}** auf
**{int(holdout_supervised_predictions['train_size'].max())} bekannte
Beobachtungen**. Jede Trainingshistorie endet strikt vor dem jeweiligen
Prognosetag.
        '''
    )
)
```

Interpretation

Der partielle Holdout enthält **166 Handelstage** vom **02.01.2026** bis **31.08.2026**, davon **32 Montage**. Alle fünf überwachten Varianten prognostizieren exakt dieselben Termine. Das Expanding Window wächst von **1945** auf **2110 bekannte Beobachtungen**. Jede Trainingshistorie endet strikt vor dem jeweiligen Prognosetag.

12.2 Chronos-2 auf dem Holdout

Erklärung

Auch Chronos-2 erhält keine Sonderbehandlung für den Holdout. Wir verwenden dieselben drei Varianten, Quantile und die natürliche Richtungsregel wie in der Entwicklung:

$$\widehat{Direction}_t = \mathbb{1}(\widehat{Q}_{0.50,t} > 0).$$

Der Kontext umfasst bei jedem Termin nur frühere QQQ-Gaps. Für die beiden Kovariatenvarianten übergeben wir die historischen Merkmale und den um 09:00 Uhr bekannten aktuellen Feature-Vektor. Es findet weiterhin weder Fine-Tuning noch Schwellenwertoptimierung statt.

```
# Reload the frozen foundation model for the final holdout pass
if DEVICE == "mps":
    torch.mps.empty_cache()

with warnings.catch_warnings():
    warnings.simplefilter("ignore", category=FutureWarning)
    chronos_holdout_pipeline = Chronos2Pipeline.from_pretrained(
        chronos_model_path,
        device_map=DEVICE,
        dtype=torch.float32,
    )

chronos_holdout_rows = []
chronos_holdout_runtime_by_model = {}
```

```
for model_name, feature_columns in CHRONOS_MODEL_FEATURES.items():
    chronos_holdout_inputs = []
    chronos_holdout_metadata = []

    for _, observation in holdout_data.iterrows():
        forecast_date = observation["target_session_date"]
        history = modeling_data[
            modeling_data["target_session_date"] < forecast_date
        ]
        target_history = history[NUMERIC_TARGET].to_numpy(dtype=np.float32)

        if feature_columns:
            chronos_input = {
                "target": target_history,
                "past_covariates": {
                    feature_name: history[feature_name].to_numpy(
                        dtype=np.float32
                    )
                    for feature_name in feature_columns
                },
                "future_covariates": {
                    feature_name: np.asarray(
                        [observation[feature_name]], dtype=np.float32
                    )
                    for feature_name in feature_columns
                },
            }
        else:
            chronos_input = target_history

        chronos_holdout_inputs.append(chronos_input)
        chronos_holdout_metadata.append(
            {
                "model": model_name,
                "fold_year": forecast_date.year,
                "forecast_date": forecast_date,
                "context_start": history["target_session_date"].min(),
                "context_end": history["target_session_date"].max(),
                "context_size": len(history),
                "feature_count": len(feature_columns),
                "actual_gap_log_return": observation[NUMERIC_TARGET],
                "actual_gap_percent": observation["qqq_gap_percent"],
                "actual": observation[CLASSIFICATION_TARGET],
                "target_is_monday": observation["target_is_monday"],
            }
        )

    model_started_at = time.perf_counter()
    quantile_tensors, median_tensors = (
        chronos_holdout_pipeline.predict_quantiles(
            chronos_holdout_inputs,
            prediction_length=1,
```

```
            quantile_levels=CHRONOS_QUANTILES,
            batch_size=CHRONOS_BATCH_SIZE,
            cross_learning=False,
        )
    )
    chronos_holdout_runtime_by_model[model_name] = (
        time.perf_counter() - model_started_at
    )

    for metadata, quantile_tensor, median_tensor in zip(
        chronos_holdout_metadata,
        quantile_tensors,
        median_tensors,
    ):
        quantiles = quantile_tensor[0, 0].detach().float().cpu().numpy()
        predicted_gap_log_return = float(
            median_tensor[0, 0].detach().float().cpu()
        )
        chronos_holdout_rows.append(
            {
                **metadata,
                "q10_gap_log_return": float(quantiles[0]),
                "q50_gap_log_return": float(quantiles[1]),
                "q90_gap_log_return": float(quantiles[2]),
                "predicted_gap_log_return": predicted_gap_log_return,
                "predicted_gap_percent": 100
                * np.expm1(predicted_gap_log_return),
                "prediction": int(predicted_gap_log_return > 0),
            }
        )

chronos_holdout_predictions = pd.DataFrame(
    chronos_holdout_rows
).sort_values(["model", "forecast_date"]).reset_index(drop=True)
chronos_holdout_predictions["inside_80_interval"] = (
    chronos_holdout_predictions["actual_gap_log_return"]
    >= chronos_holdout_predictions["q10_gap_log_return"]
) & (
    chronos_holdout_predictions["actual_gap_log_return"]
    <= chronos_holdout_predictions["q90_gap_log_return"]
)
chronos_holdout_predictions = add_chronos_margin_columns(
    chronos_holdout_predictions
)

# Release the second model instance after the single final inference pass
del chronos_holdout_pipeline, quantile_tensors, median_tensors
gc.collect()
if DEVICE == "mps":
    torch.mps.empty_cache()

chronos_holdout_preview = chronos_holdout_predictions.groupby(
    "model", observed=False, sort=False
```

```
).head(2).copy()
chronos_holdout_numeric = chronos_holdout_preview.select_dtypes(
    include="number"
).columns
chronos_holdout_preview[chronos_holdout_numeric] = chronos_holdout_preview[
    chronos_holdout_numeric
].round(4)
display(chronos_holdout_preview)
```

	model	fold_year	forecast_date	context_start	context_end	context_size	feature_count	actual_gap
0	Chronos-2 + Bitcoin	2026	2026-01-02	2018-03-05	2025-12-31	1945	17	0.0093
1	Chronos-2 + Bitcoin	2026	2026-01-05	2018-03-05	2026-01-02	1946	17	0.0101
166	Chronos-2 Kontrolle	2026	2026-01-02	2018-03-05	2025-12-31	1945	12	0.0093
167	Chronos-2 Kontrolle	2026	2026-01-05	2018-03-05	2026-01-02	1946	12	0.0101
332	Chronos-2 Zero-shot	2026	2026-01-02	2018-03-05	2025-12-31	1945	0	0.0093
333	Chronos-2 Zero-shot	2026	2026-01-05	2018-03-05	2026-01-02	1946	0	0.0101

6 rows × 25 columns

```
# Validate Chronos chronology, quantiles and the unchanged sign rule
for model_name, feature_columns in CHRONOS_MODEL_FEATURES.items():
    model_predictions = chronos_holdout_predictions[
        chronos_holdout_predictions["model"] == model_name
    ]
    assert len(model_predictions) == len(holdout_data)
    assert model_predictions["forecast_date"].tolist() == expected_holdout_dates
    assert model_predictions["actual"].tolist() == holdout_data[
        CLASSIFICATION_TARGET
    ].tolist()
    assert model_predictions["feature_count"].eq(len(feature_columns)).all()
    assert (
        model_predictions["context_end"]
        < model_predictions["forecast_date"]
    ).all()

assert (
    chronos_holdout_predictions["q10_gap_log_return"]
```

```
    <= chronos_holdout_predictions["q50_gap_log_return"]
).all()
assert (
    chronos_holdout_predictions["q50_gap_log_return"]
    <= chronos_holdout_predictions["q90_gap_log_return"]
).all()
assert chronos_holdout_predictions["prediction"].eq(
    (chronos_holdout_predictions["predicted_gap_log_return"] > 0).astype(int)
).all()

# Save one shared forecast-level audit trail for all final model variants
holdout_classification_predictions = pd.concat(
    [
        holdout_supervised_predictions[MARGIN_AUDIT_COLUMNS],
        chronos_holdout_predictions[MARGIN_AUDIT_COLUMNS],
    ],
    ignore_index=True,
)
holdout_output_path = (
    PROCESSED_DATA_DIR / "btc_overnight_qqq_holdout_2026.csv"
)
holdout_classification_predictions.to_csv(holdout_output_path, index=False)

chronos_holdout_handoff = (
    chronos_holdout_predictions.groupby("model", sort=False)
    .agg(
        Prognosen=("forecast_date", "size"),
        Kleinster_Kontext=("context_size", "min"),
        Grösster_Kontext=("context_size", "max"),
        Features=("feature_count", "first"),
    )
    .reset_index()
)
chronos_holdout_handoff["Laufzeit (Sekunden)"] = (
    chronos_holdout_handoff["model"].map(
        chronos_holdout_runtime_by_model
    )
)
display(chronos_holdout_handoff.round(1))
display(
    Markdown(
        f'''### Interpretation

Jede Chronos-2-Variante erzeugt **{len(holdout_data)} Holdout-Prognosen**.
Die Varianten verwenden unverändert **0, {len(CONTROL_FEATURES)} und
{len(FULL_FEATURES)} Kovariaten**. Der historische Kontext wächst während des
Holdouts weiter, endet aber immer vor dem Prognosetag. Die Richtung stammt
ausschließlich aus dem Vorzeichen der Medianprognose.
        '''
    )
)
```

	model	Prognosen	Kleinster_Kontext	Grösster_Kontext	Features	Laufzeit (Sekunden)
0	Chronos-2 + Bitcoin	166	1945	2110	17	21.0
1	Chronos-2 Kontrolle	166	1945	2110	12	15.3
2	Chronos-2 Zero-shot	166	1945	2110	0	1.3

Interpretation

Jede Chronos-2-Variante erzeugt **166 Holdout-Prognosen**. Die Varianten verwenden unverändert **0, 12 und 17 Kovariaten**. Der historische Kontext wächst während des Holdouts weiter, endet aber immer vor dem Prognosetag. Die Richtung stammt ausschließlich aus dem Vorzeichen der Medianprognose.

12.3 Holdout-Ergebnisse und Schlussfolgerung

Erklärung

Wir berichten dieselben primären Metriken wie in der Entwicklung: Accuracy, Balanced Accuracy sowie tatsächliche und prognostizierte Positivrate. Für das vorab festgelegte Hauptmodell zeigt eine Confusion Matrix zusätzlich die korrekt und falsch klassifizierten positiven und negativen Gaps:

$$\begin{pmatrix} TN & FP \\ FN & TP \end{pmatrix}.$$

Die Margin-Auswertung verwendet unverändert die vorab festgelegten Regeln. Für Mehrheitsbaseline, logistische Regression und XGBoost gilt $s_i = 2p_i - 1$; als grenznah gelten $|p_i - 0.5| < 0.10$. Für Chronos-2 ist $s_i = \widehat{Gap}_i^{\%}$, und ein die Null enthaltendes 80-%-Intervall kennzeichnet Richtungsunsicherheit. Wir berichten die Margin-Kennzahlen wegen der verschiedenen Scoreeinheiten getrennt nach Modellfamilie und nehmen keine Schwellenoptimierung am Holdout vor. Die nominale Chronos-Intervallabdeckung bleibt als Diagnose sichtbar.

Der Vergleich zwischen 2021-2025 und dem Holdout dient ausschließlich der Beurteilung der zeitlichen Übertragbarkeit. Die Holdout-Ergebnisse werden nicht für eine nachträgliche Modell- oder Feature-Auswahl verwendet.

```
# Summarize the final classification results on identical holdout dates
holdout_metrics = (
    holdout_classification_predictions.groupby(
        "model", observed=False, sort=False
    )
    .apply(summarize_classification, include_groups=False)
    .reindex(final_model_order)
    .reset_index()
)

holdout_scope_rows = []
for model_name in final_model_order:
    model_predictions = holdout_classification_predictions[
        holdout_classification_predictions["model"] == model_name
```

```
    ]
    for scope_name, scope_frame in [
        ("Alle Handelstage", model_predictions),
        (
            "Montage",
            model_predictions[model_predictions["target_is_monday"] == 1],
        ),
        (
            "Dienstag bis Freitag",
            model_predictions[model_predictions["target_is_monday"] == 0],
        ),
    ]:
        holdout_scope_rows.append(
            {
                "Modell": model_name,
                "Teilmenge": scope_name,
                **summarize_classification(scope_frame).to_dict(),
            }
        )
holdout_scope_metrics = pd.DataFrame(holdout_scope_rows)

chronos_holdout_metrics = (
    chronos_holdout_predictions.groupby(
        "model", observed=False, sort=False
    )
    .apply(summarize_chronos, include_groups=False)
    .reset_index()
)

holdout_classifier_margin_predictions = holdout_supervised_predictions[
    MARGIN_AUDIT_COLUMNS
].copy()
holdout_chronos_margin_predictions = chronos_holdout_predictions[
    MARGIN_AUDIT_COLUMNS
].copy()
holdout_classifier_margin_metrics = (
    holdout_classifier_margin_predictions.groupby(
        "model", observed=False, sort=False
    )
    .apply(summarize_margin, include_groups=False)
    .reindex(all_model_order)
    .reset_index()
)
holdout_chronos_margin_metrics = (
    holdout_chronos_margin_predictions.groupby(
        "model", observed=False, sort=False
    )
    .apply(summarize_margin, include_groups=False)
    .reindex(list(CHRONOS_MODEL_FEATURES))
    .reset_index()
)

development_holdout_comparison = final_development_metrics[
```

```
    ["model", "Accuracy", "Balanced Accuracy"]
].merge(
    holdout_metrics[["model", "Accuracy", "Balanced Accuracy"]],
    on="model",
    suffixes=(" Entwicklung 2021–2025", " Holdout 2026"),
    validate="one_to_one",
)

display(holdout_metrics.round(3))
display(
    holdout_scope_metrics[
        holdout_scope_metrics["Teilmenge"] != "Alle Handelstage"
    ].round(3)
)
# Add a bounded monthly stability check for the strongest model family
xgboost_month_metrics = (
    holdout_classification_predictions[
        holdout_classification_predictions["model"].isin(
            ["XGBoost Kontrolle", "XGBoost + Bitcoin"]
        )
    ]
    .assign(Monat=lambda frame: frame["forecast_date"].dt.month)
    .groupby(["Monat", "model"], observed=False, sort=True)
    .apply(summarize_classification, include_groups=False)
    .reset_index()
)
xgboost_month_balanced = xgboost_month_metrics.pivot(
    index="Monat", columns="model", values="Balanced Accuracy"
).reset_index()

display(chronos_holdout_metrics.round(3))
display(Markdown("#### Margin-Auswertung: probabilistische Klassifikatoren"))
display(holdout_classifier_margin_metrics.round(3))
display(Markdown("#### Margin-Auswertung: Chronos-2"))
display(holdout_chronos_margin_metrics.round(3))
display(development_holdout_comparison.round(3))
display(xgboost_month_balanced.round(3))
```

	model	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy
0	Historische Mehrheitsklasse	166.0	0.566	1.000	0.566	0.500
1	Logistische Regression Kontrolle	166.0	0.566	0.241	0.482	0.517
2	Logistische Regression + Bitcoin	166.0	0.566	0.602	0.663	0.652
3	XGBoost Kontrolle	166.0	0.566	0.283	0.512	0.542
4	XGBoost + Bitcoin	166.0	0.566	0.494	0.735	0.740
5	Chronos-2 Zero-shot	166.0	0.566	1.000	0.566	0.500
6	Chronos-2 Kontrolle	166.0	0.566	0.759	0.530	0.496

	model	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy
7	Chronos-2 + Bitcoin	166.0	0.566	0.717	0.572	0.544

	Modell	Teilmenge	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy
1	Historische Mehrheitsklasse	Montage	32.0	0.531	1.000	0.531	0.500
2	Historische Mehrheitsklasse	Dienstag bis Freitag	134.0	0.575	1.000	0.575	0.500
4	Logistische Regression Kontrolle	Montage	32.0	0.531	0.188	0.469	0.488
5	Logistische Regression Kontrolle	Dienstag bis Freitag	134.0	0.575	0.254	0.485	0.522
7	Logistische Regression + Bitcoin	Montage	32.0	0.531	0.625	0.594	0.586
8	Logistische Regression + Bitcoin	Dienstag bis Freitag	134.0	0.575	0.597	0.679	0.668
10	XGBoost Kontrolle	Montage	32.0	0.531	0.281	0.500	0.514
11	XGBoost Kontrolle	Dienstag bis Freitag	134.0	0.575	0.284	0.515	0.548
13	XGBoost + Bitcoin	Montage	32.0	0.531	0.625	0.719	0.712
14	XGBoost + Bitcoin	Dienstag bis Freitag	134.0	0.575	0.463	0.739	0.750
16	Chronos-2 Zero-shot	Montage	32.0	0.531	1.000	0.531	0.500
17	Chronos-2 Zero-shot	Dienstag bis Freitag	134.0	0.575	1.000	0.575	0.500
19	Chronos-2 Kontrolle	Montage	32.0	0.531	0.844	0.500	0.478
20	Chronos-2 Kontrolle	Dienstag bis Freitag	134.0	0.575	0.739	0.537	0.502
22	Chronos-2 + Bitcoin	Montage	32.0	0.531	0.594	0.562	0.557
23	Chronos-2 + Bitcoin	Dienstag bis Freitag	134.0	0.575	0.746	0.575	0.539

	model	Beobachtungen	Positivrate Ziel	Positivrate Prognose	Accuracy	Balanced Accuracy	Abdeckung 80%-Intervall
0	Chronos-2 + Bitcoin	166.0	0.566	0.717	0.572	0.544	0.313
1	Chronos-2 Kontrolle	166.0	0.566	0.759	0.530	0.496	0.283
2	Chronos-2 Zero-shot	166.0	0.566	1.000	0.566	0.500	0.777

Margin-Auswertung: probabilistische Klassifikatoren

	model	Beobachtungen	Scoretyp	Scoreeinheit	Mittlere Boundary-L1-Loss	Median Signed Margin	Anteil negative Signed Margin	Anteil grenzna unsicher
0	Historische Mehrheitsklasse	166	Probabilistischer Klassifikator	Zentrierte Wahrscheinlichkeit [-1, 1]	0.056	0.126	0.434	1.000
1	Logistische Regression Kontrolle	166	Probabilistischer Klassifikator	Zentrierte Wahrscheinlichkeit [-1, 1]	0.049	-0.003	0.518	0.873
2	Logistische Regression + Bitcoin	166	Probabilistischer Klassifikator	Zentrierte Wahrscheinlichkeit [-1, 1]	0.034	0.074	0.337	0.747
3	XGBoost Kontrolle	166	Probabilistischer Klassifikator	Zentrierte Wahrscheinlichkeit [-1, 1]	0.048	0.004	0.488	0.916
4	XGBoost + Bitcoin	166	Probabilistischer Klassifikator	Zentrierte Wahrscheinlichkeit [-1, 1]	0.055	0.200	0.265	0.380

Margin-Auswertung: Chronos-2

	model	Beobachtungen	Scoretyp	Scoreeinheit	Mittlere Boundary-L1-Loss	Median Signed Margin	Anteil negative Signed Margin	Anteil grenznah unsicher
0	Chronos-2 Zero-shot	166	Chronos-2	Prognostizierter Gap (Prozentpunkte)	0.038	0.062	0.434	1.000
1	Chronos-2 Kontrolle	166	Chronos-2	Prognostizierter Gap (Prozentpunkte)	0.089	0.016	0.470	0.777
2	Chronos-2 + Bitcoin	166	Chronos-2	Prognostizierter Gap (Prozentpunkte)	0.088	0.036	0.428	0.765

	model	Accuracy Entwicklung 2021-2025	Balanced Accuracy Entwicklung 2021-2025	Accuracy Holdout 2026	Balanced Accuracy Holdout 2026
0	Historische Mehrheitsklasse	0.551	0.500	0.566	0.500
1	Logistische Regression Kontrolle	0.524	0.515	0.482	0.517

	model	Accuracy Entwicklung 2021-2025	Balanced Accuracy Entwicklung 2021-2025	Accuracy Holdout 2026	Balanced Accuracy Holdout 2026
2	Logistische Regression + Bitcoin	0.607	0.596	0.663	0.652
3	XGBoost Kontrolle	0.531	0.526	0.512	0.542
4	XGBoost + Bitcoin	0.633	0.625	0.735	0.740
5	Chronos-2 Zero-shot	0.546	0.496	0.566	0.500
6	Chronos-2 Kontrolle	0.539	0.507	0.530	0.496
7	Chronos-2 + Bitcoin	0.562	0.535	0.572	0.544

model	Monat	XGBoost + Bitcoin	XGBoost Kontrolle
0	1	0.562	0.688
1	2	0.705	0.625
2	3	0.725	0.642
3	4	0.923	0.577
4	5	0.571	0.369
5	6	0.808	0.553
6	7	0.909	0.545
7	8	0.611	0.404

```
# Plot final performance and temporal transfer on common scales
holdout_metric_plot = holdout_metrics.melt(
    id_vars="model",
    value_vars=["Accuracy", "Balanced Accuracy"],
    var_name="Metrik",
    value_name="Wert",
)
holdout_metric_plot["Wert (%)"] = 100 * holdout_metric_plot["Wert"]

balanced_transfer_plot = development_holdout_comparison.melt(
    id_vars="model",
    value_vars=[
        "Balanced Accuracy Entwicklung 2021–2025",
        "Balanced Accuracy Holdout 2026",
    ],
    var_name="Periode",
    value_name="Balanced Accuracy",
)
balanced_transfer_plot["Periode"] = balanced_transfer_plot[
    "Periode"
].replace(
    {
        "Balanced Accuracy Entwicklung 2021–2025": "Entwicklung 2021–2025",
        "Balanced Accuracy Holdout 2026": "Holdout 02.01.–31.08.2026",
    }
```

```
)
balanced_transfer_plot["Balanced Accuracy (%)"] = (
    100 * balanced_transfer_plot["Balanced Accuracy"]
)

fig, axes = plt.subplots(1, 2, figsize=(20, 8))
sns.barplot(
    data=holdout_metric_plot,
    y="model",
    x="Wert (%)",
    hue="Metrik",
    order=final_model_order,
    palette=[VIRIDIS(0.25), VIRIDIS(0.72)],
    ax=axes[0],
)
axes[0].axvline(50, color="black", linewidth=1, linestyle="--")
axes[0].set_xlim(0, 75)
axes[0].set_title("Finaler partieller Holdout: 02.01. bis 31.08.2026")
axes[0].set_xlabel("Klassifikationsleistung (%)")
axes[0].set_ylabel("Modell")
axes[0].legend(title="Metrik")

sns.barplot(
    data=balanced_transfer_plot,
    y="model",
    x="Balanced Accuracy (%)",
    hue="Periode",
    order=final_model_order,
    palette=[VIRIDIS(0.30), VIRIDIS(0.78)],
    ax=axes[1],
)
axes[1].axvline(50, color="black", linewidth=1, linestyle="--")
axes[1].set_xlim(0, 75)
axes[1].set_title("Übertragbarkeit auf den partiellen 2026-Holdout")
axes[1].set_xlabel("Balanced Accuracy (%)")
axes[1].set_ylabel("Modell")
axes[1].legend(
    title="Periode",
    loc="upper left",
    bbox_to_anchor=(1.01, 1.0),
)

fig.tight_layout()
plt.show()

# Compare holdout margin distributions on explicitly separate score scales
fig, axes = plt.subplots(1, 2, figsize=(18, 6), sharex=False, sharey=False)
sns.histplot(
    data=holdout_classifier_margin_predictions,
    x="signed_margin",
    hue="model",
    hue_order=all_model_order,
    stat="density",
```

```
    common_norm=False,
    element="step",
    fill=False,
    bins=30,
    palette=[VIRIDIS(value) for value in np.linspace(0.12, 0.88, 5)],
    ax=axes[0],
)
axes[0].axvline(0, color="black", linewidth=1.2, linestyle="--")
axes[0].set_xlim(-1, 1)
axes[0].set_title("Signed Margins der Klassifikatoren im 2026-Holdout")
axes[0].set_xlabel("Signed Margin (zentrierte Wahrscheinlichkeit, [-1, 1])")
axes[0].set_ylabel("Dichte")

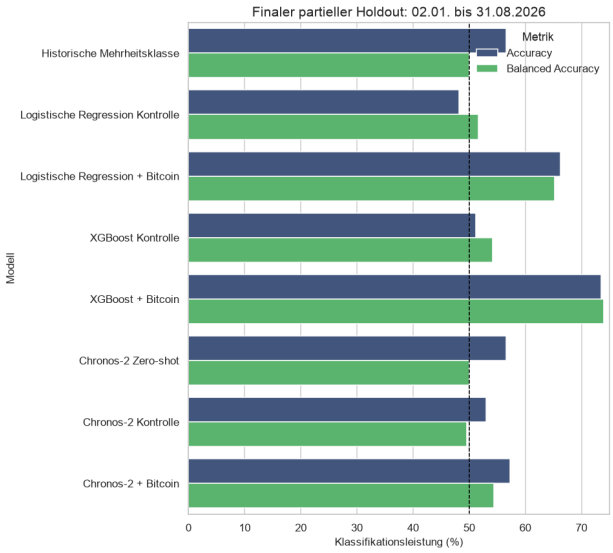
sns.histplot(
    data=holdout_chronos_margin_predictions,
    x="signed_margin",
    hue="model",
    hue_order=list(CHRONOS_MODEL_FEATURES),
    stat="density",
    common_norm=False,
    element="step",
    fill=False,
    bins=30,
    palette=[VIRIDIS(0.20), VIRIDIS(0.50), VIRIDIS(0.80)],
    ax=axes[1],
)
axes[1].axvline(0, color="black", linewidth=1.2, linestyle="--")
axes[1].set_title("Signed Margins von Chronos-2 im 2026-Holdout")
axes[1].set_xlabel("Signed Margin (prognostizierter Gap in Prozentpunkten)")
axes[1].set_ylabel("Dichte")

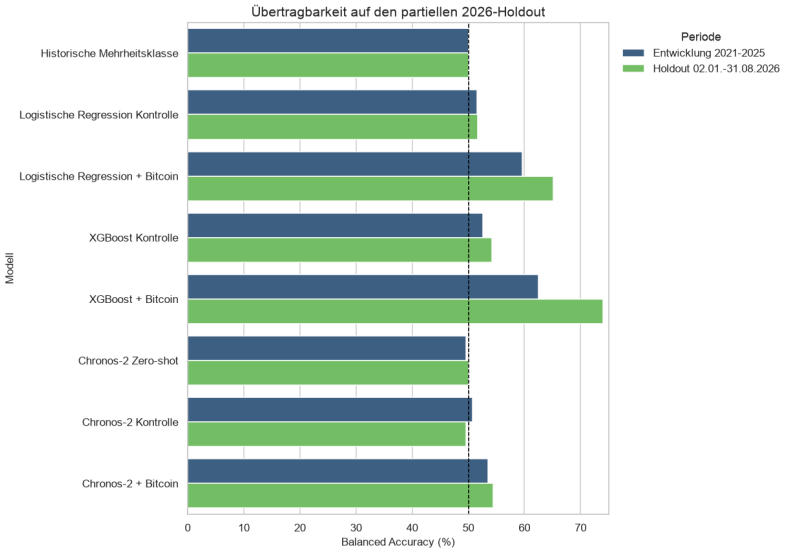
fig.tight_layout()
plt.show()

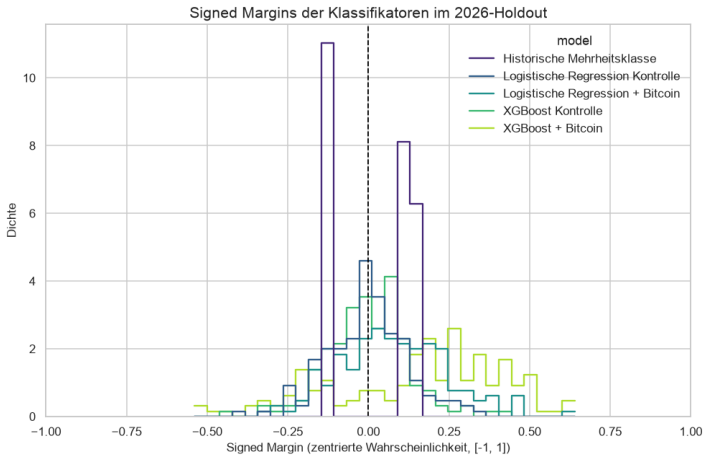
# Show the four outcomes for the preselected final model
from sklearn.metrics import confusion_matrix

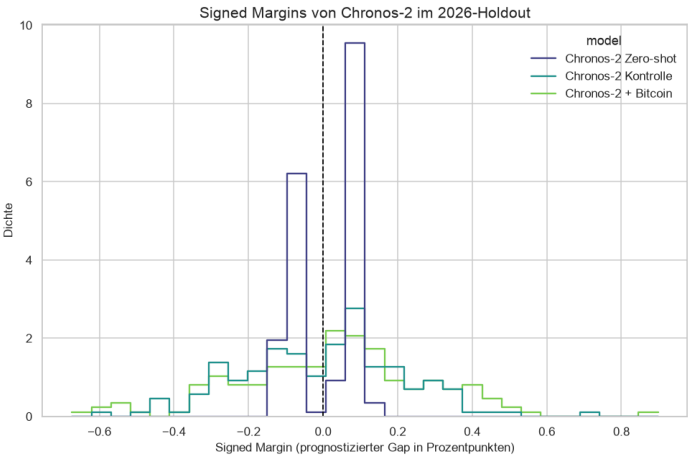
final_model_holdout = holdout_classification_predictions[
    holdout_classification_predictions["model"] == "XGBoost + Bitcoin"
]
final_confusion_matrix = confusion_matrix(
    final_model_holdout["actual"],
    final_model_holdout["prediction"],
    labels=[0, 1],
)
true_negative, false_positive, false_negative, true_positive = (
    final_confusion_matrix.ravel()
)
final_confusion_display = pd.DataFrame(
    final_confusion_matrix,
    index=["Tatsächlich: nicht positiv", "Tatsächlich: positiv"],
    columns=["Prognose: nicht positiv", "Prognose: positiv"],
)
```

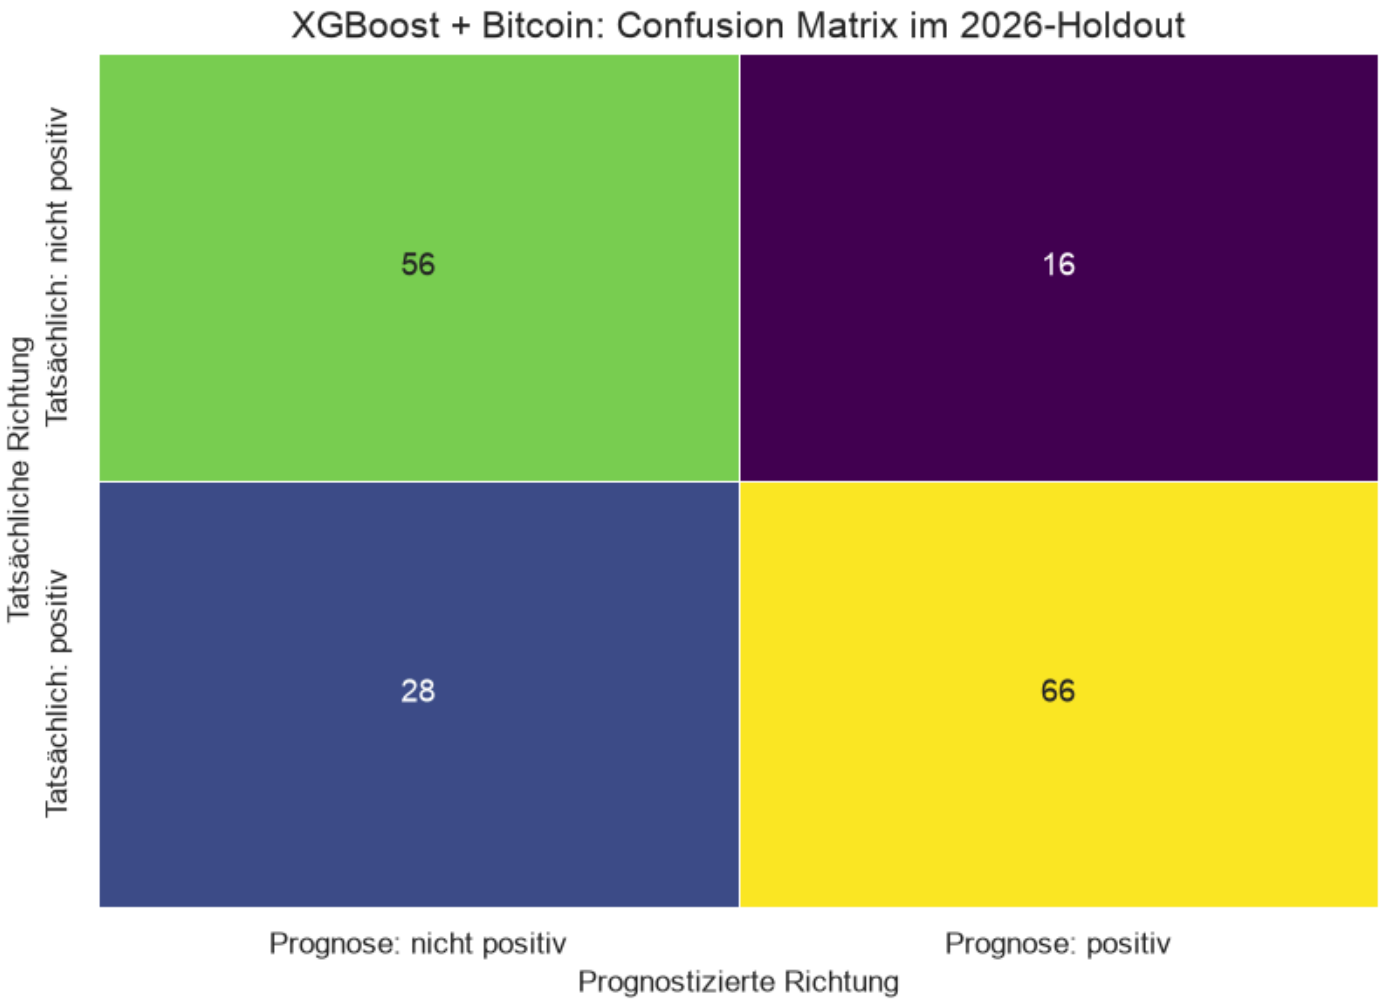
```
plt.figure(figsize=(7.5, 5.5))
sns.heatmap(
    final_confusion_display,
    annot=True,
    fmt="d",
    cmap="viridis",
    cbar=False,
    linewidths=0.5,
)
plt.title("XGBoost + Bitcoin: Confusion Matrix im 2026-Holdout")
plt.xlabel("Prognostizierte Richtung")
plt.ylabel("Tatsächliche Richtung")
plt.tight_layout()
plt.show()
```












```
# Derive the final narrative only from the executed holdout results
holdout_indexed = holdout_metrics.set_index("model")
holdout_winner = holdout_indexed["Balanced Accuracy"].idxmax()
holdout_winner_balanced = holdout_indexed.loc[
    holdout_winner, "Balanced Accuracy"
]
holdout_winner_accuracy = holdout_indexed.loc[holdout_winner, "Accuracy"]
holdout_target_positive_rate = holdout_data[CLASSIFICATION_TARGET].mean()

logistic_holdout_lift = (
    holdout_indexed.loc[
        "Logistische Regression + Bitcoin", "Balanced Accuracy"
    ]
    - holdout_indexed.loc[
        "Logistische Regression Kontrolle", "Balanced Accuracy"
    ]
)
xgboost_holdout_lift = (
    holdout_indexed.loc["XGBoost + Bitcoin", "Balanced Accuracy"]
    - holdout_indexed.loc["XGBoost Kontrolle", "Balanced Accuracy"]
)
chronos_holdout_lift = (
    holdout_indexed.loc["Chronos-2 + Bitcoin", "Balanced Accuracy"]
    - holdout_indexed.loc["Chronos-2 Kontrolle", "Balanced Accuracy"]
```

```
)

xgboost_development_balanced = final_metrics_indexed.loc[
    "XGBoost + Bitcoin", "Balanced Accuracy"
]
xgboost_holdout_accuracy = holdout_indexed.loc[
    "XGBoost + Bitcoin", "Accuracy"
]
xgboost_holdout_balanced = holdout_indexed.loc[
    "XGBoost + Bitcoin", "Balanced Accuracy"
]
xgboost_bitcoin_month_wins = int(
    (
        xgboost_month_balanced["XGBoost + Bitcoin"]
        > xgboost_month_balanced["XGBoost Kontrolle"]
    ).sum()
)
holdout_months = holdout_data["target_session_date"].dt.month.nunique()

holdout_classifier_margin_indexed = holdout_classifier_margin_metrics.set_index(
    "model"
)
holdout_chronos_margin_indexed = holdout_chronos_margin_metrics.set_index(
    "model"
)
xgboost_holdout_boundary = holdout_classifier_margin_indexed.loc[
    "XGBoost + Bitcoin", "Mittlere Boundary-L1-Loss"
]
xgboost_holdout_median_margin = holdout_classifier_margin_indexed.loc[
    "XGBoost + Bitcoin", "Median Signed Margin"
]
xgboost_holdout_negative_margin = holdout_classifier_margin_indexed.loc[
    "XGBoost + Bitcoin", "Anteil negative Signed Margin"
]
xgboost_holdout_uncertain = holdout_classifier_margin_indexed.loc[
    "XGBoost + Bitcoin", "Anteil grenznah unsicher"
]
chronos_holdout_boundary = holdout_chronos_margin_indexed.loc[
    "Chronos-2 + Bitcoin", "Mittlere Boundary-L1-Loss"
]
chronos_holdout_median_margin = holdout_chronos_margin_indexed.loc[
    "Chronos-2 + Bitcoin", "Median Signed Margin"
]
chronos_holdout_negative_margin = holdout_chronos_margin_indexed.loc[
    "Chronos-2 + Bitcoin", "Anteil negative Signed Margin"
]
chronos_holdout_uncertain = holdout_chronos_margin_indexed.loc[
    "Chronos-2 + Bitcoin", "Anteil grenznah unsicher"
]

display(
    Markdown(
        f'''### Interpretation
```

```
Der partielle 2026-Holdout enthält **{len(holdout_data)} Beobachtungen** und
eine tatsächliche Positivrate von **{holdout_target_positive_rate:.1%}**. Die
höchste Balanced Accuracy erreicht **{holdout_winner}** mit
**{holdout_winner_balanced:.1%}**; seine Accuracy beträgt
**{holdout_winner_accuracy:.1%}**.

Das bereits vor dem Holdout festgelegte Hauptmodell
**XGBoost + Bitcoin** erzielt **{xgboost_holdout_accuracy:.1%} Accuracy** und
**{xgboost_holdout_balanced:.1%} Balanced Accuracy**, gegenüber
**{xgboost_development_balanced:.1%} Balanced Accuracy** in der Validierung
2021 bis 2025. Der Bitcoin-Zusatz verändert die Holdout-Balanced-Accuracy
innerhalb der logistischen Regression um
**{100 * logistic_holdout_lift:+.1f} Prozentpunkte**, innerhalb von XGBoost um
**{100 * xgboost_holdout_lift:+.1f} Prozentpunkte** und innerhalb von
Chronos-2 um **{100 * chronos_holdout_lift:+.1f} Prozentpunkte**.
XGBoost mit Bitcoin übertrifft seine Kontrollvariante in
**{xgboost_bitcoin_month_wins} von {holdout_months} Kalendermonaten**. Diese Monatswerte
umfassen jeweils nur 19 bis 22 Beobachtungen und dienen daher ausschließlich
als einfache Stabilitätskontrolle. Die Confusion Matrix enthält
**{true_negative} korrekt negative** und **{true_positive} korrekt positive**
Prognosen sowie **{false_positive} falsch positive** und
**{false_negative} falsch negative** Fälle. Das tägliche Neutraining verwendet
dabei jeweils nur Ziele, die vor dem aktuellen Prognosetag bereits bekannt
sind.

Die Margin-Auswertung ergänzt die harte Richtung um die Distanz zur
Entscheidungsgrenze. XGBoost + Bitcoin erreicht im Holdout eine mittlere
Boundary-L1-Loss von **{xgboost_holdout_boundary:.3f}**, eine mediane signed
margin von **{xgboost_holdout_median_margin:.3f}**,
**{xgboost_holdout_negative_margin:.1%} negative Margins** und
**{xgboost_holdout_uncertain:.1%} grenznahe Prognosen**. Chronos-2 + Bitcoin
weist auf seiner eigenen Skala eine mittlere Boundary-L1-Loss von
**{chronos_holdout_boundary:.3f} Gap-Prozentpunkten**, eine mediane signed
margin von **{chronos_holdout_median_margin:.3f} Gap-Prozentpunkten**,
**{chronos_holdout_negative_margin:.1%} negative Margins** und
**{chronos_holdout_uncertain:.1%} die Null umfassende Intervalle** auf. Die
Rohwerte beider Modellfamilien sind wegen ihrer unterschiedlichen
Scoreeinheiten nicht direkt vergleichbar. Alle Unsicherheitsregeln wurden vor
dem Holdout festgelegt und nicht nachträglich optimiert.

Praktisch interpretieren wir die Richtungsprognose nicht als fertige
Handelsstrategie, sondern als mögliches Frühwarnsignal für Overnight-Risiken.
Ein Portfolio-Manager mit bestehender QQQ- oder Nasdaq-Exposition könnte eine
negative Prognose vor der US-Markteröffnung als zusätzliche Information für
die Risikobeurteilung verwenden. Wir testen weder eine konkrete Hedging- noch
eine Handels- oder Execution-Strategie. Ein wirtschaftlicher Nutzen würde von
Transaktionskosten, Liquidität, Ausführungszeitpunkt und den verfügbaren
Instrumenten abhängen.

Eine mögliche ökonomische Erklärung ist, dass der rund um die Uhr gehandelte
Bitcoin-Markt während der geschlossenen US-Kassamärkte als Proxy für globale
Risikostimmung, kurzfristige Risikoaversion oder die internationale
```

```
Verarbeitung neuer Informationen fungiert. BTC-Overnight-Returns und
Drawdowns könnten Teile dieser Stimmung enthalten. Dies ist eine Hypothese und
kein kausaler Befund: Die Analyse kann nicht unterscheiden, ob Bitcoin selbst
Information überträgt oder ob Bitcoin und QQQ lediglich gemeinsam auf globale
Nachrichten reagieren.

Damit beurteilen wir die ursprüngliche Hypothese auf einem zeitlich späteren,
vollständig getrennten Zeitraum. Unterschiede zwischen Entwicklung und
Holdout zeigen zeitliche Instabilität und dürfen nicht durch nachträgliches
Tuning geglättet werden. Wegen der auf acht Monate begrenzten Periode mit nur
**{holdout_mondays} Montagen** sind insbesondere Wochentagsresultate
deskriptiv. Die Auswertung belegt eine Prognosebeziehung, aber weder
Kausalität noch nachgewiesene Profitabilität. Die Resultate dürfen nicht über
den untersuchten Zeitraum hinaus verallgemeinert werden.
        '''
    )
)
```

Interpretation

Der partielle 2026-Holdout enthält **166 Beobachtungen** und eine tatsächliche Positivrate von **56.6%**. Die höchste Balanced Accuracy erreicht **XGBoost + Bitcoin** mit **74.0%**; seine Accuracy beträgt **73.5%**.

Das bereits vor dem Holdout festgelegte Hauptmodell **XGBoost + Bitcoin** erzielt **73.5% Accuracy** und **74.0% Balanced Accuracy**, gegenüber **62.5% Balanced Accuracy** in der Validierung 2021 bis 2025. Der Bitcoin-Zusatz verändert die Holdout-Balanced-Accuracy innerhalb der logistischen Regression um **+13.5 Prozentpunkte**, innerhalb von XGBoost um **+19.8 Prozentpunkte** und innerhalb von Chronos-2 um **+4.9 Prozentpunkte**. XGBoost mit Bitcoin übertrifft seine Kontrollvariante in **7 von 8 Kalendermonaten**. Diese Monatswerte umfassen jeweils nur 19 bis 22 Beobachtungen und dienen daher ausschließlich als einfache Stabilitätskontrolle. Die Confusion Matrix enthält **56 korrekt negative** und **66 korrekt positive** Prognosen sowie **16 falsch positive** und **28 falsch negative** Fälle. Das tägliche Neutraining verwendet dabei jeweils nur Ziele, die vor dem aktuellen Prognosetag bereits bekannt sind.

Die Margin-Auswertung ergänzt die harte Richtung um die Distanz zur Entscheidungsgrenze. XGBoost + Bitcoin erreicht im Holdout eine mittlere Boundary-L1-Loss von **0.055**, eine mediane signed margin von **0.200**, **26.5% negative Margins** und **38.0% grenznahe Prognosen**. Chronos-2 + Bitcoin weist auf seiner eigenen Skala eine mittlere Boundary-L1-Loss von **0.088 Gap-Prozentpunkten**, eine mediane signed margin von **0.036 Gap-Prozentpunkten**, **42.8% negative Margins** und **76.5% die Null umfassende Intervalle** auf. Die Rohwerte beider Modellfamilien sind wegen ihrer unterschiedlichen Scoreeinheiten nicht direkt vergleichbar. Alle Unsicherheitsregeln wurden vor dem Holdout festgelegt und nicht nachträglich optimiert.

Praktisch interpretieren wir die Richtungsprognose nicht als fertige Handelsstrategie, sondern als mögliches Frühwarnsignal für Overnight-Risiken. Ein Portfolio-Manager mit bestehender QQQ- oder Nasdaq-Exposition könnte eine negative Prognose vor der US-Markteröffnung als zusätzliche Information für die Risikobeurteilung verwenden. Wir testen weder eine konkrete Hedging- noch eine Handels- oder Execution-Strategie. Ein wirtschaftlicher Nutzen würde von Transaktionskosten, Liquidität, Ausführungszeitpunkt und den verfügbaren Instrumenten abhängen.

Eine mögliche ökonomische Erklärung ist, dass der rund um die Uhr gehandelte Bitcoin-Markt während der geschlossenen US-Kassamärkte als Proxy für globale Risikostimmung, kurzfristige Risikoaversion oder die internationale Verarbeitung neuer Informationen fungiert. BTC-Overnight-Returns und Drawdowns könnten Teile dieser Stimmung enthalten. Dies ist eine Hypothese und kein kausaler Befund: Die Analyse kann nicht unterscheiden, ob Bitcoin selbst Information überträgt oder ob Bitcoin und QQQ lediglich gemeinsam auf globale Nachrichten reagieren.

Damit beurteilen wir die ursprüngliche Hypothese auf einem zeitlich späteren, vollständig getrennten Zeitraum. Unterschiede zwischen Entwicklung und Holdout zeigen zeitliche Instabilität und dürfen nicht durch nachträgliches Tuning geglättet werden. Wegen der auf acht Monate begrenzten Periode mit nur **32 Montagen** sind insbesondere Wochentagsresultate deskriptiv. Die Auswertung belegt eine Prognosebeziehung, aber weder Kausalität noch nachgewiesene Profitabilität. Die Resultate dürfen nicht über den untersuchten Zeitraum hinaus verallgemeinert werden.

13. Modellvergleich über die Prognosegüte hinaus

Die Modelle unterscheiden sich nicht nur in Accuracy und Balanced Accuracy, sondern auch in Erklärbarkeit, Robustheit, Rechenleistung und Generalisierbarkeit. Wir ordnen diese Eigenschaften qualitativ ein; ein kontrollierter Laufzeit- oder Speicherbenchmark ist nicht Teil der Analyse.

Erklärbarkeit. Die historische Mehrheitsklasse ist vollständig transparent, kann aber keine Merkmale auswerten. Die logistische Regression besitzt eine klar definierte lineare Entscheidungsfunktion und ist damit am einfachsten inhaltlich zu interpretieren. XGBoost kann nichtlineare Zusammenhänge und Interaktionen abbilden; seine Feature-Importances zeigen, welche Variablen das Modell verwendet, aber weder Wirkungsrichtung noch Kausalität. Chronos-2 ist als vortrainiertes neuronales Modell am wenigsten direkt erklärbar. Quantile und Prognoseintervalle machen seine Unsicherheit sichtbar, erklären jedoch nicht die interne Entstehung einer Prognose.

Robustheit. Alle Modelle werden auf identischen chronologischen Terminen bewertet. Jährliche Expanding-window-Folds, Wochentagsauswertungen, die monatliche Stabilitätskontrolle und der zeitlich spätere Holdout prüfen die Stabilität aus mehreren Perspektiven. XGBoost mit Bitcoin liefert dabei die stärkste Holdout-Leistung, zeigt aber wie alle Modelle zeitliche Schwankungen. Bei Chronos-2 weisen insbesondere die deutlich unter dem Nominalwert liegenden Intervallabdeckungen auf eine geringe Robustheit der Unsicherheitsschätzung in dieser Anwendung hin.

Rechenleistung. Mehrheitsklasse und logistische Regression sind leichtgewichtig und auf der CPU schnell ausführbar. XGBoost benötigt wegen des täglichen Neutrainings mehr Rechenaufwand, bleibt mit flachen Bäumen und der CPU-optimierten Histogramm-Methode aber praktikabel. Chronos-2 hat den höchsten qualitativen Ressourcenbedarf: Es erfordert einen Modelldownload, PyTorch sowie mehr Speicher und profitiert auf Apple Silicon von MPS. Die ausgewiesenen Chronos-Laufzeiten gelten nur für die dokumentierte Hardware und sind kein kontrollierter Geschwindigkeitsvergleich der Modellklassen.

Generalisierbarkeit. Der Holdout zeigt, dass sich die vorab festgelegte Methode auf einen späteren Zeitraum übertragen lässt. Daraus folgt jedoch keine allgemeine Gültigkeit für andere Marktphasen, Assets oder Prognosezeitpunkte. Das breite Vortraining von Chronos-2 garantiert keinen Vorteil in dieser spezialisierten Aufgabe; umgekehrt belegt die bessere XGBoost-Leistung nur den Nutzen innerhalb des untersuchten QQQ-Bitcoin-Setups. Die Generalisierbarkeit über diesen Rahmen hinaus bleibt offen.